

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт (национальный
исследовательский институт)»
Факультет управления и прикладной математики
Кафедра «Интеллектуальные системы»

Приложения алгоритма Франк-Вульфа к задачам машинного обучения

Выпускная квалификационная работа
(магистерская диссертация)

Направление подготовки: 09.04.01 «Информатика и вычислительная
техника»

Выполнил:

магистрант

Игнашин Игорь Николаевич

(подпись обучающегося)

Научный руководитель:

доктор физико-математических наук

Грабовой Андрей Олегович

(подпись научного руководителя)

Москва 2026

Аннотация

Работа посвящена приложениям алгоритма Frank–Wolfe к задачам машинного обучения и смежным задачам крупномасштабной выпуклой оптимизации. Цель работы состоит в развитии проекционно-свободных модификаций Frank–Wolfe, уменьшающих вычислительную стоимость итерации без потери базовых гарантий сходимости. Для достижения этой цели рассматриваются методы с памятью о предыдущих направлениях, перенос CFW и NFW на гладкие задачи машинного обучения, стохастический блочно-координатный SOFW для транспортных сетей и децентрализованный блочно-координатный DBCFW. Получены оценки сходимости для CFW, SOFW и DBCFW, описаны специальные случаи этих методов и проведены эксперименты для логистической регрессии и задач распределения транспортных потоков. Результаты работы могут использоваться при выборе модификации Frank–Wolfe под конкретное вычислительное ограничение: стоимость линейного оракула, выбор направления или распределенный характер данных.

Ключевые слова: Frank–Wolfe; условный градиент; машинное обучение; выпуклая оптимизация; моментум по направлениям; сопряженные направления; SOFW; стохастический LMO; блочно-координатная оптимизация; распределенная оптимизация.

Содержание

Обозначения и сокращения	6
Сокращения	7
1 Введение	9
1.1 Актуальность	11
1.2 Научная новизна и практическая значимость	11
1.3 Цель работы	13
1.4 Задачи работы	13
1.5 Структура работы	14
2 Модификации алгоритма Frank–Wolfe	15
2.1 Модель Бекмана	15
2.2 Оптимальные условия модели Бекмана	17
2.3 Линейный оракул как all-or-nothing assignment	17
2.4 Классический алгоритм Frank–Wolfe	18
2.5 Conjugate Frank–Wolfe	20
2.6 Fukushima Frank–Wolfe и WFFW	21
2.7 N-conjugate Frank–Wolfe	21
2.8 Экспериментальные результаты	22
2.9 Более подробная запись CFW и BFW	22
2.10 Вывод коэффициентов NFW	24
2.11 Fukushima Frank–Wolfe как сглаживание направлений	26
2.12 Относительный зазор и критерий останова	28
2.13 Серии экспериментов	30
2.14 Одномерный поиск для BPR-функций	35
2.15 Итоги раздела	36
2.16 Выводы по модификациям	36
3 Сопряженный Frank–Wolfe в задачах машинного обучения	38
3.1 Базовый FW для гладкой выпуклой задачи	38
3.2 CFW без явного вычисления гессиана	39
3.3 Сходимость CFW	40
3.4 NFW в машинном обучении	44
3.5 Эксперименты на логистической регрессии	46

3.6	Выводы по CFW in ML	54
4	Стохастический блочно-координатный Frank–Wolfe	55
4.1	Блочная структура транспортной задачи	55
4.2	Stochastic Origin Frank–Wolfe	56
4.3	Статическое назначение потоков и роль модели Бекмана . .	56
4.4	Path-based и link-based представления	57
4.5	Взвешенный вариант	59
4.6	Сходимость	59
4.7	Доказательство батчевой оценки	61
4.8	Вычислительная сложность и память	64
4.9	Экспериментальные результаты	64
4.10	Интерпретация графиков SOFW	67
4.11	Переход от OD-пар к источникам	68
4.12	Обновление разложения потока	68
4.13	Равномерная и взвешенная выборка	69
4.14	Влияние батча на теоретический порядок	70
4.15	Память и время	70
4.16	Итоги раздела	71
4.17	Выводы по BCFW/SOFW	71
5	Децентрализованный блочно-координатный Frank–Wolfe	72
5.1	Мотивация и место DBCFW среди FW-методов	72
5.2	Связанные направления	73
5.3	Постановка распределенной задачи	73
5.4	Коммуникационная модель	74
5.5	Алгоритм DBCFW	75
5.6	Связь с классическим DFW	76
5.7	Полный DFW как предельный случай	77
5.8	Отличие SOFW от обычного DFW	78
5.9	Кривизна и оценка сходимости	80
5.10	Доказательство оценки DBCFW	89
5.11	Блочный линейный оракул	93
5.12	Специальные случаи DBCFW	94
5.13	Интерпретация констант в оценке	94

5.14	Итоги раздела	95
5.15	Выводы по DBCFW	95
6	Заключение	97
6.1	Итоги по главам	97
6.2	Ограничения и дальнейшая работа	98
	Список использованных источников	100

Обозначения и сокращения

В работе используется единая система обозначений для рассматриваемых методов. Часть обозначений относится к транспортной постановке, часть – к общей выпуклой и распределенной оптимизации. Ниже приведено согласование обозначений, которое используется в дальнейшем тексте.

$\mathcal{X}$, D допустимое множество; в транспортной задаче обычно множество путей потоков, в ML-задаче множество параметров модели.

$D_1 \times \dots \times D_n$ декартова блочная структура допустимого множества.

x переменная оптимизации в общей задаче и в задачах машинного обучения.

f поток по ребрам транспортной сети; также $f(x)$ обозначает целевую функцию в общей оптимизации, если это не конфликтует с контекстом.

$\Psi(f)$ потенциал Бекмана в задаче равновесного распределения транспортных потоков.

$\tau(f)$ вектор времен движения по ребрам; равен $\nabla \Psi(f)$.

Θ матрица принадлежности ребер путям, переводящая путевые потоки в потоки по ребрам.

OD множество пар источник–сток.

$\mathcal{P}_{ij}$ множество путей между источником i и стоком j .

d_{ij} спрос между источником i и стоком j .

s_k^{FW} решение линейного оракула Frank–Wolfe на итерации k .

d_k направление шага; в транспортных главах не смешивается со спросом d_{ij} , потому что индекс и контекст различают эти величины.

γ_k длина шага FW.

g_k зазор Frank–Wolfe.

H_k гессиан целевой функции в текущей точке.

N в главах о NFW – число прошлых направлений; в главе о DBCFW – число агентов, если явно указан распределенный контекст.

B размер батча блоков в DBCFW.

W_t матрица смешивания коммуникационного графа.

x_t^i локальная точка агента i на итерации t .

g_t^i локальная оценка градиента в градиентном отслеживании.

$x_{\text{avg},t}$ средняя точка по агентам.

Сокращения

FW Frank–Wolfe, метод условного градиента.

CFW Conjugate Frank–Wolfe.

BFW Bi-conjugate Frank–Wolfe.

NFW N-conjugate Frank–Wolfe.

FFW Fukushima Frank–Wolfe.

WFFW Weighted Fukushima Frank–Wolfe.

BCFW Block-Coordinate Frank–Wolfe, блочно-координатный Frank–Wolfe.

SOFW Stochastic Origin Frank–Wolfe.

DFW Decentralized Frank–Wolfe.

DBCFW Decentralized Block-Coordinate Frank–Wolfe.

LMO linear minimization oracle, линейный оракул.

BPR Bureau of Public Roads travel time function.

OD origin–destination pair, пара источник–сток.

Линия развития методов

Рассматриваемая линия методов может быть интерпретирована как последовательное расширение проекционно-свободной оптимизации по трем исследовательским осям: геометрия направления, стоимость линейного оракула и распределенная информационная структура. Первое направление связано с улучшением геометрии шага Frank–Wolfe. В транспортной задаче это приводит к методам CFW, BFW, NFW, FFW и WFFW, которые используют память о предыдущих направлениях для уменьшения зигзагообразного поведения траектории.

Второе направление состоит в адаптации сопряженных FW-методов к задачам машинного обучения. Главная трудность состоит в стоимости вычисления и хранения гессиана, а также в стоимости точных произведений гессиана на направления. Поэтому информация о кривизне приближается конечными разностями градиентов. Так сохраняется идея сопряженности, но алгоритм остается практически применимым.

Третье направление исследует другой вычислительный предел FW – стоимость полного линейного оракула. В крупной транспортной сети полный оракул требует решать задачи кратчайших путей для всех источников на каждой итерации. SOFW заменяет полный оракул случайным блочным оракулом и тем самым связывает транспортный Frank–Wolfe с теорией стохастических блочно-координатных методов.

Четвертое направление обобщает блочную стохастичность на распределенную оптимизацию. DBCFW соединяет локальные функции агентов, консенсус через матрицу смешивания, отслеживание градиента и блочный линейный оракул. Тем самым случайный выбор блоков становится частью децентрализованной схемы условного градиента.

1 Введение

Алгоритм Frank–Wolfe, также известный как метод условного градиента, был предложен для задач квадратичного программирования и стал одним из базовых проекционно-свободных методов выпуклой оптимизации [1]. В отличие от проекционных градиентных методов, на каждой итерации он решает линейную задачу минимизации на допустимом множестве. Это делает метод особенно удобным для задач, в которых линейный оракул существенно дешевле евклидовой проекции: оптимизация на симплексах, транспортных политопах, ядерных шарах, множествах с ограничением на l_1 -норму и других структурированных областях [2, 3].

В машинном обучении оптимизация параметров обычно формулируется как минимизация функции потерь с регуляризацией. Регуляризованная задача

$$f(x) + \mu g(x) \rightarrow \min_x$$

может быть рассмотрена как задача с ограничением

$$f(x) \rightarrow \min_{x \in \mathcal{X}},$$

где множество $\mathcal{X}$ задает допустимую область параметров. Если для $\mathcal{X}$ эффективен линейный оракул, методы Frank–Wolfe позволяют решать такие задачи без явного вычисления проекции. Это особенно важно в задачах высокой размерности, где проекция может быть основной вычислительной нагрузкой.

Классический алгоритм Frank–Wolfe эффективен на первых итерациях, но часто замедляется при приближении к решению. Одной из причин является зигзагообразное движение траектории около условного минимума [4]. Однако зигзагообразность является только одним из вычислительных ограничений метода. В разных постановках узким местом может быть не только геометрия направления, но и стоимость полного линейного оракула, вычисление информации второго порядка или коммуникация между агентами. Поэтому развитие Frank–Wolfe естественно идет не по одной линии, а по нескольким взаимосвязанным исследовательским направлениям.

Первое направление удобно анализировать в бекмановской постановке равновесного распределения транспортных потоков. В этой задаче ли-

нейный оракул имеет понятную структуру кратчайших путей, а гессиан целевой функции диагонален, что позволяет детально исследовать модификации направления шага: CFW, BFW, NFW, FFW и WFFW. Второе направление переносит идею сопряженных направлений в задачи машинного обучения. Здесь явное использование гессиана и точных Hessian-vector products становится вычислительно дорогим, поэтому произведения гессиана на направления аппроксимируются конечными разностями градиентов. Третье направление снова возникает в транспортных сетях, но отвечает на другой вопрос: как уменьшить стоимость полного ЛМО, если на каждой итерации приходится решать задачи кратчайших путей для большого числа источников. Это приводит к SOFW как стохастическому блочно-координатному варианту FW. Наконец, четвертое направление рассматривает распределенную постановку, где у агентов есть локальные функции, а алгоритм должен совмещать блочный линейный оракул, консенсус и отслеживание градиента. В этой части DBCFW выступает как распределенное обобщение блочно-координатного подхода: блочная структура сохраняет дешевизну локальных ЛМО-шагов, а механизмы консенсуса и отслеживания градиента позволяют согласовывать локальные обновления между агентами.

Таким образом, работа объединяет четыре связанных направления модификации Frank–Wolfe:

1. модификации FW в задаче равновесного распределения транспортных потоков;
2. перенос Conjugate Frank–Wolfe и N-conjugate Frank–Wolfe на задачи машинного обучения;
3. стохастический блочно-координатный Frank–Wolfe для крупномасштабных транспортных сетей;
4. децентрализованный блочно-координатный Frank–Wolfe для распределенной оптимизации.

1.1 Актуальность

Актуальность работы связана с тем, что многие современные задачи машинного обучения и сетевой оптимизации имеют одновременно три свойства. Во-первых, размерность переменной велика, и поэтому проекция на допустимое множество может быть дорогой операцией. Во-вторых, допустимое множество часто имеет структуру, для которой линейный оракул вычисляется существенно проще проекции. В-третьих, данные и вычисления могут быть распределены: либо по блокам задачи, либо по агентам, либо по источникам транспортного спроса.

Алгоритм Frank–Wolfe естественно подходит для таких условий, потому что он заменяет проекцию линейной минимизацией. Однако базовый FW не решает все вычислительные проблемы. В транспортных задачах он может требовать слишком дорогой полной итерации. В задачах с активной границей допустимого множества он часто демонстрирует зигзагообразное движение. В распределенных задачах необходимо дополнительно учитывать консенсус между агентами и ошибку приближения глобального градиента. Поэтому практическая эффективность FW зависит не только от классической теоретической оценки сходимости, но и от архитектуры итерации.

Рассматриваемые в работе методы образуют единую исследовательскую линию. Первое направление изучает геометрию шага FW и использует память о предыдущих направлениях для подавления зигзагообразного поведения. Второе направление адаптирует эту идею к задачам машинного обучения, где информация второго порядка должна извлекаться без явного построения гессиана. Третье направление рассматривает стоимость полного линейного оракула как самостоятельное вычислительное ограничение и приводит к стохастическим блочно-координатным схемам. Четвертое направление объединяет блочный оракул с децентрализованной оптимизацией, консенсусом и отслеживанием градиента.

1.2 Научная новизна и практическая значимость

Научная новизна работы состоит в развитии нескольких модификаций Frank–Wolfe как единой линии проекционно-свободных методов с яв-

ным теоретическим обоснованием. CFW, NFW, SOFW и DBCFW обычно можно рассматривать отдельно: как транспортные методы, как методы машинного обучения, как стохастические блочные схемы или как распределенную оптимизацию. В этой работе они рассматриваются как разные способы устранения вычислительных ограничений одного подхода: неблагоприятной геометрии направления, дорогой информации второго порядка, дорогого полного линейного оракула и ограниченной коммуникации между агентами.

Теоретическая часть работы включает три ключевых результата. Во-первых, для CFW в общей гладкой выпуклой постановке доказывается оценка сходимости по минимальному зазору Frank–Wolfe. Эта оценка показывает, что переход к сопряженным направлениям сохраняет базовый порядок сходимости FW, а отличие входит только через контролируемый параметр направления. Во-вторых, для SOFW формулируется стохастический блочно-координатный ЛМО-оракул и доказывается оценка ожидаемой субоптимальности, в том числе для батчевого выбора блоков. Тем самым показывается, что можно уменьшать стоимость итерации за счет случайного обновления части блоков без ухудшения базового порядка теоретической гарантии. В-третьих, для DBCFW выводится рекурсия спуска и оценка сходимости для распределенной блочно-координатной схемы с консенсусом и отслеживанием градиента. Эта оценка показывает, при каких условиях децентрализованный блочный вариант сохраняет порядок $O(1/t)$ для гладких выпуклых задач.

Практическая значимость состоит в том, что такая архитектура помогает выбирать модификацию под вычислительный узкий участок задачи. Если проблема заключается в зигзагообразном движении при активном ограничении, естественно использовать CFW или NFW. Если основной расход связан с полным линейным оракулом по большому числу блоков, подходит BCFW/SOFW. Если данные распределены между агентами и при этом множество имеет блочную структуру, естественным кандидатом становится DBCFW.

Кроме того, перенос CFW и NFW в машинное обучение показывает важный общий принцип. Методы можно адаптировать к общей гладкой задаче без явного построения гессиана: произведения гессиана на на-

правления приближаются конечными разностями градиентов. Это сохраняет идею сопряженности, но оставляет итерацию достаточно дешевой для практического обучения моделей.

1.3 Цель работы

Целью работы является систематизация, развитие и теоретическое обоснование модификаций алгоритма Frank–Wolfe для задач машинного обучения и смежных крупномасштабных задач выпуклой оптимизации, в которых вычислительная стоимость линейного оракула, выбора направления и коммуникаций существенно влияет на практическую эффективность метода. Особое внимание уделяется получению оценок сходимости для CFW, SOFW и DBCFW, поскольку именно эти результаты показывают, что ускорение отдельных компонентов итерации не разрушает базовые гарантии метода.

1.4 Задачи работы

1. Описать базовую постановку задачи равновесного распределения транспортных потоков и модификации FW, использующие предыдущие направления.
2. Сформулировать CFW и NFW для общей гладкой выпуклой задачи на компактном множестве и показать, как коэффициенты сопряженности можно вычислять без явного построения гессиана.
3. Доказать теоретическую оценку сходимости CFW по зазору Frank–Wolfe и показать, что порядок сходимости сохраняется относительно базового FW.
4. Описать SOFW как стохастический блочно-координатный вариант FW, обновляющий только часть блоков корреспонденций, и показать его связь с Block-Coordinate Frank–Wolfe.
5. Получить оценку ожидаемой сходимости SOFW, включая батчевый выбор блоков, и проанализировать компромисс между стоимостью

итерации, дисперсией направления и качеством теоретической гарантии.

6. Сформулировать Decentralized Block-Coordinate Frank–Wolfe как распределенное обобщение блочно-координатных FW-методов с консенсусом и отслеживанием градиента.
7. Доказать рекурсию спуска и оценку сходимости DBCFW, показать, что DBCFW содержит BCFW и децентрализованный FW как специальные случаи, и описать SOFW в том же блочно-координатном языке.

1.5 Структура работы

Глава 2 посвящена модификациям Frank–Wolfe в модели Бекмана. Глава 3 переносит CFW и NFW в постановку машинного обучения и содержит доказательство оценки сходимости CFW. Глава 4 рассматривает стохастический блочно-координатный подход для крупных транспортных графов и выводит оценку ожидаемой сходимости SOFW. Глава 5 формулирует децентрализованный блочно-координатный алгоритм, его связь с предыдущими методами и теоретическую оценку сходимости.

2 Модификации алгоритма Frank–Wolfe

В этой главе рассматриваются модификации алгоритма Frank–Wolfe для задачи поиска равновесного распределения транспортных потоков. В качестве базовой модели используется модель Бекмана. Основное внимание уделяется выбору направления шага: классический FW использует только решение текущей линейной подзадачи, тогда как CFW, BFW, FFW, NFW и WFFW строят новое направление с учетом предыдущих направлений. Такая идея позволяет уменьшить эффект зигзагообразного движения и ускорить уменьшение относительного зазора.

Рассматриваемая линия методов включает CFW и BFW [5], FFW [6], а также последующие расширения [8]:

1. Conjugate Frank–Wolfe (CFW);
2. Bi-conjugate Frank–Wolfe (BFW);
3. Fukushima Frank–Wolfe (FFW);
4. N-conjugate Frank–Wolfe (NFW);
5. Weighted Fukushima Frank–Wolfe (WFFW).

Алгоритмы NFW и WFFW являются развитием BFW и FFW соответственно. Если BFW использует два предыдущих направления, то NFW использует N предыдущих направлений. Если FFW использует среднее по нескольким предыдущим направлениям, то WFFW заменяет его экспоненциальным сглаживанием.

2.1 Модель Бекмана

Пусть задан ориентированный дорожный граф с множеством ребер $\mathcal{E}$. Вектор $f = \{f_e\}_{e \in \mathcal{E}}$ задает потоки по дорогам, а функция $\tau_e(f_e)$ задает время движения по ребру e при потоке f_e . В транспортной модели спрос задается не по ребрам, а по корреспонденциям источник–сток. Пусть OD обозначает множество таких пар:

$$OD = \{(i, j) \mid i \in O, j \in D\}.$$

Для каждой пары $w = (i, j) \in OD$ задан спрос $d_w = d_{(i,j)}$, то есть объем потока, который должен быть перевезен из i в j . Пусть $\mathcal{P}_w = \mathcal{P}_{i,j}$ есть множество всех путей из i в j , а $\mathcal{P} = \bigcup_{w \in OD} \mathcal{P}_w$ – множество всех рассматриваемых путей. Переменная x_p обозначает поток, отправленный по пути p . Тогда для каждой OD-пары допустимые распределения потока по путям образуют симплекс

$$X^w = \left\{ x^w \left| \sum_{p \in \mathcal{P}_w} x_p = d_w, \ x_p \geq 0 \right. \right\},$$

а полное множество допустимых путевых потоков имеет декартову структуру

$$X = \prod_{w \in OD} X^w.$$

Связь потоков по путям и потоков по дорогам задается матрицей принадлежности ребер путям:

$$f = \Theta x, \quad \Theta = \{\delta_{e,p}\}_{e \in \mathcal{E}, p \in \mathcal{P}},$$

где $\delta_{e,p} = 1$, если путь p проходит по ребру e , и $\delta_{e,p} = 0$ иначе. Множество допустимых потоков по ребрам обозначим

$$\mathcal{F} = \{f = \Theta x \mid x \in X\}.$$

В модели Бекмана равновесное распределение потоков находится как решение задачи минимизации потенциальной функции

$$\Psi(f) = \sum_{e \in \mathcal{E}} \underbrace{\int_0^{f_e} \tau_e(z) dz}_{\sigma_e(f_e)} \longrightarrow \min_{f = \Theta x, x \in X}. \quad (2.1)$$

В качестве функций затрат используются классические BPR-функции:

$$\tau_e(f_e) = \bar{t}_e \left(1 + \rho \left(\frac{f_e}{\bar{f}_e} \right)^{1/\mu} \right), \quad \tau(f) = \{\tau_e(f_e)\}_{e \in \mathcal{E}}. \quad (2.2)$$

Параметры $\rho, \mu, \bar{t}_e, \bar{f}_e$ задаются дорожной сетью. Градиент функционала Ψ имеет простой вид:

$$\nabla \Psi(f) = \tau(f).$$

2.2 Оптимальные условия модели Бекмана

Для задачи

$$\min_{f=\Theta x, x \in X} \Psi(f)$$

условие оптимальности можно записать как вариационное неравенство

$$\langle \nabla \Psi(f^*), f - f^* \rangle \geq 0, \quad f = \Theta x, x \in X.$$

Так как $\nabla \Psi(f) = \tau(f)$, получаем

$$\langle \tau(f^*), \Theta x - \Theta x^* \rangle \geq 0.$$

Пусть для некоторой ОД-пары w существует используемый путь p и другой путь q с меньшим временем движения:

$$\sum_{e \in q} \tau_e(f_e^*) < \sum_{e \in p} \tau_e(f_e^*).$$

Тогда можно перенести малую величину потока с p на q и получить допустимое направление, для которого скалярное произведение с $\tau(f^*)$ отрицательно. Это противоречит вариационному неравенству. Следовательно, в оптимуме все используемые пути являются кратчайшими при равновесных временах. Так модель Бекмана связывает выпуклую оптимизацию и принцип Вардропа.

2.3 Линейный оракул как all-or-nothing assignment

Главная причина, по которой метод Frank–Wolfe удобен для модели Бекмана, состоит в структуре линейного оракула. На итерации с текущим потоком f^k нужно решить

$$s_k^{FW} = \arg \min_{y=\Theta x, x \in X} \langle \tau(f^k), y \rangle = \arg \min_{x \in X} \sum_{w \in OD} \sum_{p \in \mathcal{P}_w} x_p c_p^k, \quad (2.3)$$

где стоимость пути p при текущих временах равна

$$c_p^k = \sum_{e \in \mathcal{E}} \delta_{e,p} \tau_e(f_e^k).$$

Так как $X = \prod_{w \in OD} X^w$, задача (2.3) распадается по OD-парам:

$$\min_{x^w \in X^w} \sum_{p \in \mathcal{P}_w} x_p c_p^k, \quad w = (i, j) \in OD.$$

Это линейная задача на симплексе. Поэтому оптимум достигается в вершине: весь спрос d_w назначается на один из путей минимальной стоимости. Иными словами,

$$p_w^k \in \arg \min_{p \in \mathcal{P}_w} c_p^k = \arg \min_{p \in \mathcal{P}_w} \sum_{e \in \mathcal{E}} \delta_{e,p} \tau_e(f_e^k),$$

а решение линейного оракула имеет вид

$$\begin{aligned} x_{p_w^k}^{k,FW} &= d_w, \\ x_p^{k,FW} &= 0, \quad p \in \mathcal{P}_w \setminus \{p_w^k\}, \quad w \in OD, \\ s_{k,e}^{FW} &= \sum_{w \in OD} d_w \delta_{e,p_w^k}, \quad e \in \mathcal{E}. \end{aligned}$$

Таким образом, вызов LMO буквально является набором задач поиска кратчайших путей: для каждой OD-пары $w = (i, j)$ нужно найти кратчайший путь из i в j в графе с длинами ребер $\tau_e(f_e^k)$. В реализации не требуется явно перечислять все пути из $\mathcal{P}_w$; достаточно запустить алгоритм кратчайших путей по текущим весам ребер. Если кратчайших путей несколько, можно выбрать любой из них или распределить спрос между ними без изменения значения линейной подзадачи.

2.4 Классический алгоритм Frank–Wolfe

Алгоритм Frank–Wolfe на каждой итерации линеаризует целевой функционал в текущей точке f^k :

$$\Psi_k(y) = \Psi(f^k) + \langle \nabla \Psi(f^k), y - f^k \rangle.$$

После этого решается линейная задача

$$s_k^{FW} = \arg \min_{y=\Theta x, x \in X} \langle \nabla \Psi(f^k), y \rangle = \arg \min_{y=\Theta x, x \in X} \langle \tau(f^k), y \rangle. \quad (2.4)$$

Как показано в разделе 2.3, в модели Бекмана эта задача решается как all-or-nothing assignment по текущим кратчайшим путям. Направление шага определяется как

$$d_k^{FW} = s_k^{FW} - f^k,$$

а длина шага выбирается одномерной минимизацией:

$$\gamma_k = \arg \min_{\gamma \in [0,1]} \Psi(f^k + \gamma d_k^{FW}), \quad f^{k+1} = f^k + \gamma_k d_k^{FW}.$$

Алгоритм 1 Frank–Wolfe для модели Бекмана

Вход: начальная точка $f^0 \in \mathcal{F}$, максимальное число итераций

$k \leftarrow 0$

повторять

$s_k^{FW} \leftarrow \arg \min_{s \in \mathcal{F}} \langle \nabla \Psi(f^k), s \rangle$

$d_k \leftarrow s_k^{FW} - f^k$

$\gamma_k \leftarrow \arg \min_{\gamma \in [0,1]} \Psi(f^k + \gamma d_k)$

$f^{k+1} \leftarrow f^k + \gamma_k d_k$

$k \leftarrow k + 1$

пока не выполнено достигнут критерий остановки

Выход: приближение равновесного распределения потоков

Для оценки качества решения используется зазор Frank–Wolfe

$$g_k = \max_{s=\Theta x, x \in X} \langle \nabla \Psi(f^k), f^k - s \rangle.$$

При липшицевом градиенте известны стандартные оценки сходимости:

$$\min_{1 \leq m \leq k} g_m \leq \frac{\min\{2h_0, L \operatorname{diam}(C)^2\}}{\sqrt{k+1}}, \quad \Psi(f^k) - \Psi(f^*) \leq \frac{2L \operatorname{diam}(C)^2}{k+1}.$$

Несмотря на эти гарантии, на практике FW часто быстро снижает функционал только на первых итерациях, а затем начинает двигаться зигзагообразно и замедляется.

2.5 Conjugate Frank–Wolfe

Идея CFW состоит в построении нового направления, сопряженного к предыдущему направлению относительно гессиана целевой функции. Пусть $d^{k-1} = s^{k-1} - f^{k-1}$. Алгоритм ищет новую точку направления в виде выпуклой комбинации

$$s_k = \alpha s_k^{FW} + (1 - \alpha)s_{k-1}.$$

Коэффициент α выбирается так, чтобы выполнялось условие сопряженности

$$(d^{k-1})^T \nabla^2 \Psi(f^k) d^k = 0, \quad d^k = s_k - f^k.$$

Для модели Бекмана гессиан диагонален, поэтому умножение на гессиан вычисляется дешево. Коэффициент α имеет вид

$$\alpha = \frac{(f^k - s_{k-1})^T \nabla^2 \Psi(f^k)(s_{k-1} - f^{k-1})}{(s_k^{FW} - s_{k-1})^T \nabla^2 \Psi(f^k)(s_{k-1} - f^{k-1})}. \quad (2.5)$$

Чтобы алгоритм не выродился в движение только по старому направлению, коэффициент проецируется на отрезок $[\alpha_0, 1]$, где $\alpha_0 \in (0, 1]$.

Алгоритм 2 Conjugate Frank–Wolfe

Вход: $f^0 \in \mathcal{F}$, параметр $\alpha_0 \in (0, 1]$

выполнить один шаг FW и получить f^1, s_0

$k \leftarrow 1$

повторять

$s_k^{FW} \leftarrow \arg \min_{s \in \mathcal{F}} \langle \nabla \Psi(f^k), s \rangle$

вычислить α по формуле (2.5)

$\alpha \leftarrow \min\{1, \max\{\alpha_0, \alpha\}\}$

$s_k \leftarrow \alpha s_k^{FW} + (1 - \alpha)s_{k-1}$

$d_k \leftarrow s_k - f^k$

$\gamma_k \leftarrow \arg \min_{\gamma \in [0, 1]} \Psi(f^k + \gamma d_k)$

$f^{k+1} \leftarrow f^k + \gamma_k d_k$

$k \leftarrow k + 1$

пока не выполнено достигнут критерий остановки

2.6 Fukushima Frank–Wolfe и WFFW

Алгоритм Fukushima Frank–Wolfe использует усреднение предыдущих направлений. В общем виде новая точка направления может быть записана как

$$s_k = \alpha_0 s_k^{FW} + \sum_{j=1}^N \alpha_j s_{k-j}, \quad \sum_{j=0}^N \alpha_j = 1, \quad \alpha_j \geq 0. \quad (2.6)$$

Классический FFW выбирает равномерные веса по нескольким предыдущим направлениям. Предложенная модификация Weighted Fukushima Frank–Wolfe заменяет равномерное среднее экспоненциальным сглаживанием. Пусть $\eta \in (0, 1)$ задает скорость затухания. Тогда старые направления получают меньший вес, а более свежие направления сильнее влияют на шаг:

$$s_k = \alpha_0 s_k^{FW} + (1 - \alpha_0) \sum_{j=1}^N w_j s_{k-j}, \quad w_j = \frac{(1 - \eta)\eta^{j-1}}{\sum_{\ell=1}^N (1 - \eta)\eta^{\ell-1}}.$$

Такой выбор сохраняет выпуклость комбинации и одновременно делает алгоритм менее чувствительным к слишком старым направлениям.

2.7 N-conjugate Frank–Wolfe

Bi-conjugate Frank–Wolfe использует две предыдущие точки направления. N-conjugate Frank–Wolfe обобщает эту идею на N предыдущих направлений. Ищется новая точка

$$s_k = \alpha_0 s_k^{FW} + \sum_{j=1}^N \alpha_j s_{k-j}, \quad \alpha_j \geq 0, \quad \sum_{j=0}^N \alpha_j = 1,$$

такая, что новое направление

$$d^k = s_k - f^k$$

сопряжено к N предыдущим направлениям:

$$(d^k)^T \nabla^2 \Psi(f^k) d^{k-j} = 0, \quad j = 1, \dots, N. \quad (2.7)$$

В NFW используется предположение, что предыдущие направления уже попарно сопряжены относительно текущего гессиана:

$$(d^{k-m})^T \nabla^2 \Psi(f^k) d^{k-n} = 0, \quad m \neq n, \quad m, n = 1, \dots, N.$$

Тогда коэффициенты могут быть вычислены независимо:

$$\alpha_j = -\alpha_0 \frac{(d_k^{FW})^T \nabla^2 \Psi(f^k) d^{k-j}}{(d^{k-j})^T \nabla^2 \Psi(f^k) d^{k-j}}, \quad j = 1, \dots, N, \quad (2.8)$$

а α_0 выбирается так, чтобы сумма весов была равна единице и все веса оставались неотрицательными.

Алгоритм 3 N-conjugate Frank–Wolfe

Вход: $f^0 \in \mathcal{F}$, число сопряженных направлений N

выполнить первые N шагов FW или CFW для инициализации

повторять

$$s_k^{FW} \leftarrow \arg \min_{s \in \mathcal{F}} \langle \nabla \Psi(f^k), s \rangle$$

вычислить коэффициенты $\alpha_0, \dots, \alpha_N$ из условий (2.7)

$$s_k \leftarrow \alpha_0 s_k^{FW} + \sum_{j=1}^N \alpha_j s_{k-j}$$

$$d_k \leftarrow s_k - f^k$$

$$\gamma_k \leftarrow \arg \min_{\gamma \in [0,1]} \Psi(f^k + \gamma d_k)$$

$$f^{k+1} \leftarrow f^k + \gamma_k d_k$$

пока не выполнено достигнут критерий остановки

2.8 Экспериментальные результаты

Эксперименты проводились на открытых транспортных датасетах из репозитория TransportationNetworks [9]. В качестве метрики качества использовался относительный зазор. Сравнивались FW, CFW, BFW, FFW, WFFW и NFW при различных значениях N .

2.9 Более подробная запись CFW и BFW

В транспортной постановке CFW рассматривается как первый способ заменить направление классического FW направлением, которое использует информацию о предыдущем шаге. Если обозначить обычную FW-точку

через $y^k = s_k^{FW}$, то на итерации k строится точка

$$\bar{y}^k = \alpha y^k + (1 - \alpha)y^{k-1}.$$

Далее направление определяется как

$$d^k = \bar{y}^k - f^k.$$

Коэффициент α получается из условия сопряженности

$$(d^k)^T \nabla^2 \Psi(f^k) d^{k-1} = 0.$$

Подставляя $d^k = \alpha(y^k - f^k) + (1 - \alpha)(y^{k-1} - f^k)$, получаем

$$\alpha = \frac{(f^k - y^{k-1})^T \nabla^2 \Psi(f^k) d^{k-1}}{(y^k - y^{k-1})^T \nabla^2 \Psi(f^k) d^{k-1}}.$$

После вычисления коэффициент ограничивается снизу параметром $\alpha_{\min}$:

$$\alpha \leftarrow \max\{\alpha_{\min}, \min\{1, \alpha\}\}.$$

Это техническое ограничение важно: оно не позволяет методу полностью игнорировать новое решение линейного оракула и тем самым сохраняет связь с классическим FW.

Bi-conjugate Frank–Wolfe использует уже две предыдущие точки. Пусть нужно построить

$$\bar{y}^k = \alpha_0 y^k + \alpha_1 y^{k-1} + \alpha_2 y^{k-2}, \quad \alpha_0 + \alpha_1 + \alpha_2 = 1.$$

Условия сопряженности имеют вид

$$(d^k)^T \nabla^2 \Psi(f^k) d^{k-1} = 0, \quad (d^k)^T \nabla^2 \Psi(f^k) d^{k-2} = 0.$$

Эта идея используется как промежуточный шаг к NFW: BFW показывает, что память о двух направлениях может быть лучше памяти об одном направлении, но жестко фиксированное число направлений не позволяет проверить, где находится практически оптимальный уровень памяти алго-

ритма.

Алгоритм 4 Bi-conjugate Frank–Wolfe

Вход: допустимая точка f^0 , нижняя граница $\alpha_{\min}$, число итераций

выполнить две начальные итерации FW/CFW и сохранить y^0, y^1

для $k = 2, 3, \dots$ **выполнить**

$y^k \leftarrow \arg \min_{y \in \mathcal{F}} \langle \nabla \Psi(f^k), y \rangle$

найти $\alpha_0, \alpha_1, \alpha_2$ из условий сопряженности к d^{k-1} и d^{k-2}

спроецировать коэффициенты на допустимый симплекс с учетом $\alpha_0 \geq \alpha_{\min}$

$\bar{y}^k \leftarrow \alpha_0 y^k + \alpha_1 y^{k-1} + \alpha_2 y^{k-2}$

$d^k \leftarrow \bar{y}^k - f^k$

$\gamma_k \leftarrow \arg \min_{\gamma \in [0,1]} \Psi(f^k + \gamma d^k)$

$f^{k+1} \leftarrow f^k + \gamma_k d^k$

конец цикла

2.10 Вывод коэффициентов NFW

Пусть на итерации k доступны N предыдущих направлений

$$d^{k-1}, d^{k-2}, \dots, d^{k-N}.$$

NFW ищет новую точку в виде

$$\bar{y}^k = \alpha_0 y^k + \sum_{i=1}^N \alpha_i y^{k-i}, \quad \sum_{i=0}^N \alpha_i = 1.$$

Тогда

$$d^k = \bar{y}^k - f^k = \alpha_0 (y^k - f^k) + \sum_{i=1}^N \alpha_i (y^{k-i} - f^k).$$

Для каждого $j = 1, \dots, N$ требуется

$$(d^k)^T H_k d^{k-j} = 0, \quad H_k = \nabla^2 \Psi(f^k).$$

Если предыдущие направления считаются попарно сопряженными относительно текущего H_k , то есть

$$(d^{k-i})^T H_k d^{k-j} = 0, \quad i \neq j,$$

коэффициенты можно вычислять последовательно. Это предположение техническое, но оно согласуется с мотивацией метода: если на предыдущих итерациях направления были сопряжены относительно близких гессианов, а H_k меняется плавно, то старые направления остаются почти сопряженными и относительно нового гессиана.

Выведем формулы подробнее. Из обновления

$$f^k = (1 - \gamma_{k-1})f^{k-1} + \gamma_{k-1}y^{k-1}, \quad d^{k-1} = y^{k-1} - f^{k-1},$$

получаем

$$y^{k-1} - f^k = (1 - \gamma_{k-1})d^{k-1}.$$

Обозначим

$$\bar{d}^{k-i} = (1 - \gamma_{k-i})d^{k-i}.$$

Для $m \geq 1$ используем телескопическую сумму:

$$y^{k-m} - f^k = \sum_{i=0}^{m-2} (y^{k-m+i} - y^{k-m+i+1}) + y^{k-1} - f^k.$$

Разность соседних точек линейного оракула переписывается через прошлые направления:

$$y^{k-m+i} - y^{k-m+i+1} = \bar{d}^{k-m+i} - d^{k-m+i+1}.$$

Следовательно,

$$d^k = \alpha_0 d_k^{FW} + \sum_{m=1}^N \alpha_m \left(\sum_{i=0}^{m-1} \bar{d}^{k-m+i} - \sum_{i=0}^{m-2} d^{k-m+i+1} \right). \quad (2.9)$$

Теперь подставим (2.9) в условия сопряженности

$$(d^{k-m})^T H_k d^k = 0, \quad m = 1, \dots, N.$$

Введем обозначения

$$A_{k-m} = (d^{k-m})^T H_k d_k^{FW}, \quad B_{k-m} = (d^{k-m})^T H_k d^{k-m}.$$

После зануления смешанных слагаемых по предположению о попарной сопряженности остается

$$\alpha_0 A_{k-m} + (1 - \gamma_{k-m}) B_{k-m} \alpha_m - \gamma_{k-m} B_{k-m} \sum_{i=m+1}^N \alpha_i = 0. \quad (2.10)$$

Положим $\alpha_m = \beta_m \alpha_0$. Тогда коэффициенты β_m считаются с конца к началу:

$$\beta_N = -\frac{A_{k-N}}{B_{k-N}(1 - \gamma_{k-N})}, \quad (2.11)$$

$$\beta_m = -\frac{A_{k-m}}{B_{k-m}(1 - \gamma_{k-m})} + \frac{\gamma_{k-m}}{1 - \gamma_{k-m}} \sum_{i=m+1}^N \beta_i, \quad m = N - 1, \dots, 1. \quad (2.12)$$

Нормировка выпуклой комбинации дает

$$\alpha_0 = \frac{1}{1 + \sum_{i=1}^N \beta_i}, \quad \alpha_m = \beta_m \alpha_0. \quad (2.13)$$

Если найденные коэффициенты нарушают неотрицательность, алгоритм возвращается к более простой комбинации: уменьшает число используемых направлений или фактически делает шаг CFW/FW. Именно поэтому NFW не является отдельным дорогим методом: он является надстройкой над тем же линейным оракулом, а дополнительные вычисления состоят из нескольких скалярных произведений с диагональным гессианом.

Отдельная эвристика связана с шагом $\gamma_k = 1$. Если такой шаг выполняется, новая точка полностью задается текущим направлением, а накопленная информация о прошлых направлениях теряет смысл. Поэтому в реализации метода используется параметр $\gamma_{\max}$: если $\gamma_k \geq \gamma_{\max}$, счетчик доступных сопряженных направлений сбрасывается, и накопление памяти для NFW начинается заново.

2.11 Fukushima Frank–Wolfe как сглаживание направлений

В алгоритме Fukushima Frank–Wolfe новое направление не выводится из условий сопряженности. Оно строится как выпуклое среднее по текущему FW-направлению и нескольким предыдущим точкам линейного ораку-

ла. Если хранится N прошлых точек, то

$$\bar{y}^k = \lambda y^k + (1 - \lambda) \frac{1}{N} \sum_{i=1}^N y^{k-i}.$$

После этого

$$d^k = \bar{y}^k - f^k.$$

Такой подход проще CFW/NFW: он не использует гессиан и не пытается сделать направления сопряженными. Его смысл состоит в подавлении резких колебаний, возникающих из-за того, что линейный оракул часто выбирает сильно различающиеся кратчайшие пути на соседних итерациях.

Weighted FFW меняет только способ усреднения:

$$\bar{y}^k = \lambda y^k + (1 - \lambda) \sum_{i=1}^N w_i y^{k-i}, \quad \sum_{i=1}^N w_i = 1.$$

Веса выбираются геометрическими:

$$w_i = \frac{q^{i-1}}{\sum_{\ell=1}^N q^{\ell-1}}, \quad q \in (0, 1).$$

При малом q метод почти полностью ориентируется на последнее сохраненное направление. При q около единицы WFFW становится близким к обычному FFW. Такой параметр позволяет управлять тем, насколько быстро алгоритм забывает устаревшую информацию.

Алгоритм 5 Weighted Fukushima Frank–Wolfe

Вход: $f^0 \in \mathcal{F}$, глубина памяти N , параметры $\lambda, q \in (0, 1)$

для $k = 0, 1, 2, \dots$ **выполнить**

$y^k \leftarrow \arg \min_{y \in \mathcal{F}} \langle \nabla \Psi(f^k), y \rangle$

выбрать доступные прошлые точки $y^{k-1}, \dots, y^{k-N}$

$w_i \leftarrow q^{i-1} / \sum_{\ell=1}^N q^{\ell-1}$

$\bar{y}^k \leftarrow \lambda y^k + (1 - \lambda) \sum_{i=1}^N w_i y^{k-i}$

$d^k \leftarrow \bar{y}^k - f^k$

$\gamma_k \leftarrow \arg \min_{\gamma \in [0, 1]} \Psi(f^k + \gamma d^k)$

$f^{k+1} \leftarrow f^k + \gamma_k d^k$

конец цикла

2.12 Относительный зазор и критерий остановки

В экспериментах основной метрикой является относительный зазор, используемый в работах по ускоренным FW-методам для traffic assignment [5, 7]. В отличие от простого значения целевой функции, эта величина сравнивает текущее верхнее приближение оптимального значения с накопленной нижней оценкой минимума. Поэтому она показывает не только факт убывания Ψ , но и то, насколько близко текущее решение к оптимальному значению в относительном масштабе.

Пусть f^k – текущий поток, s_k^{FW} – решение линейного оракула, а f^{k+1} – точка после линейного поиска. Верхняя оценка оптимального значения берется как значение целевой функции в новой допустимой точке:

$$\text{UBD}_k = \Psi(f^{k+1}). \quad (2.14)$$

Так как $f^{k+1} \in \mathcal{F}$, всегда выполнено $\Psi(f^*) \leq \text{UBD}_k$.

Нижняя оценка строится из линеаризации выпуклой функции Ψ в точке f^k :

$$\text{LB}_k = \min_{y=\Theta x, x \in X} \{ \Psi(f^k) + \langle \nabla \Psi(f^k), y - f^k \rangle \}. \quad (2.15)$$

По выпуклости для любой допустимой точки y справедливо

$$\Psi(y) \geq \Psi(f^k) + \langle \nabla \Psi(f^k), y - f^k \rangle.$$

В частности, для оптимального потока f^* получаем

$$\Psi(f^*) \geq \Psi(f^k) + \langle \nabla \Psi(f^k), f^* - f^k \rangle \geq \text{LB}_k.$$

Следовательно, LB_k действительно является нижней оценкой оптимального значения.

Эту нижнюю оценку можно выразить через зазор Frank–Wolfe. Обозначим

$$g_k = \langle \nabla \Psi(f^k), f^k - s_k^{FW} \rangle = \langle \tau(f^k), f^k - s_k^{FW} \rangle. \quad (2.16)$$

Так как s_k^{FW} минимизирует линейную форму $\langle \nabla \Psi(f^k), y \rangle$ на допустимом

множестве, из (2.15) следует

$$\text{LB}_k = \Psi(f^k) + \langle \nabla \Psi(f^k), s_k^{FW} - f^k \rangle = \Psi(f^k) - g_k. \quad (2.17)$$

В транспортной постановке g_k имеет понятную интерпретацию: он измеряет, насколько можно уменьшить линейную аппроксимацию целевой функции, если переназначить весь спрос на текущие кратчайшие пути.

Поскольку отдельные нижние оценки могут колебаться от итерации к итерации, в относительном зазоре используется лучшая накопленная нижняя оценка:

$$\text{BLB}_k = \max_{1 \leq m \leq k} \text{LB}_m. \quad (2.18)$$

Из $\text{LB}_m \leq \Psi(f^*)$ для всех m следует $\text{BLB}_k \leq \Psi(f^*)$. Итоговая метрика задается формулой

$$\text{RG}_k = \frac{\text{UBD}_k - \text{BLB}_k}{\text{BLB}_k}. \quad (2.19)$$

Если $\text{BLB}_k > 0$, что выполняется для стандартных транспортных задач с положительными временами движения, то

$$\frac{\Psi(f^{k+1}) - \Psi(f^*)}{\Psi(f^*)} \leq \frac{\Psi(f^{k+1}) - \text{BLB}_k}{\text{BLB}_k} = \text{RG}_k. \quad (2.20)$$

Таким образом, RG_k является вычислимой верхней оценкой относительной ошибки по целевой функции.

Также эта величина не хуже грубой относительной оценки, построенной напрямую по FW-зазору. Действительно, при точном линейном поиске $\Psi(f^{k+1}) \leq \Psi(f^k)$, а $\text{BLB}_k \geq \text{LB}_k$. Поэтому

$$\text{RG}_k = \frac{\Psi(f^{k+1}) - \text{BLB}_k}{\text{BLB}_k} \leq \frac{\Psi(f^k) - \text{LB}_k}{\text{BLB}_k} = \frac{g_k}{\text{BLB}_k}. \quad (2.21)$$

Именно поэтому в сравнении модификаций FW используется RG_k : он сохраняет связь с зазором Frank–Wolfe, но дополнительно учитывает лучшую накопленную нижнюю оценку оптимального значения. Алгоритм считается более быстрым, если достигает одного и того же уровня RG_k за меньшее число итераций или за меньшее время.

Для всех модификаций схема эксперимента одинакова:

1. построить начальный допустимый поток назначением спроса на кратчайшие пути при свободных временах;
2. на каждой итерации пересчитать времена $\tau(f^k)$;
3. решить линейный оракул как набор задач кратчайших путей;
4. построить направление конкретной модификации;
5. выполнить точный линейный поиск по $\gamma \in [0, 1]$;
6. вычислить LB_k , обновить BLB_k и сохранить RG_k вместе со значением целевой функции.

Такая унификация важна: различия в результатах объясняются именно выбором направления, а не разными правилами шага или разными линейными оракулами.

2.13 Серии экспериментов

Эксперименты проводились на транспортных сетях Anaheim, SiouxFalls, Berlin-Tiergarten, Terrassa-Asymmetric, Chicago-Sketch, Berlin-Mitte-Center, Berlin-Friedrichshain, Barcelona и Berlin-Mitte-Prenzlauerberg-Friedrichshain-Center. Во всех сериях сравнивается зависимость относительного зазора от времени работы. Это важно: методы используют один и тот же линейный оракул кратчайших путей и один и тот же линейный поиск, поэтому различия на графиках отражают именно выбор направления.

Первая серия сравнивает FW, CFW, BFW, WFFW и 3-conjugate FW. Главный вопрос здесь состоит в том, дает ли третье сопряженное направление выигрыш по сравнению с уже известным BFW. На рис. 1–3 видно, что на многих сетях 3-conjugate FW уменьшает относительный зазор быстрее BFW, CFW и классического FW. Это означает, что эффект памяти не исчерпывается двумя направлениями.

Сходимость относительного зазора на разных городах




Рис. 1: Сходимость относительного зазора для NFW, CFW, BFW, WFFW и FW на сетях Chicago-Sketch, Berlin-Friedrichshain и Anaheim.

Сходимость относительного зазора на разных городах




Рис. 2: Сходимость относительного зазора для NFW, CFW, BFW, WFFW и FW на сетях Berlin-Mitte-Center, Berlin-Tiergarten и Barcelona.

Сходимость относительного зазора на разных городах




Рис. 3: Сходимость относительного зазора для NFW, CFW, BFW, WFFW и FW на сетях Berlin-Mitte-Prenzlauerberg-Friedrichshain-Center, SiouxFalls и Terrassa-Asymmetric.

Вторая серия посвящена сравнению Fukushima Frank–Wolfe и Weighted Fukushima Frank–Wolfe. Здесь проверяется, насколько простое сглаживание направлений может конкурировать с сопряженными методами. Равномерное усреднение FFW стабилизирует траекторию, но может запаздывать, поскольку старые направления удерживают алгоритм в области, которая уже не соответствует текущим кратчайшим путям. WFFW исправляет эту особенность с помощью геометрического забывания. Результаты приведены на рис. 4–5.

Сходимость относительного зазора на разных городах




Рис. 4: Сравнение FFW, WFFW и CFW по относительному зазору на сетях Anaheim и Berlin-Friedrichshain.

Сходимость относительного зазора на разных городах




Рис. 5: Сравнение FFW, WFFW и CFW по относительному зазору на сетях SiouxFalls и Terrassa-Asymmetric.

Третья серия меняет глубину памяти NFW. Сравняются варианты с разным числом предыдущих направлений. При $N = 2$ метод совпадает по смыслу с BFW, а при больших N начинает использовать более длинную историю направлений. На рис. 6–7 видно, что увеличение глубины памяти может давать дополнительное ускорение, но эффект зависит от сети: слишком старые направления иногда описывают уже неактуальную локальную геометрию задачи.

Сходимость относительного зазора на разных городах




Рис. 6: Сравнение NFW с разной глубиной памяти и BFW на сетях Anaheim и Berlin-Friedrichshain.

Сходимость относительного зазора на разных городах




Рис. 7: Сравнение NFW с разной глубиной памяти и BFW на сетях SiouxFalls и Terrassa-Asymmetric.

Четвертая серия проверяет параметры WFFW. Если вес текущего FW-направления слишком мал, метод двигается инерционно и может медленно реагировать на изменение кратчайших путей. Если этот вес слишком велик, метод почти совпадает с FW и теряет смысл сглаживания. На рис. 8 показано, что нужен баланс между новым FW-направлением и памятью о прошлых направлениях.




Рис. 8: Сходимость WFFW при различных параметрах геометрического сглаживания на сети Terrassa-Asymmetric.

Основные наблюдения следующие. Во-первых, методы, использующие предыдущие направления, в большинстве экспериментов сходятся быстрее классического FW. Во-вторых, использование более чем двух сопряженных направлений может давать дополнительное ускорение: вариант 3-conjugate FW часто оказывается одним из наиболее эффективных. В-третьих, WFFW обычно улучшает FFW и CFW за счет управляемого забывания старых направлений, хотя в ряде экспериментов уступает NFW. Таким образом, использование памяти о предыдущих направлениях является устойчивым способом ускорить FW без изменения линейного оракула.

2.14 Одномерный поиск для BPR-функций

Длина шага выбирается точной минимизацией

$$\gamma_k = \arg \min_{\gamma \in [0,1]} \Psi(f^k + \gamma d^k).$$

Для BPR-функции

$$\tau_e(f_e) = \bar{t}_e \left(1 + \rho \left(\frac{f_e}{\bar{f}_e} \right)^{1/\mu} \right)$$

производная одномерной функции равна

$$\frac{d}{d\gamma}\Psi(f^k + \gamma d^k) = \sum_{e \in \mathcal{E}} \tau_e(f_e^k + \gamma d_e^k) d_e^k.$$

Поэтому задача поиска γ сводится к нахождению нуля монотонной функции на $[0, 1]$. Если производная в нуле неотрицательна, оптимум находится при $\gamma = 0$. Если производная в единице неположительна, оптимум находится при $\gamma = 1$. В остальных случаях используется одномерный численный метод. Эта процедура одинакова для FW, CFW, BFW, FFW, WFFW и NFW; различается только направление d^k .

2.15 Итоги раздела

Рассмотренное направление развития движется от уже известных CFW/BFW к двум новым вариантам. NFW проверяет гипотезу, что память о большем числе прошлых направлений может усилить эффект сопряженности. WFFW проверяет другую гипотезу: может быть, часть ускорения объясняется не строгой сопряженностью, а более устойчивым сглаживанием направлений. Эксперименты показывают, что обе гипотезы полезны. Сопряженные методы дают наиболее сильный эффект, но взвешенное сглаживание также улучшает поведение классического FW.

2.16 Выводы по модификациям

Рассмотренные модификации сохраняют ключевое преимущество FW: каждая итерация требует решения той же линейной подзадачи, которая в транспортной модели сводится к поиску кратчайших путей. Дополнительные вычисления связаны с линейным поиском и комбинированием предыдущих направлений. Для модели Бекмана эти операции существенно дешевле линейного оракула, поскольку гессиан диагонален.

Эксперименты показывают, что направление шага является главным объектом для улучшения FW. Наиболее перспективным оказывается семейство сопряженных методов, особенно NFW при малых значениях N . Эта идея становится отправной точкой для следующей главы, где CFW и

NFW переносятся из транспортной постановки в задачи машинного обучения.

3 Сопряженный Frank–Wolfe в задачах машинного обучения

В этой главе модификации Frank–Wolfe с сопряженными направлениями переносятся из транспортной постановки в задачи машинного обучения. Рассматривается гладкая выпуклая задача

$$f(x) \rightarrow \min_{x \in \mathcal{X}}, \quad f : \mathbb{R}^d \rightarrow \mathbb{R}, \quad (3.1)$$

где $\mathcal{X}$ является компактным выпуклым множеством. Такая постановка возникает, например, когда регуляризованная задача машинного обучения переписывается как задача с ограничением на норму параметров.

Если исходная задача имеет вид

$$f(x) + \mu g(x) \rightarrow \min_x,$$

то при подходящем выборе радиуса она может быть рассмотрена как

$$f(x) \rightarrow \min_{g(x) \leq R}.$$

Для ограничений вида $\|x\|_1 \leq R$ линейный оракул Frank–Wolfe вычисляется проще, чем проекция на соответствующее множество. Поэтому FW и его модификации естественно применимы к обучению моделей с ограничениями на параметры.

3.1 Базовый FW для гладкой выпуклой задачи

На итерации k алгоритм решает линейную подзадачу

$$s_k^{FW} = \arg \min_{s \in \mathcal{X}} \langle \nabla f(x_k), s \rangle, \quad (3.2)$$

после чего делает шаг

$$d_k = s_k^{FW} - x_k, \quad x_{k+1} = x_k + \gamma_k d_k.$$

Длина шага может задаваться теоретической последовательностью

$$\gamma_k = \frac{2}{k+2},$$

или выбираться линейным поиском

$$\gamma_k = \arg \min_{\gamma \in [0,1]} f(x_k + \gamma d_k).$$

Алгоритм 6 Frank–Wolfe для задачи машинного обучения

Вход: компактное выпуклое множество $\mathcal{X}$, начальная точка $x_0 \in \mathcal{X}$

$k \leftarrow 0$

повторять

$$s_k^{FW} \leftarrow \arg \min_{s \in \mathcal{X}} \langle \nabla f(x_k), s \rangle$$

$$d_k \leftarrow s_k^{FW} - x_k$$

$$\gamma_k \leftarrow \arg \min_{\gamma \in [0,1]} f(x_k + \gamma d_k)$$

$$x_{k+1} \leftarrow x_k + \gamma_k d_k$$

$$k \leftarrow k + 1$$

пока не выполнено достигнут критерий остановки

3.2 CFW без явного вычисления гессиана

В транспортной задаче гессиан модели Бекмана диагонален, поэтому вычисление коэффициента CFW по формуле (2.5) дешево. В задачах машинного обучения явное вычисление гессиана может быть слишком дорогим. Поэтому используется приближение произведения гессиана на вектор через разность градиентов.

Пусть

$$d_{k-1} = s_{k-1} - x_{k-1}, \quad x_k = x_{k-1} + \gamma_{k-1} d_{k-1}.$$

Тогда

$$s_{k-1} - x_{k-1} = \frac{x_k - x_{k-1}}{\gamma_{k-1}},$$

и произведение гессиана на предыдущее направление приближенно выражается как

$$\nabla^2 f(x_k)(s_{k-1} - x_{k-1}) \approx \frac{\nabla f(x_k) - \nabla f(x_{k-1})}{\gamma_{k-1}}.$$

После сокращения γ_{k-1} получается формула

$$\alpha = \frac{(x_k - s_{k-1})^T (\nabla f(x_k) - \nabla f(x_{k-1}))}{(s_k^{FW} - s_{k-1})^T (\nabla f(x_k) - \nabla f(x_{k-1}))}. \quad (3.3)$$

Эта формула не требует явного построения гессиана и хорошо согласуется с реализацией в библиотеках автоматического дифференцирования.

Алгоритм 7 Conjugate Frank–Wolfe для общей гладкой задачи

Вход: $x_0 \in \mathcal{X}$, параметр $\alpha_0 \in (0, 1]$

выполнить один шаг FW и получить x_1, s_0

$k \leftarrow 1$

повторять

$s_k^{FW} \leftarrow \arg \min_{s \in \mathcal{X}} \langle \nabla f(x_k), s \rangle$

если $\langle \nabla f(x_k), s_k^{FW} \rangle = \langle \nabla f(x_k), x_k \rangle$, **то**

остановить алгоритм

конец условия

вычислить α по формуле (3.3)

$\alpha \leftarrow \min\{1, \max\{\alpha_0, \alpha\}\}$

$s_k \leftarrow \alpha s_k^{FW} + (1 - \alpha)s_{k-1}$

$d_k \leftarrow s_k - x_k$

$\gamma_k \leftarrow \arg \min_{\gamma \in [0, 1]} f(x_k + \gamma d_k)$

$x_{k+1} \leftarrow x_k + \gamma_k d_k$

$k \leftarrow k + 1$

пока не выполнено достигнут критерий остановки

3.3 Сходимость CFW

Для анализа используется стандартное предположение о выпуклости и гладкости.

Предположение 1. Множество $\mathcal{X} \subset \mathbb{R}^d$ выпукло и компактно. Функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ выпукла и непрерывно дифференцируема, а ее градиент липшицев на $\mathcal{X}$ с константой L :

$$0 \leq f(x') - f(x) - \langle \nabla f(x), x' - x \rangle \leq \frac{L}{2} \|x' - x\|_2^2, \quad x, x' \in \mathcal{X}.$$

Зазор Frank–Wolfe в точке x_k равен

$$g_k = \langle \nabla f(x_k), x_k - s_k^{FW} \rangle.$$

Обозначим

$$h_0 = f(x_0) - f(x^*), \quad R = \max_{x,y \in \mathcal{X}} \|x - y\|_2, \quad A = LR^2.$$

Лемма 2. Пусть d_k является направлением шага CFW, а длина шага выбирается точным линейным поиском на отрезке $[0, 1]$. Тогда

$$\langle \nabla f(x_{k+1}), d_k \rangle \leq 0.$$

Доказательство. Докажем утверждение по индукции. На нулевой итерации направление CFW совпадает с направлением FW:

$$d_0 = d_0^{FW} = s_0^{FW} - x_0.$$

Рассмотрим одномерную функцию

$$\varphi(\gamma) = f(x_0 + \gamma d_0)$$

на отрезке $[0, 1]$. Если x_0 не является решением, то по условию оптимальности для выпуклой задачи

$$\varphi'(0) = \langle \nabla f(x_0), s_0^{FW} - x_0 \rangle < 0.$$

Следовательно, точный линейный поиск выбирает $\gamma_0 > 0$. Так как φ выпукла, условие оптимальности одномерной задачи

$$\gamma_0 \in \arg \min_{\gamma \in [0,1]} \varphi(\gamma)$$

дает

$$\varphi'(\gamma_0) \leq 0, \quad \langle \nabla f(x_1), d_0 \rangle \leq 0.$$

Если же x_0 уже является решением, алгоритм останавливается, и утверждение не требуется.

Пусть теперь для предыдущей итерации выполнено

$$\langle \nabla f(x_k), d_{k-1} \rangle \leq 0.$$

Для направления CFW имеем

$$d_k = \alpha d_k^{FW} + (1 - \alpha)(s_{k-1} - x_k) = \alpha d_k^{FW} + (1 - \alpha)(1 - \gamma_{k-1})d_{k-1}.$$

Здесь $\alpha \in [\alpha_0, 1]$. По определению линейного оракула

$$\langle \nabla f(x_k), d_k^{FW} \rangle = \langle \nabla f(x_k), s_k^{FW} - x_k \rangle = -g_k \leq 0,$$

а второе слагаемое не положительно по предположению индукции. Значит,

$$\langle \nabla f(x_k), d_k \rangle \leq 0.$$

Если $g_k > 0$, то производная одномерной функции

$$\varphi_k(\gamma) = f(x_k + \gamma d_k)$$

в нуле отрицательна или равна нулю только в вырожденном случае. Точный линейный поиск по выпуклой функции снова дает

$$\langle \nabla f(x_{k+1}), d_k \rangle = \varphi'_k(\gamma_k) \leq 0.$$

Тем самым индукция завершена. □

Теорема 3. Пусть выполнено предположение 1. Тогда для CFW с параметром $\alpha_0 \in (0, 1]$ справедлива оценка

$$g_N^* = \min_{1 \leq k \leq N} g_k \leq \frac{\max\{2h_0, A\}}{\alpha_0 \sqrt{N+1}}.$$

Доказательство. Так как γ_k выбирается точным линейным поиском, для любого $\gamma \in [0, 1]$ выполнено

$$f(x_{k+1}) = \min_{\eta \in [0, 1]} f(x_k + \eta d_k) \leq f(x_k + \gamma d_k).$$

Используя L -гладкость, получаем

$$f(x_{k+1}) \leq f(x_k) + \gamma \langle \nabla f(x_k), d_k \rangle + \frac{\gamma^2 L}{2} \|d_k\|_2^2.$$

Далее

$$d_k = \alpha_k d_k^{FW} + (1 - \alpha_k)(1 - \gamma_{k-1})d_{k-1}.$$

По лемме 2, примененной к предыдущему шагу,

$$\langle \nabla f(x_k), d_{k-1} \rangle \leq 0.$$

Следовательно,

$$\langle \nabla f(x_k), d_k \rangle \leq \alpha_k \langle \nabla f(x_k), d_k^{FW} \rangle = -\alpha_k g_k \leq -\alpha_0 g_k.$$

Так как $x_k, s_k \in \mathcal{X}$ и R является диаметром $\mathcal{X}$,

$$\|d_k\|_2 \leq R, \quad A = LR^2.$$

Следовательно,

$$f(x_{k+1}) \leq f(x_k) + \min_{\gamma \in [0,1]} \left\{ -\alpha_0 \gamma g_k + \frac{\gamma^2 A}{2} \right\}.$$

Минимум в правой части достигается либо во внутренней точке, либо на правой границе отрезка. Поэтому

$$f(x_{k+1}) - f(x_k) \leq -\frac{\alpha_0 g_k}{2} \min \left\{ \frac{\alpha_0 g_k}{A}, 1 \right\}.$$

Суммируя по $k = 0, \dots, N$ и используя $f(x^*) \leq f(x_{N+1})$, получаем

$$h_0 \geq \sum_{k=0}^N \frac{\alpha_0 g_k}{2} \min \left\{ \frac{\alpha_0 g_k}{A}, 1 \right\}.$$

Так как $g_N^* = \min_{0 \leq k \leq N} g_k$, то

$$h_0 \geq (N+1) \frac{\alpha_0 g_N^*}{2} \min \left\{ \frac{\alpha_0 g_N^*}{A}, 1 \right\}.$$

Если $\alpha_0 g_N^* \leq A$, то

$$\alpha_0 g_N^* \leq \sqrt{\frac{2Ah_0}{N+1}} \leq \frac{\max\{2h_0, A\}}{\sqrt{N+1}}.$$

Если $\alpha_0 g_N^* > A$, то

$$\alpha_0 g_N^* \leq \frac{2h_0}{N+1} \leq \frac{\max\{2h_0, A\}}{\sqrt{N+1}}.$$

Объединяя два случая, получаем утверждение теоремы. $\square$

Оценка отличается от стандартной оценки FW только множителем $1/\alpha_0$. Это означает, что CFW сохраняет асимптотический порядок сходимости FW по зазору Frank–Wolfe, а практическое ускорение связано с более удачным выбором направления.

3.4 NFW в машинном обучении

Метод Bi-conjugate Frank–Wolfe обобщается до N-conjugate Frank–Wolfe, где новое направление строится с учетом нескольких предыдущих направлений. Предполагается, что предыдущие направления сопряжены между собой относительно нового гессиана:

$$d_{k-m}^T \nabla^2 f(x_k) d_{k-n} = 0, \quad m \neq n, \quad m, n \in \{1, \dots, N\}.$$

Новая точка направления записывается как выпуклая комбинация текущей точки линейного оракула и нескольких предыдущих точек:

$$s_k = \alpha_0 s_k^{FW} + \sum_{m=1}^N \alpha_m s_{k-m}.$$

Коэффициенты выбираются так, чтобы новое направление было сопряжено с предыдущими:

$$d_{k-m}^T \nabla^2 f(x_k) d_k = 0, \quad m = 1, \dots, N.$$

Обозначим $H^k = \nabla^2 f(x_k)$ и

$$A_{k-m} = d_{k-m}^T H^k d_k^{FW}, \quad B_{k-m} = d_{k-m}^T H^k d_{k-m}.$$

Если на текущей итерации используется N_{curr} предыдущих направлений,

то сначала вычисляется

$$\beta_{N_{\text{curr}}} = \frac{-A_{k-N_{\text{curr}}}}{B_{k-N_{\text{curr}}}(1 - \gamma_{k-N_{\text{curr}}})},$$

а затем последовательно для $m = N_{\text{curr}} - 1, \dots, 1$:

$$\beta_m = \frac{-A_{k-m}}{B_{k-m}(1 - \gamma_{k-m})} + \frac{\gamma_{k-m}}{1 - \gamma_{k-m}} \sum_{n=m+1}^{N_{\text{curr}}} \beta_n.$$

После этого

$$\alpha_m = \beta_m \alpha_0, \quad \alpha_0 = \frac{1}{1 + \sum_{i=1}^{N_{\text{curr}}} \beta_i}.$$

Для ML-задач точное вычисление H^k обычно слишком дорого. Поэтому, как и в CFW, используется приближение произведений гессиана через разности градиентов. Для предыдущего направления $d_{k-m} = s_{k-m} - x_{k-m}$ применяется оценка

$$\nabla f(s_{k-m}) - \nabla f(x_{k-m}) \approx \nabla^2 f(x_{k-m})(s_{k-m} - x_{k-m}).$$

Если гессиан за несколько итераций меняется умеренно, то отношение, входящее в формулы для коэффициентов, можно заменить выражением

$$\frac{A_{k-m}}{B_{k-m}} \approx \frac{(\nabla f(s_{k-m}) - \nabla f(x_{k-m}))^T d_k^{FW}}{(\nabla f(s_{k-m}) - \nabla f(x_{k-m}))^T (s_{k-m} - x_{k-m})}.$$

Так NFW сохраняет идею сопряжения с несколькими предыдущими направлениями, но не требует явного построения матрицы Гессе.

Алгоритм 8 N-conjugate Frank–Wolfe для задачи машинного обучения

Вход: начальная точка $x_0 \in \mathcal{X}$, глубина памяти N , параметр $\gamma_{\max} \in [0, 1]$

выполнить начальный FW-шаг и получить $x_1, s_0, N_{\text{curr}} \leftarrow 1$

повторять

$$s_k^{FW} \leftarrow \arg \min_{s \in \mathcal{X}} \langle \nabla f(x_k), s \rangle$$

вычислить коэффициенты $\alpha_0, \dots, \alpha_{N_{\text{curr}}}$

$$s_k \leftarrow \alpha_0 s_k^{FW} + \sum_{i=1}^{N_{\text{curr}}} \alpha_i s_{k-i}$$

$$d_k \leftarrow s_k - x_k$$

$$\gamma_k \leftarrow \arg \min_{\gamma \in [0, 1]} f(x_k + \gamma d_k)$$

$$x_{k+1} \leftarrow x_k + \gamma_k d_k$$

обновить N_{curr} : увеличить до N или сбросить до 1, если $\gamma_k > \gamma_{\max}$

пока не выполнено достигнут критерий остановки

3.5 Эксперименты на логистической регрессии

Эксперименты проводились на задачах бинарной классификации с логистической регрессией на наборах Mushrooms и MNIST. Рассматривалась задача

$$\|w\|_1 \leq R,$$

а также вариант с l_2 -регуляризацией:

$$f(w) = \text{logloss}(w) + \frac{\lambda}{2} \|w\|_2^2.$$

Интерес представляло сравнение случаев, когда решение безусловной задачи лежит внутри допустимого множества, около границы или далеко вне него.

Таблица 1: l_1 -нормы решений безусловной задачи для разных датасетов и регуляризаций.

Датасет	Без регуляризации	l_2 -регуляризация
Mushrooms	> 1000	30.5
MNIST	2.77	0.15

Частота настоящей сопряженности. Так как коэффициент α в CFW проецируется на $[\alpha_0, 1]$, важно понять, как часто алгоритм действительно строит сопряженное направление, а не просто использует усеченный коэффициент. Направление считается сопряженным в этом смысле, если неусе-

ченное значение α уже лежит в отрезке $[\alpha_0, 1]$. Для численной проверки использовалась нормированная величина сопряженности

$$\eta_k = \frac{|d_{k-1}^T \nabla^2 f(x_k) d_k|}{\sqrt{(d_{k-1}^T \nabla^2 f(x_k) d_{k-1}) (d_k^T \nabla^2 f(x_k) d_k)}}.$$

В точной арифметике для сопряженных направлений $\eta_k = 0$. Нормировка нужна, чтобы сравнивать значения на разных итерациях независимо от масштаба направлений. На рис. 9 показано значение η_k на первых ста итерациях CFW. В эксперименте примерно в 80% итераций новое направление действительно оказывается сопряженным с предыдущим; при этом на начальных итерациях такие направления встречаются реже.




Рис. 9: Частота настоящей сопряженности на первых 100 итерациях CFW.

Сравнение модификаций. Сравнивались FW с линейным поиском, FW с теоретическим шагом, CFW и NFW при $N = 2, 3, 4, 5$. Во всех экспериментах для CFW использовалось $\alpha_0 = 0.05$. Критерием качества был зазор Frank–Wolfe.

На рис. 10–17 приведены графики сходимости для четырех групп задач: Mushrooms без регуляризации, Mushrooms с l_2 -регуляризацией, MNIST без регуляризации и MNIST с l_2 -регуляризацией. Для каждого датасета рассматриваются разные радиусы ограничения $\|w\|_1 \leq R$.

LIBSVM.




Рис. 10: Mushrooms без l_2 -регуляризации: сходимость FW, CFW и NFW по FW-зазору для первых значений радиуса R .

LIBSVM.




Рис. 11: Mushrooms без l_2 -регуляризации: сходимость FW, CFW и NFW по FW-зазору для больших значений радиуса R .

LIBSVM. l_2 regularization




Рис. 12: Mushrooms с l_2 -регуляризацией: сходимость FW, CFW и NFW по FW-зазору для первых значений радиуса R .

LIBSVM. l_2 regularization




Рис. 13: Mushrooms с l_2 -регуляризацией: сходимость FW, CFW и NFW по FW-зазору для больших значений радиуса R .

MNIST.




Рис. 14: MNIST без l_2 -регуляризации: сходимость FW, CFW и NFW по FW-зазору для первых значений радиуса R .

MNIST.




Рис. 15: MNIST без l_2 -регуляризации: сходимость FW, CFW и NFW по FW-зазору для больших значений радиуса R .




Рис. 16: MNIST с l_2 -регуляризацией: сходимость FW, CFW и NFW по FW-зазору для первых значений радиуса R .




Рис. 17: MNIST с l_2 -регуляризацией: сходимость FW, CFW и NFW по FW-зазору для больших значений радиуса R .

Полученные результаты показывают:

1. CFW и NFW часто существенно превосходят классический FW, особенно когда решение безусловной задачи далеко от границы допустимого множества.
2. На Mushrooms преимущество сопряженных модификаций выражено сильнее, чем на MNIST.

3. При близости безусловного решения к границе $\mathcal{X}$ различия между FW с линейным поиском и CFW могут уменьшаться.
4. Когда безусловное решение далеко от границы допустимого множества, NFW с числом предыдущих направлений больше двух часто сходится быстрее FW и CFW.

Экспериментальные таблицы.

В таблицах ниже приведены численные результаты. В каждой строке фиксируется радиус R ограничения $\|w\|_1 \leq R$. Значения в таблице являются достигнутым FW-зазором к моменту остановки по времени; меньшее значение означает более качественное решение. Лучший результат в строке выделен зеленым.

Таблица 2: Mushrooms без l_2 -регуляризации. Критерий – FW-зазор.

R	FW ls	FW	CFW	NFW $N = 2$	NFW $N = 3$	NFW $N = 4$	NFW $N = 5$
5	$9.93 \cdot 10^{-4}$	$1.54 \cdot 10^{-4}$	$4.46 \cdot 10^{-5}$	$9.72 \cdot 10^{-10}$	$2.11 \cdot 10^{-9}$	$2.49 \cdot 10^{-9}$	$5.59 \cdot 10^{-9}$
30	$5.11 \cdot 10^{-3}$	$2.05 \cdot 10^{-3}$	$1.82 \cdot 10^{-3}$	$3.19 \cdot 10^{-4}$	$1.40 \cdot 10^{-4}$	$7.52 \cdot 10^{-5}$	$2.72 \cdot 10^{-4}$
60	$3.82 \cdot 10^{-3}$	$2.11 \cdot 10^{-3}$	$1.12 \cdot 10^{-3}$	$1.14 \cdot 10^{-3}$	$3.38 \cdot 10^{-4}$	$6.59 \cdot 10^{-4}$	$3.83 \cdot 10^{-4}$
150	$9.20 \cdot 10^{-4}$	$3.06 \cdot 10^{-2}$	$1.34 \cdot 10^{-4}$	$4.06 \cdot 10^{-4}$	$1.40 \cdot 10^{-4}$	$9.27 \cdot 10^{-5}$	$1.47 \cdot 10^{-4}$

Таблица 3: Mushrooms с l_2 -регуляризацией. Критерий – FW-зазор.

R	FW ls	FW	CFW	NFW $N = 2$	NFW $N = 3$	NFW $N = 4$	NFW $N = 5$
5	$1.41 \cdot 10^{-3}$	$3.71 \cdot 10^{-4}$	$1.56 \cdot 10^{-5}$	$4.42 \cdot 10^{-9}$	$3.30 \cdot 10^{-9}$	$1.86 \cdot 10^{-8}$	$4.86 \cdot 10^{-6}$
30	$8.96 \cdot 10^{-3}$	$1.33 \cdot 10^{-2}$	$6.21 \cdot 10^{-3}$	$7.13 \cdot 10^{-3}$	$5.61 \cdot 10^{-3}$	$8.16 \cdot 10^{-3}$	$5.48 \cdot 10^{-3}$
60	$7.11 \cdot 10^{-3}$	$6.69 \cdot 10^{-2}$	$2.40 \cdot 10^{-3}$	$2.12 \cdot 10^{-3}$	$1.57 \cdot 10^{-3}$	$1.13 \cdot 10^{-3}$	$9.26 \cdot 10^{-4}$
150	$1.82 \cdot 10^{-3}$	$5.73 \cdot 10^{-1}$	$2.06 \cdot 10^{-4}$	$1.22 \cdot 10^{-3}$	$1.00 \cdot 10^{-3}$	$5.40 \cdot 10^{-4}$	$1.34 \cdot 10^{-3}$

Таблица 4: MNIST без l_2 -регуляризации. Критерий – FW-зазор.

R	FW ls	FW	CFW	NFW $N = 2$	NFW $N = 3$	NFW $N = 4$	NFW $N = 5$
0.10	$7.48 \cdot 10^{-2}$	$1.97 \cdot 10^{-2}$	$4.00 \cdot 10^{-2}$	$3.87 \cdot 10^{-2}$	$2.63 \cdot 10^{-2}$	$2.06 \cdot 10^{-2}$	$2.98 \cdot 10^{-2}$
0.80	$5.56 \cdot 10^{-1}$	2.83	$5.37 \cdot 10^{-1}$	$6.45 \cdot 10^{-1}$	$5.88 \cdot 10^{-1}$	$6.22 \cdot 10^{-1}$	$6.48 \cdot 10^{-1}$
1.50	1.15	14.17	1.04	1.25	1.19	1.45	1.48
2.50	1.93	32.05	1.63	2.33	2.11	2.44	2.51

Таблица 5: MNIST с l_2 -регуляризацией. Критерий – FW-зазор.

R	FW ls	FW	CFW	NFW $N = 2$	NFW $N = 3$	NFW $N = 4$	NFW $N = 5$
0.01	$3.47 \cdot 10^{-3}$	$3.38 \cdot 10^{-4}$	$2.63 \cdot 10^{-4}$	$1.41 \cdot 10^{-4}$	$1.44 \cdot 10^{-4}$	$4.47 \cdot 10^{-5}$	$5.62 \cdot 10^{-5}$
0.10	$5.39 \cdot 10^{-2}$	$5.75 \cdot 10^{-2}$	$4.93 \cdot 10^{-2}$	$4.69 \cdot 10^{-2}$	$4.92 \cdot 10^{-2}$	$6.02 \cdot 10^{-2}$	$5.01 \cdot 10^{-2}$
0.20	$1.63 \cdot 10^{-1}$	$2.68 \cdot 10^{-1}$	$1.46 \cdot 10^{-1}$	$1.60 \cdot 10^{-1}$	$1.42 \cdot 10^{-1}$	$1.74 \cdot 10^{-1}$	$1.65 \cdot 10^{-1}$
0.50	$4.10 \cdot 10^{-1}$	2.03	$3.82 \cdot 10^{-1}$	$4.65 \cdot 10^{-1}$	$4.28 \cdot 10^{-1}$	$4.35 \cdot 10^{-1}$	$4.45 \cdot 10^{-1}$

Интерпретация ML-экспериментов.

На Mushrooms без регуляризации безусловное решение имеет очень большую l_1 -норму. При радиусах $R = 5, 30, 60, 150$ оно находится далеко за пределами допустимого множества. В этом режиме траектория FW часто упирается в границу l_1 -шара и начинает менять активные координаты зигзагообразно. Именно здесь сопряженные методы дают наиболее заметный выигрыш. Особенно сильный эффект виден при $R = 5$, где NFW достигает зазора порядка 10^{-9} , а FW остается на уровнях 10^{-4} – 10^{-3} .

Для Mushrooms с l_2 -регуляризацией безусловное решение имеет норму около 30.5. Поэтому при $R = 30$ граница близка к естественному решению задачи, а при больших радиусах часть ограничительного эффекта ослабевает. Тем не менее CFW и NFW сохраняют преимущество над FW. Интересно, что при $R = 150$ лучшим оказывается CFW, а не NFW. Это показывает, что увеличение памяти не является универсально лучшим выбором: когда активная геометрия задачи становится менее жесткой, одного предыдущего направления может быть достаточно.

На MNIST картина слабее. Без регуляризации оценочная l_1 -норма безусловного решения равна примерно 2.77, то есть часть выбранных радиусов находится близко к решению или внутри допустимой области. В таких условиях FW с линейным поиском и CFW/NFW становятся близкими. Однако даже здесь CFW часто дает лучший накопленный FW-зазор, особенно при $R = 0.80, 1.50, 2.50$. С l_2 -регуляризацией безусловное решение имеет норму около 0.15. Поэтому при $R = 0.01$ ограничение жесткое, и NFW с $N = 4$ оказывается лучшим. При $R = 0.50$ ограничение уже сравнительно слабое, и лучшим становится CFW.

Общий вывод экспериментов таков:

1. если безусловное решение далеко от границы $\mathcal{X}$, сопряженные модификации резко ускоряют FW;
2. если безусловное решение лежит близко к границе или внутри множества, разница между методами уменьшается;
3. для простых и разреженных задач NFW с $N > 2$ часто выигрывает у CFW;

4. для более сложных задач с плотной структурой признаков эффект сопряженности проявляется слабее;
5. зигзагообразность не исчезает полностью, но наступает позже, чем у классического FW.

3.6 Выводы по CFW in ML

CFW и NFW можно применять не только в транспортном моделировании, но и в задачах машинного обучения, если они сводятся к гладкой выпуклой оптимизации на компактном выпуклом множестве. Для таких задач явное вычисление гессиана не является обязательным: достаточно приближения произведения гессиана на вектор через разность градиентов. Теоретически CFW сохраняет порядок сходимости FW по зазору Frank–Wolfe. Практически же использование предыдущих направлений позволяет уменьшить зигзагообразность траектории и ускорить обучение логистической регрессии с ограничениями на параметры.

4 Стохастический блочно-координатный Frank–Wolfe

В этой главе рассматривается стохастический вариант Frank–Wolfe для крупномасштабной задачи равновесного распределения потоков [12]. Этот вариант удобно называть Stochastic Origin Frank–Wolfe (SOFW). В контексте данной работы он рассматривается как специальный случай блочно-координатного FW (BCFW) со стохастическим выбором блоков. Его ключевая идея состоит в выборе случайных блоков и обновлении только части координат на каждой итерации.

Классический FW в транспортной задаче требует на каждой итерации найти кратчайшие пути от всех источников ко всем стокам. Если граф содержит много зон и узлов, стоимость одной итерации становится основной вычислительной проблемой. Стохастический подход уменьшает стоимость итерации: вместо полного линейного оракула выбирается случайное подмножество источников или OD-пар, а остальные блоки фиксируются.

4.1 Блочная структура транспортной задачи

Рассмотрим вектор потоков по путям как конкатенацию блоков по OD-парам:

$$x = \left(x^{(i,j)} \right)_{(i,j) \in OD}, \quad x^{(i,j)} \in \mathbb{R}^{|\mathcal{P}_{i,j}|}.$$

Каждый блок соответствует множеству путей $\mathcal{P}_{i,j}$ между источником i и стоком j . Для блока выполняются ограничения спроса

$$\sum_{p \in \mathcal{P}_{i,j}} x_p = d_{ij}, \quad x_p \geq 0.$$

Следовательно, допустимое множество потоков по путям является декартовым произведением:

$$\mathcal{X} = \prod_{(i,j) \in OD} \mathcal{X}^{(i,j)}.$$

Переход от потоков по путям к потокам по ребрам задается линейным отображением

$$F(x) = \Theta x, \quad f = F(x).$$

В классическом FW линейный оракул решается по всем блокам:

$$s_k \in \arg \min_{x \in \mathcal{X}} \langle \nabla \Psi(F(x_k)), F(x) \rangle.$$

Так как

$$\langle \nabla \Psi(F(x_k)), F(x) \rangle = \sum_{(i,j) \in OD} \left\langle \tau(f_k), \Theta_{ij} x^{(i,j)} \right\rangle,$$

оракул распадается на независимые подзадачи по OD-парам. Каждая такая подзадача является назначением всего спроса на кратчайший путь при текущих дорожных временах.

4.2 Stochastic Origin Frank–Wolfe

На итерации k SOFW выбирает случайное подмножество OD-пар $\mathcal{I}_k \subset OD$ и обновляет только соответствующие блоки. Остальные блоки фиксируются в текущих значениях:

$$\mathcal{X}_k = \left\{ x \in \mathcal{X} \mid x^{(i,j)} = x_k^{(i,j)} \text{ для всех } (i,j) \notin \mathcal{I}_k \right\}.$$

Линейный оракул решается на суженном множестве:

$$s_k \in \arg \min_{x \in \mathcal{X}_k} \langle \nabla \Psi(f_k), F(x) \rangle.$$

На практике удобно выбирать не отдельные OD-пары, а подмножество источников. Если выбран источник i , то в батч включаются все корреспонденции (i, j) . Это позволяет один раз запустить алгоритм Дейкстры от источника i и получить кратчайшие пути до всех стоков.

4.3 Статическое назначение потоков и роль модели Бекмана

SOFW мотивируется задачей прогнозирования транспортных потоков. В транспортном планировании требуется оценить распределение движения по дорожной сети при заданной матрице спроса. В статической модели считается, что спрос за рассматриваемый период фиксирован, а рав-

новесие описывается принципом Вардропы: все используемые пути между одной OD-парой имеют минимальное время движения, а неиспользуемые пути не короче используемых.

Модель Бекмана дает выпуклую оптимизационную формулировку этого равновесия:

$$\min_{f=\Theta x, x \in \mathcal{X}} \Psi(f) = \sum_{e \in \mathcal{E}} \int_0^{f_e} \tau_e(z) dz.$$

Если функции τ_e неубывающие, то задача выпукла. Оптимальность x^* означает, что для любой допустимой перераспределенной траектории x выполнено вариационное неравенство

$$\langle \tau(f^*), \Theta x - \Theta x^* \rangle \geq 0.$$

Это ровно условие равновесия: нельзя уменьшить суммарную линейную стоимость при текущих временах движения.

Классический FW применим здесь особенно естественно. Линейная подзадача

$$\min_{x \in \mathcal{X}} \langle \tau(f^k), \Theta x \rangle$$

распадается по OD-парам:

$$\min_{x^{(i,j)} \in \mathcal{X}^{(i,j)}} \sum_{p \in \mathcal{P}_{i,j}} x_p \sum_{e \in p} \tau_e(f_e^k).$$

Оптимум достигается назначением всего спроса d_{ij} на кратчайший путь. Поэтому каждая полная итерация FW фактически состоит из набора запусков алгоритма кратчайших путей.

4.4 Path-based и link-based представления

В теории удобно работать с путевыми потоками x , потому что допустимое множество имеет явную блочную структуру:

$$\mathcal{X} = \prod_{(i,j) \in OD} \left\{ x^{(i,j)} \geq 0 \mid \sum_{p \in \mathcal{P}_{i,j}} x_p = d_{ij} \right\}.$$

Однако число возможных путей может быть экспоненциальным. Поэтому в реализации обычно не хранится весь вектор x . Хранятся потоки по ребрам f , а очередное решение линейного оракула строится как all-or-nothing assignment: для каждой OD-пары весь спрос временно отправляется на текущий кратчайший путь.

SOFW требует больше информации, чем полный FW. Если обновляется только часть источников, нужно уметь вычесть старый вклад этих источников из суммарного потока и добавить новый. Поэтому алгоритм хранит разложение

$$f = \sum_{o \in O} f^{(o)},$$

где $f^{(o)}$ – поток по ребрам, порожденный спросом из источника o . Когда выбран батч источников $\mathcal{A}_k$, обновляются только компоненты $f^{(o)}$, $o \in \mathcal{A}_k$, а остальные остаются фиксированными. Именно это разложение объясняет главный компромисс метода: SOFW уменьшает время итерации, но требует больше памяти.

Алгоритм 9 Stochastic Origin Frank–Wolfe

Вход: допустимое множество $\mathcal{X} = \prod_{w \in OD} \mathcal{X}^w$, отображение $F(x) = \Theta x$, вероятности выбора блоков, шаги γ_k

выбрать начальное $x_0 \in \mathcal{X}$ и положить $f_0 = F(x_0)$

для $k = 0, 1, 2, \dots$ **выполнить**

выбрать случайное подмножество $\mathcal{I}_k \subset OD$

определить суженное множество

$$\mathcal{X}_k = \left(\prod_{w \in \mathcal{I}_k} \mathcal{X}^w \right) \times \left(\prod_{w \notin \mathcal{I}_k} \{x_k^w\} \right)$$

вычислить $s_k \in \arg \min_{x \in \mathcal{X}_k} \langle \nabla \Psi(f_k), F(x) \rangle$

вычислить направление $d_k = F(s_k) - F(x_k)$ или его взвешенную несмещенную оценку

обновить $f_{k+1} = f_k + \gamma_k d_k$

обновить $x_{k+1} = x_k + \gamma_k (s_k - x_k)$

конец цикла

4.5 Взвешенный вариант

Во взвешенном варианте источники выбираются с вероятностями, пропорциональными суммарному спросу. Пусть

$$d_i = \sum_j d_{ij}, \quad \mathcal{C}_i = \{(i, j) \in OD\}.$$

Здесь d_i – полный спрос, исходящий из источника i , а $\mathcal{C}_i$ – множество всех корреспонденций с этим источником. В качестве веса источника можно взять нормированный спрос

$$w_i = \frac{d_i}{\sum_\ell d_\ell}, \quad \sum_i w_i = 1.$$

Тогда источник i выбирается с вероятностью w_i . Если после выбора источника корреспонденция внутри $\mathcal{C}_i$ выбирается равномерно, то вес OD-блока (i, j) равен

$$w_{ij} = \mathbb{P}\{(i, j)\} = w_i \cdot \frac{1}{|\mathcal{C}_i|} = \frac{d_i}{\sum_\ell d_\ell} \cdot \frac{1}{|\mathcal{C}_i|}.$$

Такой выбор чаще обновляет источники с большим суммарным спросом. На практике можно выбирать сразу батч источников с вероятностями w_i и затем включать в батч все корреспонденции выбранных источников; это соответствует той же идее, но лучше согласуется с вычислением кратчайших путей от одного источника ко всем стокам.

Для сохранения несмещенности направления используется importance-weighted коррекция:

$$d_k = \frac{1}{|\mathcal{I}_k|} W_k \sum_{(i,j) \in \mathcal{I}_k} \frac{1}{w_{ij}} \left(F(s_k^{[(i,j)]}) - F(x_k^{[(i,j)]}) \right), \quad W_k = \left(\sum_{(i,j) \in \mathcal{I}_k} \frac{1}{w_{ij}} \right)^{-1}.$$

4.6 Сходимость

Сходимость SOFW следует из анализа Block-Coordinate Frank–Wolfe на произведениях множеств [11, 10]. Для каждого блока $w = (i, j)$ вводится

блочная константа кривизны:

$$C_{\Psi}^w = \sup \frac{2}{\gamma^2} \left[\Psi(F(y)) - \Psi(F(x)) - \left\langle \nabla \Psi(F(x)), F(y^{[w]}) - F(x^{[w]}) \right\rangle \right],$$

где супремум берется по $x \in \mathcal{X}$, $s^w \in \mathcal{X}^w$, $\gamma \in [0, 1]$ и

$$y = x + \gamma(s^{[w]} - x^{[w]}).$$

Суммарная блочная кривизна равна

$$C_{\Psi}^{\otimes} = \sum_{w \in OD} C_{\Psi}^w.$$

Если на каждой итерации выбирается одна OD-пара равномерно случайно, то для ожидаемой субоптимальности выполняется оценка

$$\mathbb{E}[\Psi(f_k)] - \Psi(f^*) \leq \frac{2|OD|}{k + 2|OD|} [C_{\Psi}^{\otimes} + \Psi(f_0) - \Psi(f^*)]. \quad (4.1)$$

Для батчевого варианта, где на итерации выбирается подмножество $\mathcal{I}_k$ размера m , направление можно записать как

$$d_k = \frac{1}{m} \sum_{w \in \mathcal{I}_k} (s_k^{[w]} - x_k^{[w]}), \quad x_{k+1} = x_k + \gamma_k d_k.$$

При равномерном выборе без возвращения условное математическое ожидание прогресса имеет тот же вид, что и в небатчевом случае:

$$\mathbb{E}[\Psi(F(x_{k+1})) \mid x_k] \leq \Psi(F(x_k)) - \frac{\gamma_k}{|OD|} g(x_k) + \frac{\gamma_k^2}{2|OD|} C_{\Psi}^{\otimes}.$$

Теорема 4. Пусть $\{x_k\}$ порождается батчевым SOFW с произвольным размером батча m и шагами

$$\gamma_k = \frac{2|OD|}{k + 2|OD|}.$$

Тогда

$$\mathbb{E}[\Psi(F(x_k))] - \Psi(F(x^*)) \leq \frac{2|OD|}{k + 2|OD|} [C_{\Psi}^{\otimes} + \Psi(F(x_0)) - \Psi(F(x^*))].$$

Следовательно, для достижения ε -точности в ожидании достаточно

$$\mathcal{O}\left(\frac{|OD|}{\varepsilon}\right)$$

итераций.

Батчирование в такой нормировке не улучшает теоретический порядок по числу итераций, но уменьшает дисперсию направления и может существенно улучшать время работы. В транспортной задаче это особенно важно, поскольку стоимость итерации почти линейно зависит от числа источников, для которых запускается поиск кратчайших путей.

4.7 Доказательство батчевой оценки

Доказательство для батчевого SOFW начинается с явного разложения полного FW-зазора по OD-блокам. Пусть выбран блок $w \in OD$ и

$$s^w(x) \in \arg \min_{u \in \mathcal{X}^w} \left\langle \nabla \Psi(F(x)), F(u^{[w]}) \right\rangle.$$

Здесь $u^{[w]}$ означает вектор, у которого активен только блок w . Определим блочный FW-зазор

$$g^w(x) = \left\langle \nabla \Psi(F(x)), F\left((x^w - s^w(x))^{[w]}\right) \right\rangle \geq 0.$$

Тогда полный FW-зазор раскладывается в сумму

$$g(x) = \sum_{w \in OD} g^w(x).$$

Это равенство является ключевым: линейный оракул в модели Бекмана распадается по OD-парам, поэтому потеря от обновления только части блоков выражается через долю неиспользованных слагаемых в этой сумме.

Обновление только этого блока имеет вид

$$x^+ = x + \gamma(s^w(x) - x^w)^{[w]}.$$

По определению блочной кривизны

$$\Psi(F(x^+)) \leq \Psi(F(x)) - \gamma g^w(x) + \frac{\gamma^2}{2} C_\Psi^w.$$

Если блок выбирается равномерно, то после взятия условного ожидания получается

$$\mathbb{E}[g^w(x) \mid x] = \frac{1}{|OD|} \sum_{w \in OD} g^w(x) = \frac{1}{|OD|} g(x).$$

Аналогично

$$\mathbb{E}[C_\Psi^w] = \frac{1}{|OD|} C_\Psi^\otimes.$$

Отсюда следует рекурсия

$$\mathbb{E}[\Psi(F(x_{k+1})) \mid x_k] \leq \Psi(F(x_k)) - \frac{\gamma_k}{|OD|} g(x_k) + \frac{\gamma_k^2}{2|OD|} C_\Psi^\otimes.$$

Для батча размера m направление записывается как среднее по выбранным блокам:

$$d_k = \frac{1}{m} \sum_{w \in \mathcal{I}_k} (s^w(x_k) - x_k^w)^{[w]}.$$

Поскольку F линейно, а Ψ выпукла, точку после батчевого шага можно сравнить со средним одноблочных шагов:

$$x_k + \gamma d_k = \frac{1}{m} \sum_{w \in \mathcal{I}_k} \left(x_k + \gamma (s^w(x_k) - x_k^w)^{[w]} \right).$$

Следовательно,

$$\Psi(F(x_k + \gamma d_k)) \leq \frac{1}{m} \sum_{w \in \mathcal{I}_k} \Psi \left(F \left(x_k + \gamma (s^w(x_k) - x_k^w)^{[w]} \right) \right).$$

Подставляя одноблочную оценку в правую часть, получаем

$$\Psi(F(x_k + \gamma d_k)) \leq \Psi(F(x_k)) - \frac{\gamma}{m} \sum_{w \in \mathcal{I}_k} g^w(x_k) + \frac{\gamma^2}{2m} \sum_{w \in \mathcal{I}_k} C_\Psi^w.$$

Если блоки выбираются равномерно без возвращения, то каждый блок попадает в батч с вероятностью $m/|OD|$. Поэтому

$$\mathbb{E} \left[\frac{1}{m} \sum_{w \in \mathcal{I}_k} g^w(x_k) \mid x_k \right] = \frac{1}{|OD|} \sum_{w \in OD} g^w(x_k) = \frac{1}{|OD|} g(x_k),$$

и аналогично

$$\mathbb{E} \left[\frac{1}{m} \sum_{w \in \mathcal{I}_k} C_\Psi^w \mid x_k \right] = \frac{1}{|OD|} C_\Psi^\otimes.$$

Именно поэтому теоретическая рекурсия для батча совпадает с одноблочной рекурсией. Размер батча не входит в порядок сходимости, но влияет на дисперсию направления и на реальное время достижения заданного зазора.

Переход от рекурсии к явной оценке использует выпуклость:

$$g(x_k) \geq \Psi(F(x_k)) - \Psi(F(x^*)).$$

Обозначив

$$h_k = \mathbb{E}[\Psi(F(x_k)) - \Psi(F(x^*))],$$

получаем

$$h_{k+1} \leq \left(1 - \frac{\gamma_k}{|OD|} \right) h_k + \frac{\gamma_k^2}{2|OD|} C_\Psi^\otimes.$$

При выборе

$$\gamma_k = \frac{2|OD|}{k + 2|OD|}$$

индукция дает

$$h_k \leq \frac{2|OD|}{k + 2|OD|} [C_\Psi^\otimes + h_0].$$

Именно эта формула и записана в теореме 4.

4.8 Вычислительная сложность и память

Пусть n есть число источников, $V = |\mathcal{V}|$ число узлов, а $E = |\mathcal{E}|$ число ребер графа. Полная итерация FW требует запустить поиск кратчайших путей из всех источников и имеет оценку

$$\mathcal{O}(n(E + V \log V)).$$

Если SOFW выбирает долю α источников, то стоимость итерации становится

$$\mathcal{O}(\alpha n(E + V \log V)).$$

Цена такого ускорения состоит в увеличенном потреблении памяти: необходимо хранить разложение суммарного потока по источникам

$$f = \sum_{a=1}^n f^{(a)}.$$

Если за итерацию выбирается множество источников $\mathcal{A}$, то увеличение памяти оценивается примерно как

$$\frac{n}{|\mathcal{A}|}.$$


Таким образом, SOFW явно задает компромисс между временем итерации, качеством стохастического направления и расходом памяти.

4.9 Экспериментальные результаты


Эксперименты проводились на транспортных сетях из открытого репозитория [9]. Сравнивались классический FW, равномерный SOFW и взвешенный SOFW-w. Для крупных графов стохастический метод давал существенно меньший зазор Frank–Wolfe при том же вычислительном бюджете.

Таблица 6: Характеристики транспортных датасетов и оценка стоимости полной итерации $\hat{\mathcal{C}}_{\text{iter}} = Z(E + N \ln N)$.

Датасет	Зоны Z	Ребра E	Узлы N	$\hat{\mathcal{C}}_{\text{iter}}$
SiouxFalls	24	76	24	$3.66 \cdot 10^3$
Anaheim	38	914	416	$1.30 \cdot 10^5$
Terrassa-Asymmetric	55	3264	1609	$8.33 \cdot 10^5$
Winnipeg	147	2836	1052	$1.49 \cdot 10^6$
Chicago-Sketch	387	2950	933	$3.61 \cdot 10^6$
GoldCoast	1068	11140	4807	$5.54 \cdot 10^7$
Birmingham-England	898	33937	14639	$1.57 \cdot 10^8$
Chicago-Regional	1790	39018	12982	$2.90 \cdot 10^8$
Philadelphia	1525	40003	13389	$2.55 \cdot 10^8$




(a) Chicago-Sketch




(b) Birmingham-England

Рис. 18: Сравнение SOFW и FW на средних транспортных сетях.



(a) Chicago-Regional



(b) GoldCoast

Рис. 19: SOFW на крупных сетях: выигрыш увеличивается вместе с размером графа.






Рис. 20: Датасет Philadelphia: сравнение SOFW и FW на крупной транспортной сети.




(a) Sioux Falls




(b) Anaheim

Рис. 21: SOFW и FW на малых сетях: преимущество стохастического подхода менее выражено из-за накладных расходов.



(a) Terrassa-Asymmetric



(b) Winnipeg

Рис. 22: Переходная зона между малыми и средними сетями: стохастический подход начинает давать устойчивый выигрыш.

4.10 Интерпретация графиков SOFW

На малых сетях SiouxFalls и Anaheim стоимость полного запуска кратчайших путей невелика. Поэтому экономия от частичного оракула не всегда перекрывает дополнительные расходы: нужно хранить разложение потока по источникам и аккуратно обновлять только выбранные компоненты. На таких задачах классический FW остается сильным базовым методом.

На Terrassa-Asymmetric и Winnipeg картина меняется. Число зон и ребер уже достаточно велико, чтобы стоимость полной итерации стала заметной. SOFW начинает выигрывать по времени, особенно на начальном участке, где даже грубое стохастическое направление быстро снижает зазор.

На Chicago-Sketch, GoldCoast, Birmingham-England, Chicago-Regional и Philadelphia преимущество становится основным практическим результатом. Чем больше сеть, тем менее рационально на каждой итерации решать линейный оракул по всем источникам. Случайное обновление части источников дает больше итераций за тот же бюджет времени. Даже если каждая отдельная итерация менее точна, суммарный прогресс оказывается лучше.

Взвешенный вариант SOFW-w особенно полезен на ранних итерациях. Если источник создает большой суммарный спрос, его вклад в поток по ребрам велик. Обновление такого источника сильнее меняет функцию Бекмана и быстрее уменьшает грубую начальную ошибку. По мере приближения к равновесию различие между равномерным и взвешенным выбором уменьшается: локальные корректировки становятся тоньше, а роль случайности и конкретных ОД-пар возрастает.

Основные экспериментальные выводы:

1. SOFW существенно превосходит FW на крупных графах.
2. Преимущество SOFW растет вместе с размером сети.
3. На малых сетях метод остается конкурентоспособным, но накладные расходы хранения разложения потока уменьшают выигрыш.
4. Взвешенный SOFW-w быстрее уменьшает зазор на первых итерациях.

5. Долгосрочно равномерный и взвешенный варианты дают близкое качество, особенно на крупных графах.

4.11 Переход от OD-пар к источникам

Теоретически блоком может быть отдельная OD-пара $w = (i, j)$. Однако в дорожном графе эффективнее выбирать источники. Если выбран источник i , то один запуск алгоритма кратчайших путей из i дает расстояния до всех стоков j . Поэтому батч источников

$$\mathcal{A}_k \subset O$$

порождает батч OD-пар

$$\mathcal{I}_k = \{(i, j) \in OD \mid i \in \mathcal{A}_k\}.$$

Такой выбор лучше соответствует структуре вычислений: стоимость одной итерации примерно пропорциональна числу выбранных источников, а не числу отдельных OD-пар.

4.12 Обновление разложения потока

Пусть

$$f_k = \sum_{i \in O} f_k^{(i)}.$$

Для выбранного источника i строится новый all-or-nothing поток $\hat{f}_k^{(i)}$: весь спрос из i назначается на кратчайшие пути при текущих временах $\tau(f_k)$. Затем направление для этого источника равно

$$d_k^{(i)} = \hat{f}_k^{(i)} - f_k^{(i)}.$$

Если выбран батч $\mathcal{A}_k$, суммарное направление записывается как

$$d_k = \sum_{i \in \mathcal{A}_k} d_k^{(i)}.$$

Обновление выполняется только для выбранных источников:

$$f_{k+1}^{(i)} = \begin{cases} f_k^{(i)} + \gamma_k d_k^{(i)}, & i \in \mathcal{A}_k, \\ f_k^{(i)}, & i \notin \mathcal{A}_k. \end{cases}$$

После этого

$$f_{k+1} = \sum_{i \in O} f_{k+1}^{(i)}.$$

Эта формула показывает, почему SOFW требует хранения $f^{(i)}$. Без такого разложения нельзя локально заменить вклад выбранного источника, не пересчитывая полный поток.

4.13 Равномерная и взвешенная выборка

При равномерной выборке каждый источник имеет одинаковую вероятность попасть в батч. Это просто и дает чистую теоретическую оценку. Но спрос по источникам может быть сильно неравномерным. Если источник генерирует большой поток, его обновление может сильнее уменьшить функционал. Поэтому рассматривается взвешенная версия.

Пусть

$$D_i = \sum_j d_{ij}$$

– полный спрос из источника i . Вероятность выбора источника задается как

$$p_i = \frac{D_i}{\sum_{\ell \in O} D_\ell}.$$

Чтобы направление не стало смещенным в сторону крупных источников, можно использовать importance weighting. В простейшей записи вклад выбранного источника корректируется множителем $1/p_i$:

$$\tilde{d}_k^{(i)} = \frac{1}{p_i} d_k^{(i)}.$$

Тогда

$$\mathbb{E}[\tilde{d}_k^{(i)}] = \sum_{i \in O} d_k^{(i)}$$

с точностью до нормировки батча. На практике эта коррекция стабилизи-

рует сравнение равномерного и взвешенного SOFW.

4.14 Влияние батча на теоретический порядок

Интуитивно может показаться, что батч размера m должен ускорять сходимость в m раз. Однако в нормированной записи направление усредняется по выбранным блокам. Ожидаемый прогресс на одну итерацию остается пропорционален полному FW-зазору, деленному на число блоков:

$$\mathbb{E}[\Delta_k \mid x_k] \approx -\frac{\gamma_k}{|OD|} g(x_k).$$

Батч уменьшает дисперсию, но не меняет этот множитель в базовой оценке. Практический выигрыш появляется через время выполнения: если батч можно обработать значительно быстрее полного оракула, то за тот же бюджет времени алгоритм делает больше обновлений.

4.15 Память и время

Если в графе $|O|$ источников и $|\mathcal{E}|$ ребер, хранение полного потока требует

$$\mathcal{O}(|\mathcal{E}|)$$

памяти. Хранение разложения по источникам требует

$$\mathcal{O}(|O||\mathcal{E}|)$$

в худшем случае. На практике потоки могут быть разреженными, но порядок показывает потенциальную цену SOFW. Время одной полной итерации FW можно оценить как

$$|O| \cdot T_{\text{SP}},$$

где T_{SP} – стоимость одного запуска кратчайших путей. Если SOFW выбирает долю α источников, то итерация стоит примерно

$$\alpha |O| \cdot T_{\text{SP}},$$

но требует поддерживать разложение $f = \sum_i f^{(i)}$.

4.16 Итоги раздела

Стохастический блочно-координатный подход показывает, что для крупных транспортных сетей главная стоимость FW – это не формула шага и не вычисление градиента, а полный линейный оракул. SOFW уменьшает эту стоимость, выбирая только часть источников. Теоретическая оценка остается такой же по порядку, как у блочного FW, а практические графики показывают, что на больших сетях экономия времени важнее шума стохастического направления.

4.17 Выводы по BCFW/SOFW

Стохастический блочно-координатный подход переносит идею SGD на Frank–Wolfe: вместо полного дорогого оракула используется случайный частичный оракул. В транспортной задаче такой выбор особенно естественен, поскольку линейная подзадача распадается по источникам и OD-парам. BCFW/SOFW позволяет масштабировать проекционно-свободную оптимизацию на крупные сети, но требует аккуратного учета компромисса между памятью, числом обновляемых блоков и качеством направления. Эта же блочная идея используется в следующей главе для построения децентрализованного алгоритма.

5 Децентрализованный блочно-координатный Frank–Wolfe

В этой главе рассматривается Decentralized Block-Coordinate Frank–Wolfe (DBCFW). Это распределенное обобщение блочно-координатного Frank–Wolfe. Метод опирается на идеи BCFW и децентрализованного FW [11, 13, 14]. Метод объединяет три идеи:

1. децентрализованный консенсус между вычислительными узлами;
2. отслеживание градиента для приближения среднего градиента глобальной функции;
3. стохастический выбор блоков и суженный линейный оракул на каждом узле.

Такой алгоритм естественно продолжает BCFW/SOFW: если в транспортной задаче блоками являются OD-пары или источники, то в общей распределенной постановке блоками являются компоненты декартова произведения допустимого множества.

5.1 Мотивация и место DBCFW среди FW-методов

Классический Frank–Wolfe хорошо подходит для задач с простым линейным оракулом и дорогой проекцией. Однако в современных задачах машинного обучения часто появляются еще две сложности. Во-первых, данные распределены между несколькими узлами и не могут быть собраны в одном месте. Во-вторых, само допустимое множество имеет блочную структуру, поэтому полный линейный оракул избыточен на каждой итерации.

Decentralized Frank–Wolfe решает первую проблему: каждый агент работает со своей локальной функцией f_i , а согласование происходит через коммуникационный граф. Block-Coordinate Frank–Wolfe решает вторую проблему: на итерации обновляется только часть блоков допустимого множества. DBCFW объединяет эти две идеи. В результате каждый агент не только использует локальную информацию и общается с соседями, но и решает линейный оракул только на выбранных блоках.

Такая постановка особенно естественна для задач вида

$$D = D_1 \times \cdots \times D_n,$$

где каждый блок D_k имеет собственный дешевый линейный оракул. Если полный оракул по D стоит примерно как сумма оракулов по всем блокам, то обновление батча размера $B \ll n$ уменьшает стоимость итерации примерно в n/B раз. Цена этого выигрыша состоит в более шумном направлении и необходимости учитывать ошибки консенсуса между агентами.

5.2 Связанные направления

DBCFW опирается на три линии работ. Первая линия – децентрализованный FW с градиентным отслеживанием. В таких методах каждый агент хранит локальную точку x_t^i и локальную оценку глобального градиента. Смешивание точек отвечает за консенсус, а смешивание градиентных оценок отвечает за то, чтобы каждый агент двигался приблизительно по направлению среднего градиента.

Вторая линия – блочно-координатный FW. В BCFW допустимое множество является декартовым произведением, и линейный оракул вызывается только для случайного блока. Для выпуклых гладких задач это сохраняет порядок $O(1/t)$ по ожидаемой субоптимальности, но уменьшает стоимость одной итерации.

Третья линия – стохастический транспортный FW из предыдущей главы. SOFW показывает, что блочная случайность может быть не только теоретической конструкцией, но и практическим способом ускорить задачу транспортного назначения. DBCFW переносит эту идею на более общую распределенную постановку.

5.3 Постановка распределенной задачи

Пусть имеется N узлов. Узел i имеет доступ только к локальной функции $f_i : D \rightarrow \mathbb{R}$. Требуется решить задачу

$$\min_{x \in D} f(x) := \frac{1}{N} \sum_{i=1}^N f_i(x), \quad (5.1)$$

где $D \subset \mathbb{R}^d$ компактно и выпукло. Предполагается, что множество имеет блочную структуру

$$D = D_1 \times \cdots \times D_n.$$

Каждый узел поддерживает локальную точку $x_t^i \in D$. Средняя точка сети равна

$$x_{\text{avg},t} = \frac{1}{N} \sum_{i=1}^N x_t^i.$$

Диаметр допустимого множества обозначается

$$\bar{\rho} = \max_{x,y \in D} \|x - y\|_2.$$

5.4 Коммуникационная модель

На итерации t узлы обмениваются информацией по графу коммуникаций с матрицей смешивания $W_t \in \mathbb{R}^{N \times N}$. Граф может меняться от итерации к итерации. Более того, W_t может быть случайной матрицей, если топология коммуникаций или выбор ребер задаются случайным механизмом. Используются стандартные предположения из децентрализованной оптимизации [13, 14].

Предположение 5. Пусть $\mathcal{H}_t$ – история процесса перед выбором коммуникационной матрицы W_t . Для каждой итерации t матрица W_t почти наверное согласована с текущим графом коммуникаций:

$$(W_t)_{ij} = 0, \quad i \neq j, \quad (i, j) \notin E_t.$$

Она почти наверное неотрицательна и дважды стохастична:

$$(W_t)_{ij} \geq 0, \quad W_t \mathbf{1} = \mathbf{1}, \quad \mathbf{1}^T W_t = \mathbf{1}^T.$$

Кроме того, существует $\lambda \in (0, 1)$ такая, что для любого $\mathcal{H}_t$ -измеримого вектора $z \in \mathbb{R}^N$ выполнено

$$\mathbb{E} \left[\left\| \left(W_t - \frac{1}{N} \mathbf{1} \mathbf{1}^T \right) z \right\|_2^2 \middle| \mathcal{H}_t \right] \leq \lambda^2 \|z\|_2^2.$$

Это квадратичная условная версия предположения для случайной коммуникационной матрицы у Ведерникова и др. [14]: сжатие требуется не для каждой реализации W_t , а для математического ожидания отклонения от консенсуса. По неравенству Йенсена из нее следует и оценка для математического ожидания нормы.

Предположение 6. Каждая функция f_i выпукла и L -гладка на D :

$$0 \leq f_i(y) - f_i(x) - \langle \nabla f_i(x), y - x \rangle \leq \frac{L}{2} \|y - x\|_2^2, \quad x, y \in D.$$

Оценки на ошибки консенсуса и градиентного отслеживания в этой главе не постулируются отдельно. Они выводятся ниже из предположений о смешивании, гладкости и компактности множества D .

5.5 Алгоритм DBCFW

В DBCFW каждый узел сначала смешивает локальные точки с соседями:

$$\tilde{x}_t^i = \sum_{j=1}^N (W_t)_{ij} x_t^j.$$

Затем он обновляет локальную оценку градиента и снова применяет смешивание:

$$g_t^i = \tilde{g}_{t-1}^i + \nabla f_i(\tilde{x}_t^i) - \nabla f_i(\tilde{x}_{t-1}^i),$$

$$\tilde{g}_t^i = \sum_{j=1}^N (W_t)_{ij} g_t^j.$$

После этого узел выбирает подмножество блоков $I_t^i \subset \{1, \dots, n\}$ размера B и строит суженное множество:

$$D_t^i = \left(\prod_{k \in I_t^i} D_k \right) \times \left(\prod_{k \notin I_t^i} \{\tilde{x}_t^i[k]\} \right).$$

Линейный оракул решается только на выбранных блоках:

$$v_t^i \in \arg \min_{v \in D_t^i} \langle \tilde{g}_t^i, v \rangle.$$

Затем выполняется FW-обновление

$$x_{t+1}^i = (1 - \gamma_t)\tilde{x}_t^i + \gamma_t v_t^i.$$

Алгоритм 10 Decentralized Block-Coordinate Frank–Wolfe

Вход: множество $D = D_1 \times \dots \times D_n$, шаги γ_t , матрицы W_t , размер батча B

инициализировать $x_0^i \in D$, $\tilde{x}_{-1}^i \leftarrow x_0^i$, $\tilde{g}_{-1}^i \leftarrow \nabla f_i(\tilde{x}_{-1}^i)$ для всех i

для $t = 0, 1, 2, \dots$ **выполнить**

для всех $i \in \{1, \dots, N\}$ параллельно **выполнить**

$$\tilde{x}_t^i \leftarrow \sum_{j=1}^N (W_t)_{ij} x_t^j$$

$$g_t^i \leftarrow \tilde{g}_{t-1}^i + \nabla f_i(\tilde{x}_t^i) - \nabla f_i(\tilde{x}_{t-1}^i)$$

$$\tilde{g}_t^i \leftarrow \sum_{j=1}^N (W_t)_{ij} g_t^j$$

выбрать блоки $I_t^i \subset \{1, \dots, n\}$, $|I_t^i| = B$

построить $D_t^i = \left(\prod_{k \in I_t^i} D_k \right) \times \left(\prod_{k \notin I_t^i} \{\tilde{x}_t^i[k]\} \right)$

$$v_t^i \leftarrow \arg \min_{v \in D_t^i} \langle \tilde{g}_t^i, v \rangle$$

$$x_{t+1}^i \leftarrow (1 - \gamma_t)\tilde{x}_t^i + \gamma_t v_t^i$$

конец цикла

конец цикла

5.6 Связь с классическим DFW

Если каждый узел на каждой итерации выбирает все блоки,

$$I_t^i = \{1, \dots, n\},$$

то суженное множество совпадает с исходным:

$$D_t^i = D.$$

В этом случае DBCFW превращается в стандартный Decentralized Frank–Wolfe с градиентным отслеживанием:

$$v_t^i \in \arg \min_{v \in D} \langle \tilde{g}_t^i, v \rangle.$$

Следовательно, DBCFW является строгим обобщением децентрализованного FW: он сохраняет консенсус и отслеживание градиента, но заменяет полный линейный оракул блочно-суженным оракулом.

Утверждение 7. Если для всех узлов i и всех итераций t выбрано $I_t^i = \{1, \dots, n\}$, то алгоритм DBCFW совпадает с децентрализованным Frank–Wolfe с градиентным отслеживанием.

Доказательство. При полном выборе блоков имеем

$$D_t^i = \left(\prod_{k=1}^n D_k \right) = D.$$

Следовательно, строка линейного оракула в алгоритме DBCFW принимает вид

$$v_t^i \in \arg \min_{v \in D} \langle \tilde{g}_t^i, v \rangle.$$

Все остальные строки алгоритма не зависят от размера батча: смешивание точек

$$\tilde{x}_t^i = \sum_{j=1}^N (W_t)_{ij} x_t^j$$

и градиентное отслеживание

$$g_t^i = \tilde{g}_{t-1}^i + \nabla f_i(\tilde{x}_t^i) - \nabla f_i(\tilde{x}_{t-1}^i)$$

остаются теми же. Значит, единственное отличие DBCFW от DFW исчезает, и полученная схема совпадает с полным децентрализованным FW. $\square$

5.7 Полный DFW как предельный случай

Для ясности запишем соответствующую полную схему. Каждый агент сначала усредняет точки с соседями, затем обновляет оценку градиента, после чего решает полный линейный оракул.

Алгоритм 11 Decentralized Frank–Wolfe с градиентным отслеживанием

Вход: множество D , шаги γ_t , матрицы смешивания W_t

инициализировать $x_0^i \in D$ и $g_0^i = \nabla f_i(x_0^i)$

для $t = 0, 1, 2, \dots$ **выполнить**

для всех $i = 1, \dots, N$ параллельно **выполнить**

$$\tilde{x}_t^i \leftarrow \sum_{j=1}^N (W_t)_{ij} x_t^j$$

$$\tilde{g}_t^i \leftarrow \sum_{j=1}^N (W_t)_{ij} g_t^j$$

$$v_t^i \leftarrow \arg \min_{v \in D} \langle \tilde{g}_t^i, v \rangle$$

$$x_{t+1}^i \leftarrow (1 - \gamma_t) \tilde{x}_t^i + \gamma_t v_t^i$$

$$g_{t+1}^i \leftarrow \tilde{g}_t^i + \nabla f_i(x_{t+1}^i) - \nabla f_i(x_t^i)$$

конец цикла

конец цикла

DBCFW заменяет только строку полного оракула. Вместо D используется D_t^i , где невыбранные блоки зафиксированы в точке $\tilde{x}_t^i$. Поэтому DBCFW можно рассматривать как DFW с активным подмножеством координат. Именно здесь находится единственная содержательная связь с SOFW из предыдущей главы: оба метода используют декартову блочную структуру допустимого множества и обновляют только часть блоков на итерации. На этом аналогия заканчивается. В SOFW блоки являются компонентами одной централизованной транспортной переменной, а в DBCFW агенты – это вычислительные узлы с локальными функциями и локальными копиями решения.

5.8 Отличие SOFW от обычного DFW

На первый взгляд SOFW и DFW с меняющимся графом могут выглядеть близко. Действительно, в децентрализованной схеме можно рассматривать стохастический граф блочного вида: на итерации выбирается только часть ребер или некоторый подграф, после чего смешивание задается матрицей W_t этого подграфа. Если такие матрицы почти наверное остаются неотрицательными и дважды стохастическими, а сжатие отклонения от консенсуса выполняется в смысле условного математического ожидания из предположения 5, то это попадает в стохастическую модель time-varying графов для DFW. В этом смысле стохастичность может появляться как в выборе коммуникационного подграфа, так и в выборе блоков допустимого множества.

При стохастических графах это условие естественно проверяется именно в среднем. Рассмотрим $N = 4$ и матрицу попарного gossip-усреднения. Если на данной итерации выбрана пара $e = \{1, 2\}$, то

$$W_{12} = \begin{pmatrix} 1/2 & 1/2 & 0 & 0 \\ 1/2 & 1/2 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

и обновляются только агенты 1 и 2. Агенты 3 и 4 в этой реализации не смешиваются ни с кем. Аналогично определяются матрицы W_{ij} для всех неупорядоченных пар $1 \leq i < j \leq 4$. Пусть теперь на каждой итерации пара e_t выбирается равномерно из шести пар полного графа, а $W_t = W_{e_t}$. Каждая реализация W_t неотрицательна, дважды стохастична и соответствует графу, в котором активно только одно ребро.

Покажем, что такая случайная матрица удовлетворяет предположению 5. Обозначим $J_4 = \frac{1}{4}\mathbf{1}\mathbf{1}^T$ и возьмем произвольный вектор $z \in \mathbb{R}^4$. Достаточно рассматривать его центрированную часть

$$z_{\perp} = (I - J_4)z,$$

поскольку $W_{ij}\mathbf{1} = \mathbf{1}$. Для попарного усреднения

$$\|W_{ij}z_{\perp}\|_2^2 = \|z_{\perp}\|_2^2 - \frac{1}{2}(z_{\perp,i} - z_{\perp,j})^2.$$

Усредняя по шести парам и используя тождество

$$\sum_{1 \leq i < j \leq 4} (z_{\perp,i} - z_{\perp,j})^2 = 4 \|z_{\perp}\|_2^2,$$

получаем

$$\mathbb{E} \|(W_t - J_4)z\|_2^2 = \mathbb{E} \|W_t z_{\perp}\|_2^2 = \frac{2}{3} \|z_{\perp}\|_2^2.$$

Следовательно, по неравенству Йенсена

$$\mathbb{E} \|(W_t - J_4)z\|_2 \leq \sqrt{\frac{2}{3}} \|z_{\perp}\|_2 \leq \sqrt{\frac{2}{3}} \|z\|_2.$$

То есть предположение 5 выполнено с $\lambda = \sqrt{2/3} < 1$. Именно это позволяет формально описать ситуацию, когда в каждой реализации обновляется только выбранный блок агентов, а остальные агенты на данном шаге не смешиваются.

Однако это сходство является только структурным. В DFW каждый агент хранит свою копию полного вектора x , вычисляет локальные величины, связанные со своей функцией f_i , и пытается согласовать эту копию с копиями других агентов. Даже если коммуникационный граф семплируется блочно, агент остается вычислительным узлом с локальной задачей и локальной информацией.

В SOFW ситуация другая. Там нет нескольких копий полного решения и нет локальных функций f_i у независимых агентов. Есть один глобальный поток, разложенный по источникам или OD-парам, а случайность возникает из выбора активных блоков этого разложения. При этом все выбранные блоки используют один и тот же глобальный градиент

$$\tau(f_k) = \nabla \Psi(f_k),$$

который зависит от суммарного потока по всем ребрам.

Поэтому SOFW/BCFW и DFW не являются частными случаями друг друга. Их можно совместить только в более общей схеме: оставить децентрализованные локальные вычисления и градиентное отслеживание, но заменить полный линейный оракул на блочно суженный оракул. Именно это и делает DBCFW.

5.9 Кривизна и оценка сходимости

Для анализа вводятся блочные константы кривизны. Пусть $D = D_1 \times \dots \times D_n$. Для блока k , точки $x \in D$, точки блока $s_k \in D_k$ и $\gamma \in (0, 1]$ определим точку $y = y(x, k, s_k, \gamma) \in D$:

$$y[j] = \begin{cases} x[k] + \gamma(s_k - x[k]), & j = k, \\ x[j], & j \neq k, \end{cases}$$

Блочная константа кривизны равна

$$C_k = \sup_{\substack{x \in D, s_k \in D_k, \\ \gamma \in (0,1]}} \frac{2}{\gamma^2} [f(y) - f(x) - \langle \nabla f(x), y - x \rangle].$$

Глобальная константа кривизны

$$C = \sup_{\substack{x, s \in D, \\ \gamma \in (0,1]}} \frac{2}{\gamma^2} [f(x + \gamma(s - x)) - f(x) - \gamma \langle \nabla f(x), s - x \rangle]$$

удовлетворяет

$$C \leq \sum_{k=1}^n C_k, \quad C \leq L\bar{\rho}^2.$$

В доказательстве ниже используется последняя, глобальная оценка через $L\bar{\rho}^2$. Она дает корректную, но консервативную зависимость константы от размера батча; более тонкий анализ через блочные кривизны может улучшать эту зависимость, но не требуется для вывода порядка $O(1/t)$.

Лемма 8 (Консенсусная ошибка для случайных time-varying графов). Пусть выполнено предположение 5. Пусть $\alpha \in (0, 1]$, шаги удовлетворяют $0 \leq \gamma_t \leq \Gamma t^{-\alpha}$, $\gamma_t \leq 1$, $\Gamma \geq 1$, и пусть t_0 – такое целое число, что

$$\lambda \leq \left(\frac{t_0}{t_0 + 1} \right)^\alpha \frac{1}{1 + t_0^{-\alpha}}. \quad (5.2)$$

В частности, достаточно взять

$$t_0 \geq \left\lceil \left(\frac{2}{1 - \lambda} \right)^{1/\alpha} \right\rceil. \quad (5.3)$$

Действительно, при $t_0 \geq 1$ имеем

$$\left(\frac{t_0}{t_0 + 1} \right)^\alpha \frac{1}{1 + t_0^{-\alpha}} = (1 + t_0^{-1})^{-\alpha} (1 + t_0^{-\alpha})^{-1} \geq 1 - \frac{\alpha}{t_0} - t_0^{-\alpha} \geq 1 - 2t_0^{-\alpha}.$$

Поэтому (5.3) влечет (5.2). Тогда

$$\Delta_p^t := \mathbb{E} \left\| \tilde{E}_t \right\|_F \leq \frac{C_p}{t^\alpha}, \quad C_p = t_0^\alpha \Gamma \sqrt{N} \bar{\rho}, \quad (5.4)$$

где

$$\tilde{E}_t = \begin{bmatrix} (\tilde{x}_t^1 - x_{\text{avg},t})^T \\ \vdots \\ (\tilde{x}_t^N - x_{\text{avg},t})^T \end{bmatrix}.$$

В частности, $\max_i \mathbb{E} \|\tilde{x}_t^i - x_{\text{avg},t}\|_2 \leq C_p/t^\alpha$.

Доказательство. Введем также матрицу отклонений до коммуникации

$$E_t = \begin{bmatrix} (x_t^1 - x_{\text{avg},t})^T \\ \vdots \\ (x_t^N - x_{\text{avg},t})^T \end{bmatrix}.$$

Двойная стохастичность W_t сохраняет среднее:

$$\frac{1}{N} \sum_{i=1}^N \tilde{x}_t^i = x_{\text{avg},t}.$$

Поэтому

$$\tilde{E}_t = \left(W_t - \frac{1}{N} \mathbf{1}\mathbf{1}^T \right) E_t.$$

Применяя предположение 5 к координатам матрицы отклонений условно относительно истории перед коммуникацией на шаге t , получаем

$$\mathbb{E} \left[\left\| \tilde{E}_t \right\|_F^2 \mid \mathcal{H}_t \right] \leq \lambda^2 \|E_t\|_F^2.$$

Действительно, левая часть распадается в сумму таких же оценок по координатам векторов из D . По неравенству Йенсена отсюда следует стандартная оценка консенсусного сжатия

$$\mathbb{E} \left[\left\| \tilde{E}_t \right\|_F \mid \mathcal{H}_t \right] \leq \lambda \|E_t\|_F. \quad (5.5)$$

Для $1 \leq t \leq t_0$ имеем $\tilde{x}_t^i, x_{\text{avg},t} \in D$: смешанные точки остаются в D по неотрицательности строк W_t и выпуклости D , а средняя точка также лежит в D . Поэтому почти наверное

$$\left\| \tilde{E}_t \right\|_F \leq \sqrt{N} \bar{\rho} \leq \frac{C_p}{t^\alpha}.$$

Пусть теперь $t \geq t_0$ и $\mathbb{E} \left\| \tilde{E}_t \right\|_F \leq C_p/t^\alpha$. Из FW-обновления

$$x_{t+1}^i = (1 - \gamma_t) \tilde{x}_t^i + \gamma_t v_t^i, \quad x_{\text{avg}, t+1} = (1 - \gamma_t) x_{\text{avg}, t} + \gamma_t v_{\text{avg}, t},$$

где $v_{\text{avg}, t} = N^{-1} \sum_i v_t^i$, следует

$$\|E_{t+1}\|_F \leq (1 - \gamma_t) \left\| \tilde{E}_t \right\|_F + \gamma_t \sqrt{N} \bar{\rho}.$$

Применяя (5.5) к следующей коммуникации и беря полное математическое ожидание, получаем

$$\begin{aligned} \mathbb{E} \left\| \tilde{E}_{t+1} \right\|_F &\leq \lambda \mathbb{E} \|E_{t+1}\|_F \\ &\leq \lambda \left((1 - \gamma_t) \frac{C_p}{t^\alpha} + \gamma_t \sqrt{N} \bar{\rho} \right) \\ &\leq \lambda \frac{C_p + \Gamma \sqrt{N} \bar{\rho}}{t^\alpha} = \lambda (1 + t_0^{-\alpha}) \frac{C_p}{t^\alpha}. \end{aligned}$$

Условие (5.2) замыкает индукцию:

$$\lambda (1 + t_0^{-\alpha}) \frac{1}{t^\alpha} \leq \frac{1}{(t+1)^\alpha}.$$

Значит, $\mathbb{E} \left\| \tilde{E}_{t+1} \right\|_F \leq C_p/(t+1)^\alpha$. □

Лемма 9 (Ошибка градиентного отслеживания для случайных time-varying графов). Пусть выполнены предположения 5–6, а шаги удовлетворяют условиям леммы 8. Обозначим

$$\tilde{g}_t = \frac{1}{N} \sum_{i=1}^N \tilde{g}_t^i, \quad S_t = \left(\sum_{i=1}^N \|\tilde{g}_t^i - \tilde{g}_t\|_2^2 \right)^{1/2}.$$

Положим

$$r_0 = \left(\frac{t_0}{t_0 + 1} \right)^\alpha, \quad \kappa = r_0 - \lambda.$$

Из выбора t_0 в (5.2) следует $\kappa > 0$. Положим

$$A_g = 2\sqrt{N} L(\Gamma \bar{\rho} + 2C_p), \quad C_g = t_0^\alpha \mathbb{E} S_0 + t_0^{\alpha+1} A_g + \frac{A_g}{\kappa}.$$

Если используется стандартная константа ограниченности градиентов $G_D = \max_{i \in [N]} \sup_{x \in D} \|\nabla f_i(x)\|_2$, то $\mathbb{E}S_0 \leq 2\sqrt{N} G_D$. Тогда

$$\Delta_d^t := \mathbb{E}S_t \leq \frac{C_g}{t^\alpha}. \quad (5.6)$$

В частности, $\max_i \mathbb{E} \|\tilde{g}_t^i - \tilde{g}_t\|_2 \leq C_g/t^\alpha$.

Доказательство. Сначала заметим, что среднее значение градиентного трекера телескопически совпадает со средним локальным градиентом в смешанных точках:

$$\tilde{g}_t = \frac{1}{N} \sum_{i=1}^N \nabla f_i(\tilde{x}_t^i). \quad (5.7)$$

Действительно, двойная стохастичность дает $N^{-1} \sum_i \tilde{g}_t^i = N^{-1} \sum_i g_t^i$, а обновление

$$g_t^i = \tilde{g}_{t-1}^i + \nabla f_i(\tilde{x}_t^i) - \nabla f_i(\tilde{x}_{t-1}^i)$$

после суммирования по i дает телескопическую рекурсию. При $t = 0$ начальное условие алгоритма задает $g_0^i = \nabla f_i(\tilde{x}_0^i)$, поэтому тождество верно при $t = 0$ и далее следует по индукции.

Для произвольного $t \geq 0$ обозначим

$$\delta_{t+1}^i = \nabla f_i(\tilde{x}_{t+1}^i) - \nabla f_i(\tilde{x}_t^i), \quad \bar{\delta}_{t+1} = \frac{1}{N} \sum_{i=1}^N \delta_{t+1}^i.$$

Тогда

$$g_{t+1}^i = \tilde{g}_t^i + \delta_{t+1}^i, \quad \tilde{g}_{t+1} = \sum_{j=1}^N (W_{t+1})_{ij} g_{t+1}^j,$$

и, по двойной стохастичности W_{t+1} , $\tilde{g}_{t+1} = \tilde{g}_t + \bar{\delta}_{t+1}$.

Именно здесь нужно аккуратно учитывать случайность графа. Приращения δ_{t+1}^i зависят от той же матрицы W_{t+1} , потому что $\tilde{x}_{t+1} = W_{t+1}x_{t+1}$. Поэтому сжатие из предположения 5 применяется только к старому расогласованию $\tilde{g}_t^i - \tilde{g}_t$, которое измеримо перед выбором W_{t+1} . Зависимое приращение оценивается отдельно.

Положим $J_N = N^{-1}\mathbf{1}\mathbf{1}^T$ и введем две центрированные матрицы: G_t со строками $(\tilde{g}_t^i - \tilde{g}_t)^T$ и R_{t+1} со строками $(\delta_{t+1}^i - \bar{\delta}_{t+1})^T$. Для i -й строки

матрицы $G_t + R_{t+1}$ имеем

$$\begin{aligned}
(G_t + R_{t+1})_{i,:}^T &= (\tilde{g}_t^i - \tilde{g}_t) + (\delta_{t+1}^i - \bar{\delta}_{t+1}) \\
&= (\tilde{g}_t^i + \delta_{t+1}^i) - (\tilde{g}_t + \bar{\delta}_{t+1}) \\
&= g_{t+1}^i - \tilde{g}_{t+1}.
\end{aligned} \tag{5.8}$$

Поэтому для i -й строки матрицы $(W_{t+1} - J_N)(G_t + R_{t+1})$ получаем

$$\begin{aligned}
[(W_{t+1} - J_N)(G_t + R_{t+1})]_{i,:}^T &= \sum_{j=1}^N (W_{t+1})_{ij} (g_{t+1}^j - \tilde{g}_{t+1}) - \frac{1}{N} \sum_{j=1}^N (g_{t+1}^j - \tilde{g}_{t+1}) \\
&= \sum_{j=1}^N (W_{t+1})_{ij} g_{t+1}^j - \tilde{g}_{t+1} \\
&= \tilde{g}_{t+1}^i - \tilde{g}_{t+1}.
\end{aligned} \tag{5.9}$$

Здесь во втором равенстве использованы $\sum_j (W_{t+1})_{ij} = 1$ и $\sum_j (g_{t+1}^j - \tilde{g}_{t+1}) = 0$. Из (5.9) следует

$$\tilde{G}_{t+1} = (W_{t+1} - J_N)(G_t + R_{t+1}), \quad S_{t+1} = \left\| \tilde{G}_{t+1} \right\|_F.$$

Это тот же шаг добавления и вычитания среднего, что и в детерминированном доказательстве, но в стохастическом случае зависимую часть нельзя помещать под условное сжатие. Поэтому

$$S_{t+1} \leq \|(W_{t+1} - J_N)G_t\|_F + \|(W_{t+1} - J_N)R_{t+1}\|_F.$$

Строки R_{t+1} суммируются в ноль, поэтому $J_N R_{t+1} = 0$ и $(W_{t+1} - J_N)R_{t+1} = W_{t+1}R_{t+1}$. Так как W_{t+1} неотрицательна и дважды стохастична, $\|W_{t+1}\|_2 \leq \sqrt{\|W_{t+1}\|_1 \|W_{t+1}\|_\infty} = 1$, откуда $\|(W_{t+1} - J_N)R_{t+1}\|_F \leq \|R_{t+1}\|_F$. С другой стороны, G_t измерима относительно истории перед выбором W_{t+1} , и к ней применяется та же покоординатная оценка консенсусного сжатия, что в (5.5):

$$\mathbb{E} [\|(W_{t+1} - J_N)G_t\|_F \mid \mathcal{H}_{t+1}] \leq \lambda \|G_t\|_F = \lambda S_t.$$

Беря полное математическое ожидание, получаем

$$\mathbb{E}S_{t+1} \leq \lambda \mathbb{E}S_t + \mathbb{E} \|R_{t+1}\|_F. \quad (5.10)$$

Оценим второе слагаемое. Из L -гладкости

$$\|\delta_{t+1}^i\|_2 \leq L \|\tilde{x}_{t+1}^i - \tilde{x}_t^i\|_2.$$

Для time-varying графа

$$\tilde{x}_{t+1}^i = \sum_{j=1}^N (W_{t+1})_{ij} x_{t+1}^j.$$

Так как $\sum_j (W_{t+1})_{ij} = 1$, имеем

$$\begin{aligned} \|\tilde{x}_{t+1}^i - \tilde{x}_t^i\|_2 &= \left\| \sum_{j=1}^N (W_{t+1})_{ij} x_{t+1}^j - \sum_{j=1}^N (W_{t+1})_{ij} \tilde{x}_t^i \right\|_2 \\ &= \left\| \sum_{j=1}^N (W_{t+1})_{ij} \left(x_{t+1}^j - \tilde{x}_t^j + \tilde{x}_t^j - \tilde{x}_t^i \right) \right\|_2 \\ &\leq \sum_{j=1}^N (W_{t+1})_{ij} \|x_{t+1}^j - \tilde{x}_t^j\|_2 + \sum_{j=1}^N (W_{t+1})_{ij} \|\tilde{x}_t^j - \tilde{x}_t^i\|_2 \\ &\leq \gamma_t \bar{\rho} + 2 \|\tilde{E}_t\|_F. \end{aligned}$$

В последнем переходе использованы оценки

$$\|x_{t+1}^j - \tilde{x}_t^j\|_2 = \gamma_t \|v_t^j - \tilde{x}_t^j\|_2 \leq \gamma_t \bar{\rho}$$

и

$$\begin{aligned} \|\tilde{x}_t^j - \tilde{x}_t^i\|_2 &\leq \|\tilde{x}_t^j - x_{\text{avg},t}\|_2 + \|\tilde{x}_t^i - x_{\text{avg},t}\|_2 \\ &\leq 2 \|\tilde{E}_t\|_F. \end{aligned}$$

Значит, почти наверное для всех i

$$\|\delta_{t+1}^i\|_2 \leq L \left(\gamma_t \bar{\rho} + 2 \|\tilde{E}_t\|_F \right).$$

Та же верхняя граница верна для $\|\bar{\delta}_{t+1}\|_2$, поскольку $\bar{\delta}_{t+1}$ является средним векторов δ_{t+1}^i . Следовательно,

$$\|R_{t+1}\|_F = \left(\sum_{i=1}^N \|\delta_{t+1}^i - \bar{\delta}_{t+1}\|_2^2 \right)^{1/2} \leq 2\sqrt{N} L \left(\gamma_t \bar{\rho} + 2 \|\tilde{E}_t\|_F \right).$$

Поскольку $\gamma_t \leq 1$, $\tilde{x}_t^i, x_{\text{avg},t} \in D$ и $C_p \geq \sqrt{N} \bar{\rho}$, из последней оценки также следует грубая оценка

$$\mathbb{E} \|R_{t+1}\|_F \leq A_g, \quad t \geq 0.$$

Для $t \geq 1$, беря математическое ожидание и используя лемму 8, получаем более точную оценку

$$\mathbb{E} \|R_{t+1}\|_F \leq \frac{A_g}{t^\alpha}.$$

Из (5.10) и грубой оценки на R_{t+1} имеем

$$\mathbb{E} S_t \leq \mathbb{E} S_0 + t A_g, \quad t = 1, \dots, t_0.$$

Следовательно, для $1 \leq t \leq t_0$

$$\mathbb{E} S_t \leq \mathbb{E} S_0 + t_0 A_g \leq \frac{C_g}{t^\alpha}.$$

Пусть теперь $t \geq t_0$ и $\mathbb{E} S_t \leq C_g/t^\alpha$. Из определения C_g следует

$$C_g \geq \frac{A_g}{\kappa}, \quad A_g \leq \kappa C_g = (r_0 - \lambda) C_g.$$

Подставляя точную оценку на R_{t+1} в (5.10), имеем

$$\mathbb{E} S_{t+1} \leq \frac{\lambda C_g + A_g}{t^\alpha} \leq \frac{\lambda C_g + (r_0 - \lambda) C_g}{t^\alpha} \leq \frac{r_0 C_g}{t^\alpha}.$$

Так как $t \geq t_0$ и функция $s/(s+1)$ возрастает по $s > 0$, выполнено

$$r_0 = \left(\frac{t_0}{t_0 + 1} \right)^\alpha \leq \left(\frac{t}{t + 1} \right)^\alpha.$$

Следовательно,

$$\mathbb{E}S_{t+1} \leq \frac{C_g}{(t+1)^\alpha}.$$

Индукция доказана. $\square$

Теорема 10. Пусть выполнены предположения 5–6. Пусть число блоков равно n , а размер батча удовлетворяет $1 \leq B \leq n$,

$$\tau = \frac{2n}{B}, \quad \gamma_t = \frac{2n}{B(t+\tau)}.$$

На каждой итерации I_t^i выбирается условно относительно истории до выбора блоков равномерно без возвращения среди подмножеств мощности B . Для $\alpha = 1$ и $\Gamma = 2n/B$ леммы 8 и 9 дают

$$\mathbb{E} \left\| \tilde{E}_t \right\|_F \leq \frac{C_p}{t}, \quad \mathbb{E}S_t \leq \frac{C_g}{t}.$$

Здесь

$$\begin{aligned} C_p &= t_0 \frac{2n}{B} \sqrt{N} \bar{\rho}, \\ A_g &= 2\sqrt{N} L \left(\frac{2n}{B} \bar{\rho} + 2C_p \right), \\ C_g &= t_0 \mathbb{E}S_0 + t_0^2 A_g + \frac{A_g}{\frac{t_0}{t_0+1} - \lambda}, \end{aligned}$$

где t_0 удовлетворяет (5.2) при $\alpha = 1$, а S_0 – начальное рассогласование градиентного трекера из леммы 9. Тогда для любого $x^* \in \arg \min_{x \in D} f(x)$ и среднего итерата при $t \geq 1$ выполняется оценка

$$\mathbb{E}[f(x_{\text{avg},t}) - f(x^*)] \leq \frac{\tilde{A}_\tau}{t + \tau},$$

где

$$A_\tau = 3\bar{\rho}(C_g + LC_p) + \frac{L}{2}\bar{\rho}^2,$$

$$H_1 = \mathbb{E}[f(x_{\text{avg},1}) - f(x^*)], \quad \tilde{A}_\tau = \max \left\{ (\tau + 1)H_1, \frac{4A_\tau n^2}{B^2} \right\}.$$

5.10 Доказательство оценки DBCFW

Доказательство теоремы 10 можно разбить на три шага. Первый шаг связывает изменение глобальной функции в средней точке сети с усредненным направлением агентов. Так как f является средним функций f_i , она также выпукла и L -гладка. Поэтому

$$f(x_{\text{avg},t+1}) \leq f(x_{\text{avg},t}) + \langle \nabla f(x_{\text{avg},t}), x_{\text{avg},t+1} - x_{\text{avg},t} \rangle + \frac{L}{2} \|x_{\text{avg},t+1} - x_{\text{avg},t}\|_2^2.$$

Так как матрицы W_t дважды стохастичны, средняя точка после смешивания равна средней точке до смешивания:

$$\frac{1}{N} \sum_{i=1}^N \tilde{x}_t^i = \frac{1}{N} \sum_{i=1}^N x_t^i = x_{\text{avg},t}.$$

После FW-обновления

$$x_{t+1}^i = (1 - \gamma_t) \tilde{x}_t^i + \gamma_t v_t^i$$

получаем

$$x_{\text{avg},t+1} = x_{\text{avg},t} + \gamma_t (v_{\text{avg},t} - x_{\text{avg},t}), \quad v_{\text{avg},t} = \frac{1}{N} \sum_{i=1}^N v_t^i.$$

Следовательно,

$$f(x_{\text{avg},t+1}) \leq f(x_{\text{avg},t}) + \gamma_t \langle \nabla f(x_{\text{avg},t}), v_{\text{avg},t} - x_{\text{avg},t} \rangle + \frac{L\gamma_t^2}{2} \bar{\rho}^2.$$

Второй шаг оценивает, насколько $v_{\text{avg},t}$ близок к истинному FW-направлению. Главная техническая трудность состоит в том, что в DBCFW агент i решает не полный линейный оракул на D , а ограниченный оракул на D_t^i . Поэтому нельзя напрямую сравнить v_t^i с произвольной точкой $a \in D$. Для такого сравнения вводится точка $a_t^i(a)$, в которой выбранные блоки берутся из a , а остальные блоки замораживаются в смешанной

точке $\tilde{x}_t^i$:

$$a_t^i(a) \in D_t^i, \quad (a_t^i(a)) [k] = \begin{cases} a[k], & k \in I_t^i, \\ \tilde{x}_t^i[k], & k \notin I_t^i. \end{cases}$$

Из оптимальности v_t^i на суженном множестве следует

$$\langle v_t^i, \tilde{g}_t^i \rangle \leq \langle a_t^i(a), \tilde{g}_t^i \rangle, \quad a \in D.$$

Теперь сравним направление агента с истинным градиентом в средней точке. Обозначим для краткости

$$\nabla_t = \nabla f(x_{\text{avg},t}).$$

Для любого $a \in D$ имеем

$$\begin{aligned} & \langle v_t^i - x_{\text{avg},t}, \nabla_t \rangle \\ &= \langle v_t^i - x_{\text{avg},t}, \tilde{g}_t^i \rangle + \langle v_t^i - x_{\text{avg},t}, \nabla_t - \tilde{g}_t^i \rangle \\ &\leq \langle a_t^i(a) - x_{\text{avg},t}, \tilde{g}_t^i \rangle + \|v_t^i - x_{\text{avg},t}\|_2 \|\nabla_t - \tilde{g}_t^i\|_2 \\ &\leq \langle a_t^i(a) - x_{\text{avg},t}, \nabla_t \rangle + \|a_t^i(a) - x_{\text{avg},t}\|_2 \|\tilde{g}_t^i - \nabla_t\|_2 \\ &\quad + \|v_t^i - x_{\text{avg},t}\|_2 \|\nabla_t - \tilde{g}_t^i\|_2 \\ &\leq \langle a_t^i(a) - x_{\text{avg},t}, \nabla_t \rangle + 2\bar{\rho} \|\nabla_t - \tilde{g}_t^i\|_2. \end{aligned}$$

В последнем переходе используется компактность D : $\|v_t^i - x_{\text{avg},t}\|_2 \leq \bar{\rho}$ и $\|a_t^i(a) - x_{\text{avg},t}\|_2 \leq \bar{\rho}$.

Осталось оценить рассогласование градиентов. Обозначим среднее значение переменных трекинга через

$$\tilde{g}_t = \frac{1}{N} \sum_{i=1}^N \tilde{g}_t^i.$$

Также положим

$$P_t = \|\tilde{E}_t\|_F, \quad D_t = S_t.$$

Двойная стохастичность W_t и телескопическая форма градиентного тре-

кинга дают тождество

$$\tilde{g}_t = \frac{1}{N} \sum_{i=1}^N \nabla f_i(\tilde{x}_t^i).$$

Поэтому

$$\begin{aligned} \|\nabla f(x_{\text{avg},t}) - \tilde{g}_t\|_2 &\leq \|\nabla f(x_{\text{avg},t}) - \tilde{g}_t\|_2 + \|\tilde{g}_t - \tilde{g}_t^i\|_2 \\ &\leq \frac{1}{N} \sum_{j=1}^N \left\| \nabla f_j(x_{\text{avg},t}) - \nabla f_j(\tilde{x}_t^j) \right\|_2 + D_t \\ &\leq LP_t + D_t. \end{aligned}$$

Следовательно, для любого $a \in D$

$$\langle v_t^i - x_{\text{avg},t}, \nabla f(x_{\text{avg},t}) \rangle \leq \langle a_t^i(a) - x_{\text{avg},t}, \nabla f(x_{\text{avg},t}) \rangle + 2\bar{\rho}(D_t + LP_t).$$

Третий шаг использует блочную случайность. Пусть $\mathcal{F}_t$ – история после коммуникационного шага и до выбора блоков на итерации t . Если I_t^i выбирается равномерно без возвращения и $|I_t^i| = B$, то для любого фиксированного $a \in D$ и любого вектора w выполняется

$$\mathbb{E} [\langle a_t^i(a) - x_{\text{avg},t}, w \rangle \mid \mathcal{F}_t] = \frac{B}{n} \langle a - x_{\text{avg},t}, w \rangle + \left(1 - \frac{B}{n}\right) \langle \tilde{x}_t^i - x_{\text{avg},t}, w \rangle.$$

Усреднение по агентам зануляет второй член, поскольку $N^{-1} \sum_i \tilde{x}_t^i = x_{\text{avg},t}$. Берем $w = \nabla f(x_{\text{avg},t})$ и выбираем $a = x^*$. Тогда из выпуклости

$$\langle x^* - x_{\text{avg},t}, \nabla f(x_{\text{avg},t}) \rangle \leq -(f(x_{\text{avg},t}) - f(x^*)).$$

В итоге получаем условную оценку спуска

$$\mathbb{E} [\langle \nabla f(x_{\text{avg},t}), v_{\text{avg},t} - x_{\text{avg},t} \rangle \mid \mathcal{F}_t] \leq -\frac{B}{n} (f(x_{\text{avg},t}) - f(x^*)) + 2\bar{\rho}(D_t + LP_t).$$

После подстановки в гладкостную оценку и взятия полного математического ожидания получается рекурсия

$$h_{t+1} \leq \left(1 - \frac{B}{n} \gamma_t\right) h_t + 2\gamma_t \bar{\rho} \mathbb{E}[D_t + LP_t] + \frac{L}{2} \gamma_t^2 \bar{\rho}^2,$$

где

$$h_t = \mathbb{E}[f(x_{\text{avg},t}) - f(x^*)].$$

Используя оценки в математическом ожидании из лемм 8 и 9,

$$\mathbb{E}P_t \leq \frac{C_p}{t}, \quad \mathbb{E}D_t \leq \frac{C_g}{t},$$

получаем

$$h_{t+1} \leq \left(1 - \frac{B}{n}\gamma_t\right) h_t + \gamma_t \frac{2\bar{\rho}(C_g + LC_p)}{t} + \frac{L}{2}\gamma_t^2\bar{\rho}^2.$$

При выборе

$$\gamma_t = \frac{2n}{B(t + \tau)}, \quad \tau = \frac{2n}{B},$$

имеем

$$\frac{B}{n}\gamma_t = \frac{2}{t + \tau}.$$

Кроме того,

$$\frac{\gamma_t/t}{\gamma_t^2} = \frac{B(t + \tau)}{2nt} = \frac{B}{2n} + \frac{1}{t} \leq \frac{1}{2} + 1 = \frac{3}{2},$$

где использованы $B \leq n$ и $t \geq 1$. Следовательно, $\gamma_t/t \leq (3/2)\gamma_t^2$ для $t \geq 1$.

Значит, предыдущая рекурсия переходит в более удобный вид

$$h_{t+1} \leq \left(1 - \frac{B}{n}\gamma_t\right) h_t + \left[3\bar{\rho}(C_g + LC_p) + \frac{L}{2}\bar{\rho}^2\right] \gamma_t^2.$$

Обозначая

$$A_\tau = 3\bar{\rho}(C_g + LC_p) + \frac{L}{2}\bar{\rho}^2,$$

и используя $\gamma_t^2 = 4n^2/[B^2(t + \tau)^2]$, перепишем рекурсию как

$$h_{t+1} \leq \left(1 - \frac{2}{t + \tau}\right) h_t + \frac{4A_\tau n^2}{B^2(t + \tau)^2}.$$

Докажем индукцией, что

$$h_t \leq \frac{\tilde{A}_\tau}{t + \tau}, \quad \tilde{A}_\tau = \max \left\{ (\tau + 1)H_1, \frac{4A_\tau n^2}{B^2} \right\}.$$

Так как $B \leq n$, имеем $\tau \geq 2$, поэтому множитель $1 - 2/(t + \tau)$ неотрицателен

при $t \geq 1$. База при $t = 1$ следует прямо из определения $\tilde{A}_\tau$:

$$h_1 = H_1 \leq \frac{\tilde{A}_\tau}{\tau + 1}.$$

Если оценка верна для некоторого $t \geq 1$, то

$$\begin{aligned} h_{t+1} &\leq \left(1 - \frac{2}{t + \tau}\right) \frac{\tilde{A}_\tau}{t + \tau} + \frac{4A_\tau n^2}{B^2(t + \tau)^2} \\ &\leq \left(1 - \frac{2}{t + \tau}\right) \frac{\tilde{A}_\tau}{t + \tau} + \frac{\tilde{A}_\tau}{(t + \tau)^2} = \frac{\tilde{A}_\tau(t + \tau - 1)}{(t + \tau)^2}. \end{aligned}$$

Так как

$$\frac{t + \tau - 1}{(t + \tau)^2} \leq \frac{1}{t + \tau + 1},$$

получаем

$$h_{t+1} \leq \frac{\tilde{A}_\tau}{t + \tau + 1}.$$

Индукция замкнута. Так сохраняется порядок $O(1/t)$, а влияние децентрализации и батчирования переносится в константу $\tilde{A}_\tau$.

Смысл оценки состоит в том, что DBCFW сохраняет порядок $O(1/t)$ для выпуклой гладкой задачи, а нужное убывание ошибок консенсуса и отслеживания градиента обеспечивается леммами выше. Размер батча B влияет на константы: увеличение числа обновляемых блоков делает шаг ближе к полному DFW, но повышает стоимость линейного оракула.

5.11 Блочный линейный оракул

Для $D = D_1 \times \dots \times D_n$ полный линейный оракул равен

$$\arg \min_{v \in D} \langle g, v \rangle.$$

Он распадается по блокам:

$$v[k] \in \arg \min_{u \in D_k} \langle g[k], u \rangle.$$

DBCFW использует только выбранный набор I_t^i :

$$v_t^i[k] \in \begin{cases} \arg \min_{u \in D_k} \langle \tilde{g}_t^i[k], u \rangle, & k \in I_t^i, \\ \tilde{x}_t^i[k], & k \notin I_t^i. \end{cases}$$

Таким образом, невыбранные блоки не меняются в направлении оракула. После FW-шага они также остаются ближе к текущей смешанной точке:

$$x_{t+1}^i[k] = \tilde{x}_t^i[k], \quad k \notin I_t^i,$$

если записывать $v_t^i[k] = \tilde{x}_t^i[k]$.

5.12 Специальные случаи DBCFW

DBCFW содержит несколько известных схем как частные случаи. Если $N = 1$, то нет децентрализации и коммуникаций. Алгоритм превращается в стохастический блочно-координатный FW:

$$x_{t+1} = (1 - \gamma_t)x_t + \gamma_t v_t,$$

где v_t отличается от x_t только на выбранных блоках.

Если $B = n$, то каждый агент выбирает все блоки. Алгоритм превращается в DFW с градиентным отслеживанием.

Если одновременно $N = 1$ и $B = n$, то DBCFW становится классическим FW. Именно поэтому DBCFW удобно рассматривать как общий каркас:

$$\text{FW} \subset \text{BCFW} \subset \text{DBCFW}, \quad \text{DFW} \subset \text{DBCFW}.$$

5.13 Интерпретация констант в оценке

В теореме 10 константа

$$A_\tau = 3\bar{\rho}(C_g + LC_p) + \frac{L}{2}\bar{\rho}^2$$

содержит два типа ошибок. Слагаемое

$$3\bar{\rho}(C_g + LC_p)$$

отвечает за несовпадение локальных направлений с направлением, которое использовал бы централизованный алгоритм. Здесь C_g связан с ошибкой градиентного отслеживания, а LC_p возникает из-за того, что локальные точки отличаются от средней точки. Слагаемое

$$\frac{L}{2}\bar{\rho}^2$$

является обычной гладкостной ценой FW-шага.

Параметр

$$\tau = \frac{2n}{B}$$

увеличивается при малом батче. Если B мал, шаг должен быть осторожнее, потому что один оракул покрывает меньшую часть координат. Если $B = n$, то $\tau = 2$, и схема ближе к полному DFW.

5.14 Итоги раздела

DBCFW формулируется как общий метод для распределенной проекционно-свободной оптимизации на декартовых множествах. Главный алгоритмический объект – локальный блочный линейный оракул, который вызывается после смешивания точек и градиентного отслеживания. Главный теоретический результат – сохранение порядка $O(1/t)$: леммы о консенсусе и градиентном отслеживании дают нужное убывание ошибок, а теорема использует эти оценки в рекурсии спуска. Главная связь с предыдущими главами состоит в том, что стохастический выбор блоков из SOFW становится частью распределенного FW-каркаса.

5.15 Выводы по DBCFW

DBCFW завершает хронологию развития методов в этой работе. Сначала предыдущие направления использовались для ускорения FW в одной централизованной задаче. Затем CFW и NFW были перенесены на ма-

шинное обучение. После этого блочная структура позволила стохастически уменьшить стоимость линейного оракула. DBCFW объединяет блочную экономию вычислений с распределенной архитектурой, где данные и функции разделены между узлами.

Алгоритм особенно полезен в задачах, где:

1. допустимое множество имеет декартову блочную структуру;
2. линейный оракул по полному множеству слишком дорог по сравнению с блочным оракулом;
3. данные или функции распределены между несколькими агентами;
4. коммуникации между агентами ограничены сетевым графом.

Таким образом, DBCFW является естественным кандидатом для крупномасштабных распределенных задач машинного обучения и сетевой оптимизации.

6 Заключение

В работе рассмотрена последовательная линия развития алгоритма Frank–Wolfe для задач машинного обучения и крупномасштабной выпуклой оптимизации. Сначала были описаны модификации FW, использующие предыдущие направления в задаче равновесного распределения транспортных потоков. Затем эти идеи были перенесены на задачи машинного обучения, сводимые к гладкой выпуклой оптимизации на компактном множестве. После этого была рассмотрена стохастическая блочно-координатная версия, уменьшающая стоимость линейного оракула за счет обновления только части блоков. Наконец, была сформулирована децентрализованная блочно-координатная схема, объединяющая линейные оракулы, консенсус и отслеживание градиента.

Основные результаты работы:

1. Описаны CFW, BFW, FFW, WFFW и NFW как модификации FW, ускоряющие сходимость за счет памяти о предыдущих направлениях.
2. Показано, что CFW можно применять в машинном обучении без явного вычисления гессиана, используя приближение через разности градиентов.
3. Приведена оценка сходимости CFW по зазору Frank–Wolfe, совпадающая по порядку со стандартной оценкой FW.
4. Описан SOFW/BCFW как блочно-координатный метод для транспортных сетей, уменьшающий стоимость итерации за счет стохастического выбора источников.
5. Сформулирован DBCFW. Это децентрализованное расширение блочного FW с градиентным отслеживанием.

6.1 Итоги по главам

В первой главе было показано, что основная слабость классического FW в транспортной задаче связана не с линейным оракулом, а с геометрией направления. CFW, BFW и NFW используют прошлые направления

для уменьшения зигзагообразного поведения, а FFW и WFFW решают похожую задачу через сглаживание. Экспериментальные результаты показывают, что память о нескольких направлениях может существенно ускорять уменьшение относительного зазора.

Во второй главе эта идея была перенесена в машинное обучение. Ключевой технический шаг состоит в отказе от явного гессиана. Вместо произведения $\nabla^2 f(x_k)d_{k-1}$ используется разность соседних градиентов. Благодаря этому CFW и NFW становятся применимыми к логистической регрессии с ограничением на l_1 -норму. Эксперименты на Mushrooms и MNIST показывают, что выигрыш особенно заметен, когда безусловное решение находится далеко от границы допустимого множества.

В третьей главе основное внимание было перенесено с направления на стоимость итерации. SOFW обновляет только часть источников транспортной сети и тем самым уменьшает стоимость линейного оракула. Теоретически метод соответствует блочно-координатному FW и сохраняет стандартный порядок сходимости в ожидании. Практически же он выигрывает на крупных сетях, где полный запуск кратчайших путей становится главной вычислительной нагрузкой.

В четвертой главе блочная идея была соединена с децентрализованной оптимизацией. DBCFW сохраняет механизм консенсуса и градиентного отслеживания из DFW, но заменяет полный линейный оракул блочным. Если выбрать все блоки, метод возвращается к обычному DFW. Если убрать децентрализацию, получается блочный FW. Поэтому DBCFW является естественным завершающим звеном рассматриваемой хронологии.

6.2 Ограничения и дальнейшая работа

Ограничение рассмотренной линии методов состоит в том, что каждая модификация улучшает свой вычислительный аспект: направление шага, стоимость линейного оракула или распределенную архитектуру. Единый метод, который одновременно использует сопряженные направления, стохастический выбор блоков и децентрализованный консенсус, остается отдельной исследовательской задачей. Перспективным направлением является объединение стохастического выбора блоков с сопряженными направлениями NFW, а также экспериментальная проверка DBCFW на рас-

пределенных задачах машинного обучения.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Frank M., Wolfe P. An algorithm for quadratic programming // Naval Research Logistics Quarterly. 1956. Vol. 3. No. 1–2. P. 95–110.
- [2] Jaggi M. Revisiting Frank–Wolfe: Projection-Free Sparse Convex Optimization // Proceedings of the 30th International Conference on Machine Learning. 2013. Vol. 28. P. 427–435.
- [3] Braun G., Pokutta S., Tu S., Wright S. Blended conditional gradients: the unconditioning of conditional gradients // SIAM Journal on Optimization. 2022.
- [4] Patriksson M. The Traffic Assignment Problem: Models and Methods. Dover Publications, 2015.
- [5] Mitradjieva M., Lindberg P. O. The Stiff Is Moving: Conjugate Direction Frank–Wolfe Methods with Applications to Traffic Assignment // Transportation Science. 2013. Vol. 47. No. 2. P. 280–293.
- [6] Fukushima M. A modified Frank–Wolfe algorithm for solving the traffic assignment problem // Transportation Research Part B: Methodological. 1984. Vol. 18. No. 2. P. 169–177.
- [7] Arrache S., Ouafi R. Accelerating Convergence of the Frank–Wolfe Algorithm for Solving the Traffic Assignment Problem // International Journal of Computer Science and Network Security. 2008. Vol. 8. No. 5. P. 181–186.
- [8] Игнашин И. Н., Ярмошик Д. В. Модификации алгоритма Frank–Wolfe в задаче поиска равновесного распределения транспортных потоков // Компьютерные исследования и моделирование. 2024. Т. 16. No. 1. С. 53–68. DOI: <https://doi.org/10.20537/2076-7633-2024-16-1-53-68>.
- [9] Stabler B. Transportation Networks for Research Core Team. TransportationNetworks repository. URL: <https://github.com/bstabler/TransportationNetworks>.

- [10] Jaggi M., Lacoste-Julien S., Schmidt M. Block-Coordinate Frank–Wolfe Optimization for Structural SVMs // Proceedings of the 30th International Conference on Machine Learning. 2013.
- [11] Lacoste-Julien S., Jaggi M., Schmidt M., Pletscher P. Block-Coordinate Frank–Wolfe Optimization for Structural SVMs // Proceedings of the 30th International Conference on Machine Learning. 2013. P. 53–61.
- [12] Ignashin I., Yarmoshik D., Raigorodskii A. Stochastic Origin Frank–Wolfe Method for Traffic Assignment // Journal of Mathematical Sciences. 2025. Vol. 295. No. 2. P. 170–184. DOI: <https://doi.org/10.1007/s10958-025-08157-6>.
- [13] Wai H.-T., Lafond J., Scaglione A., Moulines E. Decentralized Frank–Wolfe Algorithm for Convex and Nonconvex Problems // IEEE Transactions on Automatic Control. 2017. Vol. 62. No. 11. P. 5522–5537.
- [14] Vedernikov R., Rogozin A., Gasnikov A. Decentralized Conditional Gradient Method over Time-Varying Graphs // arXiv preprint arXiv:2307.10978. 2023.
- [15] Beckmann M., McGuire C. B., Winsten C. B. Studies in the Economics of Transportation. Yale University Press, 1956.
- [16] Wardrop J. G. Some theoretical aspects of road traffic research // Proceedings of the Institution of Civil Engineers. 1952. Vol. 1. No. 3. P. 325–362.
- [17] Bureau of Public Roads. Traffic Assignment Manual. U.S. Department of Commerce, Urban Planning Division, 1964.
- [18] Sheffi Y. Urban Transportation Networks: Equilibrium Analysis with Mathematical Programming Methods. Prentice-Hall, 1985.
- [19] LeBlanc L. J., Morlok E. K., Pierskalla W. P. An improved method for the solution of the transportation network equilibrium problem // Transportation Science. 1975. Vol. 9. No. 4. P. 309–318.

- [20] Luenberger D. G. Linear and Nonlinear Programming. Addison-Wesley, 1984.
- [21] Bertsekas D. P. Nonlinear Programming. Athena Scientific, 1999.
- [22] Nesterov Y. A method for solving the convex programming problem with convergence rate $O(1/k^2)$ // Soviet Mathematics Doklady. 1983. Vol. 27. No. 2. P. 372–376.
- [23] Nesterov Y. Lectures on Convex Optimization. Springer, 2018.
- [24] Pedregosa F., Negiar G., Askari A., Jaggi M. Linearly convergent Frank–Wolfe with backtracking line-search // Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics. 2020. P. 1–10.
- [25] Pearlmutter B. A. Fast exact multiplication by the Hessian // Neural Computation. 1994. Vol. 6. No. 1. P. 147–160.
- [26] Bradbury J., Frostig R., Hawkins P., Johnson M. J., Leary C., Maclaurin D., Wanderman-Milne S. JAX: composable transformations of Python+NumPy programs. 2018. URL: <https://github.com/google/jax>.
- [27] LeCun Y., Cortes C., Burges C. The MNIST database of handwritten digits. 1998. URL: <http://yann.lecun.com/exdb/mnist/>.
- [28] Dua D., Graff C. UCI Machine Learning Repository. University of California, Irvine, School of Information and Computer Sciences, 2019.
- [29] Tibshirani R. Regression shrinkage and selection via the lasso // Journal of the Royal Statistical Society: Series B. 1996. Vol. 58. No. 1. P. 267–288.