

Стохастическая оптимизация в равновесных и минимаксных задачах

И. Н. Игнашин

Московский физико-технический институт

Научный руководитель: к.ф.-м.н. Грабовой А. В.

Научный консультант: Ярмошик Д. В.

2025

Исследуется применение стохастических методов оптимизации к задачам минимизации функций на выпуклых множествах, а также к минимаксным задачам.

Цель исследования:

Разработка и теоретический анализ стохастических алгоритмов для задач выпуклой минимизации на сложных множествах и невыпуклых минимаксных задач с контролируемой стохастической сложностью.

Результаты:

- ▶ предложен стохастический линейный минимизационный оракул (lmo) для задач минимизации на выпуклых множествах, используемый в алгоритмах типа Frank–Wolfe с пониженной вычислительной стоимостью;
- ▶ получена оценка на сходимость для данной стохастической модификации Frank-Wolfe
- ▶ получены теоретические гарантии для алгоритма ALSO для невыпукло–сильно вогнутых минимаксных задач.

Stochastic Origin Frank–Wolfe

- ▶ Постановка задачи равновесного распределения потоков
- ▶ Стохастический оракул линейной минимизации
- ▶ Улучшенная теорема сходимости

ALSO: невыпукло–сильно вогнутая постановка

- ▶ Min–max формулировка
- ▶ Сильная вогнутость по весам
- ▶ Теоретические гарантии

Мотивация и постановка задачи

Рассматривается классическая задача поиска **равновесного распределения потоков** в транспортной сети.

Обозначения:

- ▶ $\mathcal{E}$ — рёбра транспортного графа,
- ▶ OD — множество пар источник–сток,
- ▶ $\mathcal{P}_{i,j}$ — множество путей между (i,j) ,
- ▶ x_p — поток по пути p ,
- ▶ $f_e = \sum_p x_p \delta_{e \in p}$ — поток по ребру,
- ▶ $\tau_e(f_e)$ — функция времени проезда.

Принцип Вардропы: каждый агент выбирает маршрут с минимальными индивидуальными затратами.

Эквивалентная оптимизационная задача

Поиск равновесия эквивалентен решению выпуклой задачи Бекмана:

$$\min_{f=\Theta x, x \in X} \Psi(f) = \sum_{e \in \mathcal{E}} \int_0^{f_e} \tau_e(z) dz$$

где

$$X = \left\{ x \geq 0 : \sum_{p \in \mathcal{P}_{i,j}} x_p = d_{i,j}, \quad \forall (i,j) \in OD \right\}.$$

Следствие: задача решается методом Frank–Wolfe, где линейный оракул соответствует поиску кратчайших путей.

Stochastic Origin Frank–Wolfe

Рассматривается задача минимизации выпуклой функции $\Psi(f)$ на выпуклом множестве $\mathcal{F} = \{f = \Theta x \mid x \in \mathcal{X}\}$, решаемая методом Frank–Wolfe.

Классический LMO: на каждой итерации требуется решить

$$\arg \min_{s \in \mathcal{F}} \langle \nabla \Psi(f_k), s \rangle,$$

что эквивалентно поиску кратчайших путей для *всех* корреспонденций $(i, j) \in OD$.

Stochastic Origin FW (SOFW): на каждой итерации случайно выбирается подмножество блоков $\mathcal{I}_k \subset OD$, и линейная минимизация выполняется *только* на соответствующем подпространстве, в то время как остальные блоки фиксируются.

Полученное направление масштабируется с помощью importance-weighted нормировки, что даёт **несмещённую стохастическую аппроксимацию** классического Frank–Wolfe направления.

Метод является частным случаем **Block-Coordinate Frank–Wolfe** и допускает batched-реализацию.

Сходимость Stochastic Origin Frank–Wolfe

Рассматривается выпуклая задача минимизации функционала $\Psi(f)$ на множестве $\mathcal{F} = \{f = \Theta x \mid x \in \mathcal{X}\}$.

Предположения:

- ▶ функции задержек $\tau_e(\cdot)$ монотонны и липшицевы;
- ▶ функционал Бекмана $\Psi(f) = \sum_{e \in \mathcal{E}} \int_0^{f_e} \tau_e(z) dz$ выпуклый и дифференцируемый;
- ▶ используется несмещённый block-coordinate линейный оракул.

Обозначения: f_k — итерации алгоритма, f^* — оптимальное решение,

$$C_{\Psi}^{\otimes} = \sum_{(i,j) \in OD} C_{\Psi}^{(i,j)}.$$

— суммарная block-кривизна.

Теорема(Игнашин): Сходимость SOFW

При выборе шага

$$\gamma_k = \frac{2}{k + 2|OD|}$$

для математического ожидания субоптимальности выполняется оценка

$$\mathbb{E}[\Psi(f_k)] - \Psi(f^*) \leq \frac{2|OD|}{k + 2|OD|} (C_{\Psi}^{\otimes} + \Psi(f_0) - \Psi(f^*)).$$

Min-max постановка

Рассматривается задача вида:

$$\min_{\theta \in \mathbb{R}^d} \max_{\pi \in \mathcal{U}} h(\theta, \pi),$$

где

$$h(\theta, \pi) = \sum_{i=1}^c \pi_i \left(\frac{c}{n} \sum_{j=1}^{n_i} f_{i,j}(\theta) \right) + \frac{\tau}{2} \|\theta\|_2^2 - \lambda \text{KL}[\pi \| \hat{\pi}].$$

Свойства:

- ▶ функция $h(\theta, \pi)$ может быть невыпуклой по θ ;
- ▶ функция $h(\theta, \pi)$ является λ -сильно вогнутой по π за счёт KL-регуляризации.

Алгоритм ALSO: две ключевые операции

Рассматривается $\Phi(\theta) = \max_{\pi \in D_\pi} h(\theta, \pi)$. ALSO чередует:

- ▶ стохастический адаптивный шаг по θ (Adam) по градиенту $\nabla_\theta h(\theta^k, \pi^k)$;
- ▶ mirror/прох-обновление по π с KL-геометрией (шаг по $\nabla_\pi h$ и KL-регуляризатору).

$$\theta^{k+1} = \theta^k - \gamma_\theta \text{Adam}\left(g_\theta^k; \beta_1, \beta_2, \varepsilon\right), \quad g_\theta^k \approx \nabla_\theta h(\theta^k, \pi^k).$$

$$\pi^{k+1} = \arg \min_{\pi \in D_\pi} \left\{ \gamma_\pi \left\langle g_\pi^k + \lambda \log \frac{\pi}{\hat{\pi}}, \pi \right\rangle + \text{KL}[\pi \| \pi^k] \right\}, \quad g_\pi^k \approx \nabla_\pi h(\theta^k, \pi^k).$$

Основная теорема сходимости ALSO: постановка и итоговая оценка

Theorem 4.5 (в статье): ε -стационарность по θ

Пусть выполнены Assumptions 4.1–4.3. Тогда для задачи (4) метод ALSO (Algorithm 1) при подходящем выборе гиперпараметров достигает ε -стационарности

$$\mathbb{E} \|\nabla \Phi(\theta^t)\|_2^2 \leq \varepsilon^2$$

за

$$T = O\left(\frac{L^4}{\lambda^4 \varepsilon^2} \cdot \max\{\Delta_\Phi \cdot (K + \sigma), D_0\}\right) \text{ итераций.}$$

Обозначения (минимально): $\Delta_\Phi = \Phi(\theta^0) - \min_\theta \Phi(\theta)$,
 $D_0 = \text{KL}(\pi^*(\theta^0) \|\pi^0)$, L, K — константы гладкости/гетерогенности в статье,
 σ — дисперсия стохастического оракула, $B = O(\sigma^2/\varepsilon^2)$.

Следствие: при $B = O(1/\varepsilon^2)$ суммарная стохастическая сложность становится $O(1/\varepsilon^4)$.

Результаты, выносимые на защиту

Получены следующие результаты:

1. Получена теоретическая оценка сходимости стохастического алгоритма минимизации на выпуклом множестве с использованием линейного оракула, а также расширено доказательство на batched-версию алгоритма Block-Coordinate Frank–Wolfe.
2. Получена теоретическая оценка сходимости стохастического алгоритма для невыпукло- μ -сильно вогнутой минимаксной постановки, усиливающая ранее известные результаты для случая простой вогнутости.

Публикации и выступления на конференциях:

1. ALSO: NeurIPS Workshop OPT/OPT-ML, 2025 (принято).
2. Stochastic Origin Frank–Wolfe: доклад на конференции TFN-2025 (Traffic Flows on Networks, Sirius); публикация в *Journal of Mathematical Sciences, Series B*.

Публикации и связанные работы

Основные публикации автора:

1. I. Ignashin, D. Yarmoshik, A. Raigorodskii. *Stochastic Origin Frank–Wolfe for Traffic Assignment*. arXiv:2509.23840, 2025.
2. D. Feoktistov, I. Ignashin, A. Veprikov, N. Borovko, A. Bogdanov, S. Chezhegov, A. Beznosikov. *Aligning Distributionally Robust Optimization with Practical Deep Learning Needs*. arXiv:2508.16734, 2025.

Связанные публикации автора:

1. I. Ignashin, D. Yarmoshik. *Modifications of the Frank–Wolfe Algorithm in the Problem of Finding an Equilibrium Distribution of Traffic Flows*. arXiv:2403.04863, 2024.
2. D. Yarmoshik, I. Ignashin, E. Sikacheva, A. Gasnikov. *Modeling Skiers Flows via Wardrop Equilibrium in Closed Capacitated Networks*. arXiv:2509.13392, 2025.

Принятые к публикации работы:

1. I. Ignashin, D. Yarmoshik. *Conjugate Frank–Wolfe in Machine Learning*. В печати: *Communications in Computer and Information Science (CCIS, Springer)*, Proceedings of OPTIMA–2024.

Связанные работы:

1. D. Bylinkin, M. Aleksandrov, S. Chezhegov, A. Beznosikov.
Enhancing Stability of Physics-Informed Neural Network Training Through Saddle-Point Reformulation.
arXiv:2507.16008, 2025.
2. S. Lacoste-Julien, M. Jaggi, M. Schmidt, P. Pletscher.
Block-Coordinate Frank-Wolfe Optimization for Structural SVMs. Proceedings of the International Conference on Machine Learning (ICML), 2013.