

Алгоритм Frank–Wolfe в задачах машинного обучения

Игорь Николаевич Игнашин
Научный руководитель: к. ф.-м. н. А. О. Грабовой

Кафедра интеллектуальных систем ФПМИ МФТИ
Специализация: Интеллектуальный анализ данных

Москва, 2026

Положения, выносимые на защиту

1. Систематизированы модификации Frank–Wolfe по трем направлениям: использование предыдущих направлений, стохастические LMO на примере SOFW и расширение на децентрализованную постановку.
2. Для модели Бекмана предложены NFW как обобщение CFW/BFW на N прошлых направлений и WFFW как модификация FFW с экспоненциальным сглаживанием.
3. CFW и NFW перенесены на ML-задачи без явного гессиана: кривизна аппроксимируется разностями градиентов.
4. Для CFW доказана оценка по минимальному зазору Frank–Wolfe того же порядка, что у базового FW.
5. Предложен SOFW как частный случай BCFW для транспортной задачи с блоками по OD-парам; доказана оценка ожидаемой сходимости для одиночного и батчевого выбора блоков.
6. Предложен DBCFW: децентрализованный блочно-координатный FW с консенсусом и отслеживанием градиента; получена оценка сходимости порядка $O(1/t)$.

Постановка задачи

Рассматривается гладкая выпуклая задача на компактном выпуклом множестве:

$$f(x) \rightarrow \min_{x \in \mathcal{X}}.$$

Метод Frank–Wolfe заменяет проекцию линейным оракулом:

$$s_k^{FW} \in \arg \min_{s \in \mathcal{X}} \langle \nabla f(x_k), s \rangle, \quad d_k^{FW} = s_k^{FW} - x_k,$$

$$x_{k+1} = x_k + \gamma_k d_k^{FW}, \quad \gamma_k \in [0, 1].$$

Основной вопрос

Как сохранить проекционно-свободную структуру FW и ускорить практическую сходимость за счет направления, стохастического LMO и распределенной архитектуры?

Качество итерации измеряется зазором

$$g_k = \langle \nabla f(x_k), x_k - s_k^{FW} \rangle.$$

Транспортная модель Бекмана


Для дорожной сети поток по ребрам $f = \Theta x$ находится из задачи

$$\Psi(f) = \sum_{e \in \mathcal{E}} \int_0^{f_e} \tau_e(z) dz \rightarrow \min_{f = \Theta x, x \in X}, \quad \nabla \Psi(f) = \tau(f).$$

Допустимое множество имеет блочную структуру по OD-парам:

$$X = \prod_{w \in OD} X^w, \quad X^w = \left\{ x^w : \sum_{p \in \mathcal{P}_w} x_p = d_w, x_p \geq 0 \right\}.$$

Линейный оракул сводится к поиску кратчайших путей для OD-пар.



Модификации направления Frank–Wolfe

Классический FW использует только текущий оракул s_k^{FW} . Модификации добавляют память о предыдущих направлениях.

Conjugate Frank–Wolfe

$$s_k = \alpha s_k^{FW} + (1 - \alpha)s_{k-1}, \quad (d^{k-1})^\top \nabla^2 \Psi(f^k) d^k = 0.$$

N-conjugate Frank–Wolfe

$$s_k = \alpha_0 s_k^{FW} + \sum_{j=1}^N \alpha_j s_{k-j}, \quad (d^k)^\top \nabla^2 \Psi(f^k) d^{k-j} = 0.$$


Fukushima и Weighted Fukushima FW

$$s_k = \alpha_0 s_k^{FW} + (1 - \alpha_0) \sum_{j=1}^N w_j s_{k-j}, \quad w_j \propto (1 - \eta) \eta^{j-1}.$$

В модели Бекмана $\nabla^2 \Psi(f)$ диагонален, поэтому коэффициенты направлений вычисляются дешево.

Транспортные сети: эффект памяти о направлениях

Сходимость относительного зазора на разных городах



NFW с памятью о нескольких направлениях часто уменьшает относительный зазор быстрее BFW и отдельных вариантов FW.

Выигрыш особенно заметен после первых итераций, когда базовый FW начинает зигзагообразное движение.

CFW в задачах машинного обучения

В ML-задачах явный гессиан часто слишком дорогой. Поэтому произведение гессиана на предыдущее направление заменяется разностью градиентов:

$$\nabla^2 f(x_k)(s_{k-1} - x_{k-1}) \approx \frac{\nabla f(x_k) - \nabla f(x_{k-1})}{\gamma_{k-1}}.$$

После сокращения γ_{k-1} коэффициент CFW вычисляется как

$$\alpha = \frac{(x_k - s_{k-1})^\top (\nabla f(x_k) - \nabla f(x_{k-1}))}{(s_k^{FW} - s_{k-1})^\top (\nabla f(x_k) - \nabla f(x_{k-1}))}.$$

Экспериментальная постановка

Логистическая регрессия на Mushrooms и MNIST:

$$\|w\|_1 \leq R, \quad f(w) = \text{logloss}(w) + \frac{\lambda}{2} \|w\|_2^2.$$

Теорема 1. Сходимость CFW


Теорема 1 (Оценка по зазору Frank–Wolfe)

Пусть $\mathcal{X} \subset \mathbb{R}^d$ выпукло и компактно, f выпукла, непрерывно дифференцируема и имеет L -липшицев градиент на $\mathcal{X}$. Тогда для CFW с параметром $\alpha_0 \in (0, 1]$

$$g_N^* = \min_{1 \leq k \leq N} g_k \leq \frac{\max\{2h_0, LR^2\}}{\alpha_0 \sqrt{N+1}}, \quad h_0 = f(x_0) - f(x^*).$$

Оценка сохраняет порядок классического FW по минимальному зазору; отличие входит через контролируемый параметр α_0 .

LIBSVM.



SOFW как BCFW в транспортной задаче

Предложен SOFW как частный случай BCFW для транспортной задачи с блочной структурой по OD-парам. Полный LMO требует запускать кратчайшие пути для всех блоков, а SOFW обновляет только случайный блок:

$$w_k \sim \text{Unif}(OD), \quad s_k^{[w_k]} \in \arg \min_{u \in X^{w_k}} \left\langle \nabla \Psi(F(x_k)), F(u^{[w_k]}) \right\rangle.$$

$$x_{k+1} = x_k + \gamma_k (s_k^{[w_k]} - x_k^{[w_k]}).$$

Батчевый вариант выбирает подмножество $\mathcal{I}_k$ размера m :

$$d_k = \frac{1}{m} \sum_{w \in \mathcal{I}_k} (s_k^{[w]} - x_k^{[w]}).$$

Компромисс

Полный FW дает более точное направление, но дорогую итерацию. SOFW как BCFW для транспортной сети уменьшает стоимость итерации и выигрывает по времени на крупных графах.

Теорема 2. Оценка SOFW

Теорема 2 (Сходимость батчевого SOFW)


Пусть $\{x_k\}$ порождается батчевым SOFW, $|OD|$ – число блоков, а

$$\gamma_k = \frac{2|OD|}{k + 2|OD|}.$$

Тогда

$$\mathbb{E}[\Psi(F(x_k))] - \Psi(F(x^*)) \leq \frac{2|OD|}{k + 2|OD|} [C_{\Psi}^{\otimes} + \Psi(F(x_0)) - \Psi(F(x^*))].$$

Для достижения ε -точности в ожидании достаточно $\mathcal{O}(|OD|/\varepsilon)$ итераций.



DVCFW: блочный FW в распределенной оптимизации

Распределенная задача:

$$f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x) \rightarrow \min_{x \in D_1 \times \dots \times D_n}.$$

Агент i смешивает точки и оценки градиента:

$$\tilde{x}_t^i = \sum_{j=1}^N (W_t)_{ij} x_t^j, \quad g_t^i = \tilde{g}_{t-1}^i + \nabla f_i(\tilde{x}_t^i) - \nabla f_i(\tilde{x}_{t-1}^i),$$

$$\tilde{g}_t^i = \sum_{j=1}^N (W_t)_{ij} g_t^j.$$

Затем выбирается батч блоков I_t^i и суженное множество

$$D_t^i = \left(\prod_{k \in I_t^i} D_k \right) \times \left(\prod_{k \notin I_t^i} \{\tilde{x}_t^i[k]\} \right),$$

Блочный LMO:

$$v_t^i \in \arg \min_{v \in D_t^i} \langle \tilde{g}_t^i, v \rangle, \quad x_{t+1}^i = (1 - \gamma_t) \tilde{x}_t^i + \gamma_t v_t^i.$$

Теорема 3. Сходимость DBCFW


Теорема 3 (Оценка для среднего итерата)

Пусть выполнены условия смешивания, гладкости и ограниченности области.
Пусть число блоков равно n , размер батча $1 \leq B \leq n$,

$$\tau = \frac{2n}{B}, \quad \gamma_t = \frac{2n}{B(t + \tau)}.$$

Если консенсусная ошибка и ошибка градиентного отслеживания убывают как $O(1/t)$, то

$$\mathbb{E}[f(x_{\text{avg},t}) - f(x^*)] \leq \frac{\tilde{A}_\tau}{t + \tau}.$$



Если $B = n$, DBCFW переходит в DFW; без децентрализации остается блочный FW.

Личный вклад автора

- ▶ **Систематизация.** Модификации FW представлены как единая линия проекционно-свободных методов для транспортных, ML и распределенных задач.
- ▶ **Методы.** Предложены NFW и WFFW как расширения BFW и FFW; предложены SOFW для транспортных OD-блоков и DBCFW для распределенной блочной оптимизации.
- ▶ **Теория.** Доказаны оценка CFW по зазору Frank–Wolfe, оценка ожидаемой сходимости SOFW и оценка $O(1/t)$ для DBCFW.
- ▶ **Эксперименты.** Проведено сравнение FW-модификаций на транспортных сетях, Mushrooms и MNIST; показаны выигрыш алгоритмов, использующих предыдущие направления, и trade-off между качеством шага и вычислительной сложностью стохастического блочно-координатного LMO.

Спасибо за внимание!

Готов ответить на вопросы.