

Приложения алгоритма Франк-Вульфа к задачам машинного обучения

Игнашин Игорь Николаевич

Научный руководитель: д.ф.-м.н. Грабовой А. О.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

Москва — 2026

Приложения алгоритма Frank–Wolfe к задачам машинного обучения

Цель исследования

Развить и теоретически обосновать модификации Frank–Wolfe для задач, где стоимость линейного оракула, выбора направления или коммуникации определяет практическую эффективность метода.

Задача

Требуется сохранить проекционно-свободную структуру Frank–Wolfe, но уменьшить вычислительную стоимость итерации для гладких ML-задач, транспортных сетей и распределенной оптимизации.

Методы решения

1. Использовать память о предыдущих направлениях в CFW/NFW.
2. Использовать случайный выбор блоков линейного оракула в SOFW.
3. Объединить блочные обновления с консенсусом и gradient tracking в DBCFW.

Постановка задачи

Рассматривается гладкая задача условной оптимизации

$$\min_{x \in \mathcal{X}} f(x),$$

где множество $\mathcal{X}$ допускает эффективную линейную минимизацию, но евклидова проекция может быть дорогой.

Шаг Frank–Wolfe

$$s_k \in \arg \min_{s \in \mathcal{X}} \langle \nabla f(x_k), s \rangle, \quad x_{k+1} = x_k + \gamma_k (s_k - x_k).$$

Вычислительные ограничения

- ▶ геометрия траектории может давать зигзагообразные направления;
- ▶ полный линейный оракул дорог на больших блочных множествах;
- ▶ данные и функции могут быть распределены между агентами сети.

Схема методов и результатов

В работе рассматриваются три способа ускорить разные части итерации Frank–Wolfe.

Ограничение	Метод	Результат
выбор направления	CFW/NFW	$g_N^* = O(N^{-1/2})$
полный линейный оракул	SOFW	$O(1/k)$ в ожидании
коммуникации + LMO	DBCFW	$O(1/t)$ для $x_{\text{avg},t}$

Дальше каждый блок излагается в одинаковом порядке:

постановка $\rightarrow$ метод $\rightarrow$ теоретический результат $\rightarrow$ проверка и обсуждение.

CFW и NFW: память о направлениях

В CFW новое направление строится как комбинация текущего FW-направления и предыдущего направления:

$$d_k = \alpha d_k^{FW} + (1 - \alpha)(1 - \gamma_{k-1})d_{k-1}.$$

Что это дает

- ▶ направление учитывает локальную геометрию траектории;
- ▶ NFW обобщает эту идею на несколько прошлых направлений;
- ▶ для ML-задач произведение на гессиан заменяется конечными разностями градиентов.

$$\nabla^2 f(x_k)d_{k-1} \approx \nabla f(x_k) - \nabla f(x_{k-1}).$$

Теоретический результат для CFW

Условия и зазор

Пусть $\mathcal{X}$ выпукло и компактно, f выпукла и имеет L -липшицев градиент.

$$g_k = \left\langle \nabla f(x_k), x_k - s_k^{FW} \right\rangle.$$

Теорема 1

Для CFW с параметром $\alpha_0 \in (0, 1]$ и точным линейным поиском


$$g_N^* = \min_{1 \leq k \leq N} g_k \leq \frac{\max\{2h_0, LR^2\}}{\alpha_0 \sqrt{N+1}}.$$

Обозначения

- ▶ s_k^{FW} – решение линейного оракула;
- ▶ g_k – зазор Frank–Wolfe;
- ▶ g_N^* – лучший зазор за N итераций.
- ▶ $h_0 = f(x_0) - f(x^*)$ – начальная ошибка;
- ▶ $R = \max_{x, y \in \mathcal{X}} \|x - y\|_2$ – диаметр $\mathcal{X}$;
- ▶ L, α_0 – гладкость и нижний вес FW-направления.

Эксперименты в машинном обучении

Рассматривалась логистическая регрессия с ограничением на l_1 -норму. Сравнивались FW, FW с линейным поиском, CFW и NFW.



CFW/NFW особенно полезны, когда активное ограничение создает зигзагообразное поведение базового FW.

SOFW: блочный оракул для транспортных сетей

В модели Бекмана допустимое множество имеет блочную структуру по OD-парам или источникам. Полная итерация FW требует решать задачи кратчайших путей для всех источников.

$$\mathcal{C}_{FW} = \mathcal{O}(n(E + V \log V)).$$

Stochastic Origin Frank–Wolfe

На каждой итерации выбирается только часть блоков, и линейный оракул решается для выбранных источников:

$$\mathcal{C}_{SOFW} = \mathcal{O}(\alpha n(E + V \log V)).$$

Цена ускорения: нужно хранить разложение потока по источникам и учитывать дисперсию стохастического направления.

Теоретический результат для SOFW

Батчевое направление

SOFW строит направление по случайному подмножеству блоков $\mathcal{I}_k$:

$$d_k = \frac{1}{m} \sum_{w \in \mathcal{I}_k} (s_k^{[w]} - x_k^{[w]}).$$

Теорема 2

$$\gamma_k = \frac{2|OD|}{k + 2|OD|},$$


$$\mathbb{E}[\Psi(F(x_k))] - \Psi(F(x^*)) \leq \frac{2|OD|}{k + 2|OD|} (C_{\Psi}^{\otimes} + \Psi(F(x_0)) - \Psi(F(x^*))).$$

Обозначения

- ▶ OD – пары источник–сток, то есть блоки;
- ▶ $\mathcal{I}_k$, m – случайный батч и его размер;
- ▶ $s_k^{[w]}$, $x_k^{[w]}$ – ЛМО и текущая точка в блоке w .
- ▶ $F(x)$ – переход от OD-потоков к реберным;
- ▶ Ψ , x^* – потенциал Бекмана и оптимум;
- ▶ $C_{\Psi}^{\otimes}$ – суммарная блочная кривизна.

SOFW: вычислительный эффект

Датасет Philadelphia: 1525 зон, 40003 ребра, 13389 узлов.



На крупных сетях стохастический оракул быстрее уменьшает относительный зазор при одинаковом вычислительном бюджете.

DBCFW: распределенная постановка

Пусть есть N агентов, и агент i знает только локальную функцию f_i :

$$\min_{x \in D} f(x), \quad f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x), \quad D = D_1 \times \dots \times D_n.$$

Децентрализация

- ▶ локальная копия x_t^i ;
- ▶ обмен только с соседями;
- ▶ матрица смешивания W_t .

Блочность

- ▶ выбирается батч блоков I_t^i ;
- ▶ LMO решается на D_t^i ;
- ▶ стоимость зависит от размера батча.

На каждой итерации агент выполняет три шага.

1. Консенсус по точкам

$$\tilde{x}_t^i = \sum_j (W_t)_{ij} x_t^j.$$

2. Отслеживание градиента

$$g_t^i = \tilde{g}_{t-1}^i + \nabla f_i(\tilde{x}_t^i) - \nabla f_i(\tilde{x}_{t-1}^i), \quad \tilde{g}_t^i = \sum_j (W_t)_{ij} g_t^j.$$

3. Блочный линейный оракул

$$v_t^i \in \arg \min_{v \in D_t^i} \langle \tilde{g}_t^i, v \rangle, \quad x_{t+1}^i = (1 - \gamma_t) \tilde{x}_t^i + \gamma_t v_t^i.$$

Теоретический результат для DBCFW

Средняя точка сети

При гладкости, выпуклости, компактности D и сжатии коммуникационной ошибки:

$$h_t = \mathbb{E}[f(x_{\text{avg},t}) - f(x^*)].$$

Теорема 3

$$\begin{aligned} \gamma_t &= \frac{2n}{B(t + \tau)}, & \tau &= \frac{2n}{B}, \\ h_t &\leq \frac{\tilde{A}_\tau}{t + \tau}, & \mathbb{E}[f(x_{\text{avg},t}) - f(x^*)] &= O(1/t). \end{aligned}$$

Обозначения

- ▶ N – число агентов сети;
- ▶ n – число блоков в $D = D_1 \times \dots \times D_n$;
- ▶ B – размер батча блоков для LMO;
- ▶ $x_{\text{avg},t} = \frac{1}{N} \sum_i x_t^i$ – средняя точка.
- ▶ h_t – ожидаемая ошибка по функции;
- ▶ $\tau = 2n/B$ – сдвиг шага из-за батча;
- ▶ $\tilde{A}_\tau$ – константа ошибок консенсуса, tracking и LMO.

Выносятся на защиту

1. Модификации CFW и NFW перенесены на гладкие задачи машинного обучения без явного вычисления гессиана.
2. Для CFW доказана оценка по зазору Frank–Wolfe:

$$g_N^* = O(N^{-1/2}).$$

3. SOFW описан как стохастический блочно-координатный Frank–Wolfe для транспортной задачи; получена оценка $O(1/k)$ в ожидании.
4. Предложен DBCFW: распределенный блочно-координатный FW с консенсусом и gradient tracking; доказано

$$\mathbb{E}[f(x_{\text{avg},t}) - f(x^*)] = O(1/t).$$

5. Эксперименты показывают выигрыш CFW/NFW и SOFW по времени достижения заданного зазора.

Статьи в журналах из перечня ВАК

1. *Игнашин И. Н., Ярмошик Д. В.* Модификации алгоритма Frank–Wolfe в задаче поиска равновесного распределения транспортных потоков // Компьютерные исследования и моделирование. 2024. Т. 16. No. 1. С. 53–68.
2. *Ignashin I., Yarmoshik D., Raigorodskii A.* Stochastic Origin Frank–Wolfe Method for Traffic Assignment // Journal of Mathematical Sciences. 2025. Vol. 295. No. 2. P. 170–184.

Выступления с докладами

- ▶ 66-я Всероссийская научная конференция МФТИ: «О задаче поиска равновесного распределения потоков».
- ▶ Конференция TFN, Математический центр «Сириус»: «Equilibrium modeling of ski resorts».
- ▶ 68-я Всероссийская научная конференция МФТИ, ФПМИ, секция математических основ управления: «Децентрализованный блочно-координатный метод условного градиента».