

Приложения алгоритма Франк-Вульфа к задачам машинного обучения

Игнашин Игорь Николаевич

Московский физико-технический институт

09.04.01 Информатика и вычислительная техника

Научный руководитель: д.ф.-м.н. Грабовой А. О.

Москва, 2026

Почему Frank–Wolfe

Во многих задачах машинного обучения и сетевой оптимизации требуется решать

$$\min_{x \in \mathcal{X}} f(x),$$

где множество $\mathcal{X}$ имеет простую линейную оптимизацию, но дорогую евклидову проекцию.

Идея метода условного градиента

На каждой итерации вместо проекции решается линейная подзадача

$$s_k \in \arg \min_{s \in \mathcal{X}} \langle \nabla f(x_k), s \rangle, \quad x_{k+1} = x_k + \gamma_k (s_k - x_k).$$

Это делает Frank–Wolfe естественным инструментом для l_1 -ограничений, симплексов, транспортных политопов и блочных произведений множеств.

Главное ограничение базового FW

Классический Frank–Wolfe проекционно-свободен, но не решает все вычислительные проблемы.

Направление

Зигзагообразность траектории около границы допустимого множества.

Оракул

Полный линейный оракул может быть дорогим на крупных блочных задачах.

Данные

Функция и данные могут быть распределены между агентами сети.

Линия работы

Модификации FW рассматриваются как способы ускорить разные части одной итерации: выбор направления, вызов линейного оракула и коммуникацию.

Структура результатов

В работе объединены четыре связанных направления.

1. Модификации FW с памятью о предыдущих направлениях в транспортной задаче.
2. Перенос CFW и NFW на гладкие задачи машинного обучения.
3. Стохастический блочно-координатный FW для транспортных сетей.
4. Децентрализованный блочно-координатный FW для распределенной оптимизации.

Узкое место	Метод	Результат
направление	CFW/NFW	гарантия по FW-зазору
полный LMO	SOFW/BCFW	$O(1/k)$ в ожидании
коммуникации + LMO	DBCFW	$O(1/t)$ для $x_{\text{avg},t}$

Цель и задачи

Цель: развить и теоретически обосновать модификации Frank–Wolfe для задач, где стоимость линейного оракула, выбора направления или коммуникации определяет практическую эффективность метода.

Задачи:

1. Сформулировать CFW/NFW для гладкой выпуклой задачи на компактном множестве.
2. Получить оценку сходимости CFW по зазору Frank–Wolfe.
3. Описать SOFW как стохастический блочно-координатный FW и вывести оценку в ожидании.
4. Сформулировать DBCFW и доказать оценку сходимости для средней точки сети.
5. Проверить практический эффект на ML-задачах и транспортных сетях.

CFW и NFW: память о направлениях

В CFW новое направление строится как комбинация текущего FW-направления и предыдущего направления:

$$d_k = \alpha d_k^{FW} + (1 - \alpha)(1 - \gamma_{k-1})d_{k-1}.$$

Что это дает

- ▶ направление учитывает локальную геометрию траектории;
- ▶ NFW обобщает эту идею на несколько прошлых направлений;
- ▶ для ML-задач произведение на гессиан заменяется конечными разностями градиентов.

$$\nabla^2 f(x_k) d_{k-1} \approx \nabla f(x_k) - \nabla f(x_{k-1}).$$

Теоретический результат для CFW

Пусть $\mathcal{X}$ выпукло и компактно, а f выпукла и имеет L -липшицев градиент на $\mathcal{X}$. FW-зазор:

$$g_k = \langle \nabla f(x_k), x_k - s_k^{FW} \rangle.$$

Теорема


Для CFW с параметром $\alpha_0 \in (0, 1]$ и точным линейным поиском

$$g_N^* = \min_{1 \leq k \leq N} g_k \leq \frac{\max\{2h_0, LR^2\}}{\alpha_0 \sqrt{N+1}}.$$

Итог: CFW сохраняет стандартный порядок сходимости по зазору, но может улучшать практическое направление шага.

Эксперименты в машинном обучении

Рассматривалась логистическая регрессия с ограничением на l_1 -норму. Сравнивались FW, FW с линейным поиском, CFW и NFW.



CFW/NFW особенно полезны, когда активное ограничение создает зигзагообразное поведение базового FW.

SOFW: блочный оракул для транспортных сетей

В модели Бекмана допустимое множество имеет блочную структуру по OD-парам или источникам. Полная итерация FW требует решать задачи кратчайших путей для всех источников.

$$C_{FW} = \mathcal{O}(n(E + V \log V)).$$

Stochastic Origin Frank–Wolfe

На каждой итерации выбирается только часть блоков, и линейный оракул решается для выбранных источников:

$$C_{SOFW} = \mathcal{O}(\alpha n(E + V \log V)).$$

Цена ускорения: нужно хранить разложение потока по источникам и учитывать дисперсию стохастического направления.

Теоретический результат для SOFW

Для батчевого SOFW направление строится по случайному подмножеству блоков $\mathcal{I}_k$:

$$d_k = \frac{1}{m} \sum_{w \in \mathcal{I}_k} (s_k^{[w]} - x_k^{[w]}).$$

Теорема

При шаге

$$\gamma_k = \frac{2|OD|}{k + 2|OD|}$$


выполнена оценка

$$\mathbb{E}[\Psi(F(x_k))] - \Psi(F(x^*)) \leq \frac{2|OD|}{k + 2|OD|} (C_{\Psi}^{\otimes} + \Psi(F(x_0)) - \Psi(F(x^*))).$$

Итог: стохастизация уменьшает стоимость итерации, не меняя порядок гарантии.

SOFW: вычислительный эффект

Эксперименты проводились на транспортных сетях из открытого репозитория TransportationNetworks. Сравнивались FW, SOFW и взвешенный SOFW-w.



На крупных сетях стохастический оракул быстрее уменьшает относительный зазор при одинаковом вычислительном бюджете.

DBCFW: распределенная постановка

Пусть есть N агентов, и агент i знает только локальную функцию f_i :

$$\min_{x \in D} f(x), \quad f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x), \quad D = D_1 \times \dots \times D_n.$$

Децентрализация

- ▶ локальная копия x_t^i ;
- ▶ обмен только с соседями;
- ▶ матрица смешивания W_t .

Блочность

- ▶ выбирается батч блоков I_t^i ;
- ▶ LMO решается на D_t^i ;
- ▶ стоимость зависит от размера батча.

Алгоритм DBCFW

На каждой итерации агент выполняет три шага.

1. Консенсус по точкам

$$\tilde{x}_t^i = \sum_j (W_t)_{ij} x_t^j.$$

2. Отслеживание градиента

$$g_t^i = \tilde{g}_{t-1}^i + \nabla f_i(\tilde{x}_t^i) - \nabla f_i(\tilde{x}_{t-1}^i), \quad \tilde{g}_t^i = \sum_j (W_t)_{ij} g_t^j.$$

3. Блочный линейный оракул

$$v_t^i \in \arg \min_{v \in D_t^i} \langle \tilde{g}_t^i, v \rangle, \quad x_{t+1}^i = (1 - \gamma_t) \tilde{x}_t^i + \gamma_t v_t^i.$$

Теоретический результат для DBCFW

При стандартных предположениях о гладкости, выпуклости, компактности D и сжатии коммуникационной ошибки получена рекурсия для средней точки сети:

$$h_t = \mathbb{E}[f(x_{\text{avg},t}) - f(x^*)].$$

Теорема

При шаге

$$\gamma_t = \frac{2n}{B(t + \tau)}, \quad \tau = \frac{2n}{B},$$

выполнено

$$h_t \leq \frac{\tilde{A}_\tau}{t + \tau}, \quad \mathbb{E}[f(x_{\text{avg},t}) - f(x^*)] = O(1/t).$$

Влияние консенсуса, gradient tracking и размера батча входит в константу, но не ухудшает порядок сходимости.

Основные результаты и публикации

Результаты

1. CFW/NFW перенесены на ML без явного гессиана.
2. Для CFW доказано $g_N^* = O(N^{-1/2})$.
3. Для SOFW получено $O(1/k)$ в ожидании.
4. Для DBCFW доказано $\mathbb{E}[f(x_{\text{avg},t}) - f(x^*)] = O(1/t)$.
5. Эксперименты подтверждают выигрыш CFW/NFW и SOFW.

Публикации

- ▶ КИМ, 2024: модификации FW для транспортных потоков.
- ▶ Journal of Mathematical Sciences, 2025: SOFW для traffic assignment.

Дальше

- ▶ DBCFW на распределенных ML-задачах;
- ▶ блочные кривизны в константах;
- ▶ NFW + стохастические блоки.